

**IMPLEMENTASI PURWARUPA SISTEM
ASESMEN ADAPTIF KOLABORATIF BERBASIS
ELO RATING DENGAN MITIGASI
*OVERPERSONALIZATION***

Laporan Tugas Akhir

Oleh

**Dama Dhananjaya Daliman
18222047**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Mei 2026**

LEMBAR PENGESAHAN

IMPLEMENTASI PURWARUPA SISTEM ASESMEN ADAPTIF KOLABORATIF BERBASIS ELO RATING DENGAN MITIGASI *OVERPERSONALIZATION*

Laporan Tugas Akhir

Oleh

Dama Dhananjaya Daliman
18222047

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 24 Mei 2026

Pembimbing

Ir. Windy Gambetta, MBA.

NIP. 196404301989031005

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 24 Mei 2026

Dama Dhananjaya Daliman

NIM: 18222047

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Pembuatan teks	Gemini	Sedang	Subbab I.1 dan Abstrak
2	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
3	Pencarian informasi atau referensi	Consensus	Sedang	Bab II
4	Penyusunan bahan diskusi	Tidak ada	Tidak ada	Tidak ada
5	Penyusunan kode program	Kimi	Sedang	Kode Tampilan Sisi Klien
6	Penulisan formula atau perhitungan matematis dalam LaTeX	Gemini	Rendah	Bab II dan Bab III
7	Penyusunan konsep desain atau algoritma	Tidak ada	Tidak ada	Tidak ada
8	Penyusunan analisis data	Tidak ada	Tidak ada	Tidak ada

Bandung, 24 Mei 2026

Dama Dhananjaya Daliman

NIM: 18222047

ABSTRAK

IMPLEMENTASI PURWARUPA SISTEM ASESMEN ADAPTIF KOLABORATIF BERBASIS ELO RATING DENGAN MITIGASI *OVERPERSONALIZATION*

oleh

Dama Dhananjaya Daliman

18222047

Perkembangan sistem asesmen adaptif bertujuan untuk mengoptimalkan jalur belajar individu melalui personalisasi konten. Namun, ketergantungan pada algoritma personalisasi yang agresif berisiko memicu fenomena *overpersonalization*, yang menciptakan *filter bubbles* akademik dan mengisolasi pembelajar dari keragaman perspektif. Kondisi ini dapat menyebabkan pengambilan sampel informasi yang selektif serta stagnasi kognitif atau *learning plateau*. Penelitian ini bertujuan untuk merancang dan mengimplementasikan purwarupa sistem asesmen adaptif kolaboratif yang mengintegrasikan fitur sosial sebagai upaya eksploratif untuk meminimalkan efek *overpersonalization*. Solusi yang diusulkan menggabungkan algoritma *Elo rating* untuk pelacakan kemampuan kognitif dengan mekanisme interaksi kolaboratif guna menjaga keseimbangan antara adaptivitas personal dan dinamika sosial. Implementasi purwarupa dilakukan dengan membangun platform berbasis web yang mengintegrasikan metrik kinerja individu dan fitur interaksi antar-rekan. Sistem dirancang untuk merekomendasikan kolaborasi berdasarkan tingkat kompetensi siswa, sehingga diharapkan dapat memberikan paparan terhadap perspektif komunitas tanpa mengorbankan fungsionalitas adaptif sistem.

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum. Sed ut perspiciatis unde omnis iste natus error sit voluptatem accusantium doloremque laudantium, totam rem aperiam, eaque ipsa quae ab illo inventore veritatis et quasi architecto beatae vitae dicta sunt explicabo. Nemo enim ipsam voluptatem quia voluptas sit aspernatur aut odit aut fugit, sed quia consequuntur magni dolores eos qui ratione voluptatem sequi nesciunt.

Kata kunci: Asesmen Adaptif, Pembelajaran Kolaboratif, Elo Rating, Overpersonalization, Filter Bubble.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, saya dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul "Implementasi Algoritma XYZ untuk Optimasi Jaringan Komputer". Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Bandung, 20 Mei 2026

Penulis

Dama Dhananjaya Daliman

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
DAFTAR PERSAMAAN	xxi
DAFTAR ALGORITMA	xxiii
DAFTAR <i>LISTING</i>	xxv
DAFTAR SIMBOL	xxvii
DAFTAR SINGKATAN	xxxi
 I PENDAHULUAN	 1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	2
I.4 Batasan Masalah	3
I.5 Metodologi	4
 II STUDI LITERATUR	 5
II.1 Pembelajaran Adaptif dan Asesmen Adaptif	5
II.1.1 Jenis Penilaian	6
II.1.2 Luaran yang Dinilai	7
II.1.3 Taksonomi Bloom dalam Asesmen Kognitif	8
II.2 Pemodelan Siswa (<i>Student Modeling</i>)	9
II.3 Teknik dan Algoritma <i>Adaptive Assessment</i>	11
II.3.1 <i>Item Response Theory</i> (IRT)	11
II.3.2 <i>Factor Analysis</i> (FA)	12
II.3.3 <i>Hidden Markov Models</i> (HMM) dan <i>Bayesian Knowledge Tracing</i> (BKT)	13
II.3.4 <i>Deep Knowledge Tracing</i> (DKT)	14
II.3.5 Sistem <i>Elo rating</i>	15
II.3.6 Posisi Teknik dan Algoritma dalam Sistem Asesmen Adaptif Individual	16
II.3.7 Karakteristik Ukuran Bank Soal dalam Implementasi Asesmen Adaptif Skala Kelas	18
II.4 Pembelajaran Kolaboratif dan CSCL	18
II.4.1 Prinsip Pembelajaran Kolaboratif berbasis Teknologi	19
II.4.2 Pengukuran Heterogenitas Kelompok dan <i>Effect Size</i>	19
II.4.3 Aktivitas Pembelajaran Sosial dan Dampaknya	21
II.4.4 Tantangan dalam Menilai Kolaborasi	23
II.4.5 Metode Pembobotan Penilaian Terintegrasi	24

II.5	Upaya Integrasi Penilaian Personal dalam Lingkungan Kolaboratif yang Sudah Ada Saat Ini	24
II.6	<i>Overpersonalization</i> dalam Konteks Pendidikan	25
II.6.1	Manifestasi <i>Overpersonalization</i> dalam Pembelajaran	26
II.6.2	Pengukuran <i>Overpersonalization</i> dalam Pembelajaran	26
II.7	Upaya Penyelesaian Masalah <i>Overpersonalization</i> yang Ada Saat Ini	26
II.7.1	Sistem Rekomendasi yang Dapat Dikontrol Pengguna (<i>User Controllable Recommender Systems</i>)	27
II.7.2	Pendekatan Berbasis Kelompok (<i>Group Recommender Systems</i>)	28
II.7.3	Pemodelan Komunitas Implisit untuk Memecahkan <i>Echo Chamber</i>	29
II.7.4	Mitigasi Dampak <i>Echo Chamber</i> Melalui <i>Constraint-Based Re-ranking</i>	30
II.8	Metodologi Evaluasi Purwarupa Sistem Pembelajaran	32
II.8.1	Pengukuran Efektivitas dengan <i>Normalized Learning Gain</i>	32
II.8.2	Penentuan Ukuran Sampel dalam Studi Pilot	33
II.9	Evaluasi Kebenaran Kueri SQL	34
III	ANALISIS MASALAH	35
III.1	Analisis Kondisi Saat Ini	35
III.2	Analisis Kebutuhan	36
III.2.1	Kebutuhan Fungsional	36
III.2.2	Kebutuhan Nonfungsional	37
III.2.3	Pemetaan Kebutuhan	38
III.3	Analisis Pemilihan Solusi	39
III.3.1	Alternatif Solusi	39
III.3.1.1	Alternatif Teknik Asesmen Kemahiran Individu (R1)	39
III.3.1.2	Alternatif Teknik Interaksi dan Asesmen Sosial (R2 & R3)	40
III.3.1.3	Alternatif Teknik Pencegahan <i>Echo Chamber</i> dan <i>Filter Bubble</i>	41
III.3.2	Analisis Penentuan Solusi	42
III.3.2.1	Penentuan Teknik Asesmen Individu	42
III.3.2.2	Penentuan Teknik Interaksi Sosial	43
III.3.2.3	Penentuan Teknik Mitigasi <i>Overpersonalization</i>	44
III.3.3	Keputusan Akhir Pemilihan Solusi	46
IV	PERANCANGAN ARSITEKTUR DAN INTERAKSI SISTEM	49
IV.1	Model Konteks dan Interaksi (<i>Use Case Diagram</i>)	49
IV.2	Model Struktur dan Perilaku (<i>Communication Diagram</i>)	54
IV.3	Perbandingan dengan Sistem Saat Ini	56
V	IMPLEMENTASI MEKANISME MITIGASI DAN IMPLEMENTASI SISTEM	59
V.1	Lingkungan Pengembangan Sistem	59
V.2	Persiapan Materi dan Instrumen Bank Soal	59

V.2.1	Struktur Kurikulum dan Distribusi Bank Soal	59
V.2.2	Kalkulasi Ambang Batas Transisi Modul	60
V.2.3	Evaluasi Kualitas Umpan Balik Berbasis NLP	60
V.3	Implementasi Teknis <i>Backend</i>	61
V.3.1	Arsitektur API dan Standardisasi	61
V.3.2	Mesin Elo dan Deteksi Stagnasi	62
V.3.3	Mekanisme Perekaman Data Trajektori (<i>Data Logging</i>)	65
V.3.4	Keamanan Eksekusi dan <i>Sandbox SQL</i>	66
V.4	Implementasi Teknis <i>Frontend</i>	66
V.4.1	Arsitektur Perangkat Lunak dan Antarmuka	66
V.4.2	Manajemen <i>State</i> Global dengan <i>Zustand</i>	67
V.4.3	Editor Kode dan Eksekusi Query	67
V.4.4	Visualisasi Kemahiran dan Umpan Balik Pengerjaan	67
V.4.5	Routing dan Keamanan Sisi Klien	68
V.5	Integrasi dan <i>Deployment</i>	68
VI	EVALUASI DAN PEMBAHASAN	69
VI.1	Analisis Kesesuaian Pelaksanaan	69
VI.1.1	Kesesuaian Linimasa Pelaksanaan	69
VI.1.2	Kesesuaian Anggaran Biaya	70
VI.2	Prosedur Pengujian Laboratorium (<i>Lab Study</i>)	70
VI.3	Hasil dan Analisis Peningkatan Hasil Belajar	70
VI.3.1	Uji Kesetaraan Awal (<i>Baseline Equivalence</i>)	70
VI.3.2	Perbandingan Skor Pre-test dan Post-test	71
VI.3.3	Analisis Signifikansi Peningkatan (NLG)	71
VI.4	Hasil dan Analisis Efektivitas Mitigasi <i>Overpersonalization</i>	72
VI.4.1	Analisis Perubahan Kemahiran (<i>Slope $\Delta\theta$</i>)	72
VI.4.2	Validitas Pemicuan Stagnasi (<i>Trigger Rate</i>)	73
VI.5	Hasil dan Analisis Komponen Kolaboratif	73
VI.5.1	Validitas Algoritma <i>Constraint-based Re-ranking</i>	74
VI.5.2	Kualitas Umpan Balik Sejawat (<i>Peer Feedback Quality</i>)	74
VI.5.3	Konvergensi <i>Social Elo</i>	74
VI.6	Pembahasan Umum dan Implikasi	75
VII	PENUTUP	77
VII.1	Kesimpulan	77
VII.2	Saran	78
VII.3	Saran Pengembangan Selanjutnya	78

DAFTAR GAMBAR

II.1	Contoh Model Konseptual dari BKT Standard yang Mengestimasi Transisi <i>State</i> siswa dari Belum Dipelajari (<i>Not Learned</i>) menjadi Sudah Dipelajari (<i>Learned</i>) (diadaptasi dari Minn (2022))	14
II.2	Model Konseptual Alur Proses Sistem Adaptif Individual (diadaptasi dari Vesin dkk. (2022))	17
II.3	Model Konseptual Antarmuka Pembelajaran Sosial (OSSM) (diadaptasi dari Brusilovsky dkk. (2016))	25
II.4	Model Konseptual Sistem Rekomendasi yang Dapat Dikontrol Pengguna (UCRS) (diadaptasi dari Wang dkk. (2022))	27
II.5	Diagram Arsitektur FRediECH (diadaptasi dari Tommasel, Rodriguez, dan Godoy (2021))	29
IV.1	Use Case Diagram - Interaksi Siswa dengan Sistem Asesmen Adaptif Kolaboratif	50
IV.2	<i>Communication Diagram</i> - Alur Interaksi pada Sistem	55
VI.1	Gantt Chart Realisasi Pelaksanaan Implementasi dan Pengujian . . .	69
VI.2	Visualisasi Perubahan Momentum Belajar Sebelum dan Sesudah Titik Pertama Stagnasi	72

DAFTAR TABEL

III.1	Kebutuhan Fungsional (FR) Sistem	37
III.2	Kebutuhan Nonfungsional (NFR) Sistem	38
III.3	Pemetaan Masalah dan Kebutuhan Fungsional	38
III.4	Matriks Keputusan Teknik Asesmen Individu	43
III.5	Matriks Keputusan Teknik Interaksi Sosial	44
III.6	Matriks Keputusan Teknik Mitigasi Isolasi	45
IV.1	Pemetaan Kebutuhan Fungsional ke Use Case	49
IV.2	Deskripsi Use Case Kelola Akun (UC-01)	50
IV.3	Deskripsi Use Case Mengerjakan Latihan Adaptif (UC-02)	51
IV.4	Deskripsi Use Case Melakukan <i>Peer Assessment</i> (UC-03)	52
IV.5	Deskripsi Use Case Melihat Umpan Balik Rekan (UC-04)	52
IV.6	Deskripsi Use Case Memantau Profil Kompetensi (UC-05)	53
IV.7	Deskripsi Use Case Memantau Konteks Sosial (UC-06)	53
IV.8	Perbandingan Desain Sistem <i>As-Is</i> vs <i>To-Be</i>	57
VI.1	Realisasi Anggaran Biaya Implementasi	70
VI.2	Perbandingan Skor Rata-rata Pre-test dan Post-test	71
VI.3	Statistik Kualitas Umpan Balik Kolaboratif	74

DAFTAR PERSAMAAN

DAFTAR ALGORITMA

DAFTAR *LISTING*

II.1	Algoritma Re-ranking	31
V.1	Algoritma Deteksi Stagnasi dan Fallback	63
V.2	Algoritma Perekaman Data Trajektori	65

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk CTC <i>loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ϵ	<i>Token blank</i> /kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam CTC	75
π_t	<i>Token</i> pada <i>timestep</i> t dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	L1 <i>loss</i> (<i>Mean Absolute Error</i>)	75
$\mathcal{L}_{L2}$	L2 <i>loss</i> (<i>Mean Squared Error</i>)	75
$\mathcal{L}_{CTC}$	CTC (<i>Connectionist Temporal Classification</i>) <i>loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75

$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator dalam GAN</i>	75
D	<i>Discriminator dalam GAN</i>	75
$G(z)$	<i>Output dari generator dengan input z</i>	75
$D(x)$	<i>Output dari discriminator dengan input x</i>	75
$G_{A \rightarrow B}$	<i>Generator dari domain A ke B</i>	75
$G_{B \rightarrow A}$	<i>Generator dari domain B ke A</i>	75
$V(D, G)$	<i>Fungsi nilai (value function) dalam GAN</i>	75
x	<i>Sampel data asli, input citra</i>	75
y	<i>Label atau ground truth, kondisi dalam conditional GAN</i>	75
z	<i>Noise vector atau representasi laten</i>	
$\mathbb{E}$	<i>Ekspektasi atau nilai harapan</i>	75
p_{data}	<i>Distribusi data asli</i>	75
p_z	<i>Distribusi prior (noise)</i>	75
$p(y x)$	<i>Probabilitas bersyarat output y given input x</i>	75
$p_t(\pi_t x)$	<i>Probabilitas token pada timestep t</i>	
$\mathcal{B}$	<i>Fungsi penciutan (collapse function) dalam CTC</i>	75
$\mathcal{B}^{-1}$	<i>Fungsi invers penciutan dalam CTC</i>	75
T	<i>Jumlah timestep atau panjang sequence</i>	
$ x - G(y) _1$	<i>L1 distance antara ground truth dan generated image</i>	75
$ x - G(y) _2$	<i>L2 distance antara ground truth dan generated image</i>	75
$N \times N$	<i>Ukuran patch dalam PatchGAN</i>	
d	<i>Cohen's d (effect size)</i>	75
n	<i>Jumlah sampel</i>	75
p	<i>p-value (nilai probabilitas statistik)</i>	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	1
CNN	<i>Convolutional Neural Network</i>	2
GPU	<i>Graphics Processing Unit</i>	14

BAB I

PENDAHULUAN

I.1 Latar Belakang

Pergeseran paradigma pendidikan tinggi global saat ini bergerak signifikan dari pendekatan pedagogis yang berpusat pada pengajar menuju pendekatan yang berpusat pada siswa melalui *Personalized Learning* (Ryoo dan Winkelmann 2021). Transformasi ini didorong oleh sistem *Adaptive Assessment* (AA) berbasis kecerdasan artifisial yang secara dinamis menyesuaikan tingkat kesulitan konten berdasarkan kinerja peserta didik secara *real-time* (Halkiopoulos dan Gkintoni 2024). Sejalan dengan visi tersebut, pemerintah Indonesia melalui Strategi Nasional Kecerdasan Artifisial (Stranas KA) 2020–2045 secara eksplisit mendorong pengembangan sistem penilaian cerdas yang adaptif (Kelompok Kerja Penyusun Strategi Nasional untuk Kecerdasan Artifisial 2020). Secara teknis, berbagai algoritma mulai dari *Bayesian Knowledge Tracing* (BKT), *Deep Knowledge Tracing* (DKT), hingga sistem *Elo rating* telah dikembangkan untuk mengestimasi kemampuan siswa secara presisi (Minn 2022; Vesin dkk. 2022). Implementasi teknik tersebut krusial untuk meninggalkan pendekatan kaku “*one size fits all*” demi mengoptimalkan jalur belajar individu di era digital.

Meskipun teknik-teknik tersebut unggul dalam mengoptimalkan jalur belajar individu, penerapan yang naif terhadap algoritma yang hanya berfokus pada preferensi historis individu membawa risiko laten yang serius. Dalam literatur sistem rekomendasi modern, fenomena ini dikenal sebagai masalah *filter bubbles*, dalam fenomena ini algoritma secara tidak sengaja mengisolasi pengguna dari keragaman informasi dan perspektif dengan hanya menyajikan konten yang selaras dengan riwayat mereka (Wang dkk. 2022). Dalam konteks pendidikan, risiko ini bermanifestasi sebagai *overpersonalization* (personalisasi berlebihan), yang menyebabkan sistem terlalu agresif dalam menyesuaikan konten dengan kenyamanan individu sehingga justru mengasingkan siswa dari manfaat pembelajaran komunitas (Halkiopoulos dan Gkintoni 2024). Algoritma yang bekerja semata-mata berdasarkan prinsip homofili (kemiripan) cenderung menciptakan *echo chambers* akademik (Tommasel, Rodriguez, dan

Godoy 2021), menghalangi interaksi sosial yang krusial bagi pengembangan keterampilan kolaboratif.

Tinjauan literatur terkini mengonfirmasi bahwa ketergantungan eksklusif pada algoritma personalisasi yang hanya mengoptimalkan parameter individu tanpa ruang eksplorasi membawa dampak kognitif yang merugikan bagi pembelajar. Bukti eksperimental menunjukkan bahwa lingkungan yang terpersonalisasi secara agresif memicu pengambilan sampel informasi yang sangat selektif sehingga membentuk representasi kognitif yang terdistorsi (Bahg, Sloutsky, dan Turner 2025). Masalah ini semakin kritis karena siswa sering menunjukkan rasa percaya diri berlebih pada generalisasi pengetahuan yang keliru dan rentan terjebak dalam *learning plateau* (Bahg, Sloutsky, dan Turner 2025; Halkiopoulou dan Gkintoni 2024). Dalam konteks nasional, ancaman *filter bubbles* akademik ini berisiko melahirkan generasi pembelajar yang terisolasi kognisinya jika implementasi Stranas KA hanya mengadopsi teknologi adaptif konvensional. Oleh karena itu, risiko isolasi kognitif ini harus dipahami secara mendalam agar intervensi teknologi tidak justru mengasingkan pembelajar dari manfaat esensial pembelajaran komunitas.

I.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, teridentifikasi adanya kebutuhan untuk mengeksplorasi pengembangan sistem asesmen yang selaras dengan Stranas KA, namun juga mempertimbangkan risiko isolasi pembelajaran pada sistem adaptif konvensional. Kesenjangan teknologi saat ini terletak pada terbatasnya penelitian yang menguji apakah integrasi fitur kolaboratif dalam sistem asesmen adaptif dapat meminimalkan efek *overpersonalization*. Maka dari itu, permasalahan utama yang ingin diselesaikan adalah:

1. Bagaimana merancang arsitektur sistem asesmen adaptif yang mampu mengintegrasikan parameter kemahiran individual dengan dimensi kontribusi sosial secara terpadu?
2. Bagaimana mengembangkan mekanisme mitigasi *overpersonalization* berbasis deteksi stagnasi kognitif dan pemilihan mitra kolaborasi yang heterogen?
3. Bagaimana mengimplementasikan rancangan arsitektur dan mekanisme tersebut menjadi purwarupa sistem asesmen adaptif kolaboratif yang fungsional?

Sebagai upaya untuk menjawab permasalahan tersebut, tugas akhir ini mengusulkan pengembangan purwarupa sistem asesmen adaptif kolaboratif yang mengintegrasikan mekanisme intervensi proaktif. Kontribusi dari pekerjaan ini terletak pada penggabungan metrik kemahiran individual dengan dimensi kontribusi sosial ke dalam sebuah arsitektur asesmen yang terpadu. Selain itu, penelitian ini mengusulkan

pengembangan metode mitigasi risiko *overpersonalization* melalui deteksi stagnasi kognitif secara otomatis, yang diharapkan dapat menjaga dinamika pertumbuhan pengetahuan pembelajar dalam lingkungan yang terpersonalisasi.

I.3 Tujuan

Tujuan utama dari tugas akhir ini adalah **membangun purwarupa sistem asesmen adaptif kolaboratif untuk menguji apakah integrasi fitur kolaboratif dapat meminimalkan efek *overpersonalization* dalam lingkungan pembelajaran.**

Secara spesifik, tujuan penelitian ini adalah:

1. Merancang arsitektur sistem asesmen adaptif yang mampu mengintegrasikan parameter kemahiran individual (*Elo Rating*) dengan dimensi kontribusi sosial secara holistik.
2. Mengembangkan mekanisme mitigasi *overpersonalization* melalui algoritma deteksi stagnasi kognitif dan pemilihan mitra kolaborasi yang heterogen.
3. Mengimplementasikan rancangan arsitektur dan mekanisme tersebut menjadi purwarupa sistem asesmen adaptif kolaboratif yang fungsional sebagai bukti konsep (*proof-of-concept*).

I.4 Batasan Masalah

Untuk memastikan penelitian ini tetap fokus dan dapat diselesaikan dalam jangka waktu yang ditentukan, maka ditetapkan batasan-batasan sebagai berikut:

1. Permasalahan asesmen adaptif yang dikaji akan difokuskan pada konteks yang selaras dengan visi Strategi Nasional Kecerdasan Artifisial (Stranas KA) Indonesia. Ini berarti penelitian berfokus pada pengembangan sistem yang mendukung ekosistem kolaboratif, yang disesuaikan dengan kebutuhan dan potensi implementasi di lingkungan pendidikan tinggi di Indonesia.
2. Fokus masalah utama penelitian ini adalah pada kesenjangan integrasi algoritmik antara asesmen adaptif individual and asesmen kolaboratif. Penelitian tidak akan menginvestigasi masalah lain dalam asesmen adaptif (seperti deteksi gaya belajar atau deteksi kecurangan dalam asesmen), melainkan terbatas pada perancangan model yang menggabungkan metrik kemahiran personal dengan metrik kinerja sosial.
3. Permasalahan yang dikaji terbatas pada penilaian luaran kognitif (*cognitive outcomes*), yaitu pelacakan "keterampilan" dan "pengetahuan" siswa. Penelitian ini tidak akan mencakup perancangan model untuk menilai luaran afektif (seperti motivasi atau kepuasan) atau luaran perilaku (seperti durasi belajar) sebagai ukuran utama kemahiran.

4. Implementasi purwarupa sistem akan diujicobakan pada populasi sampel terbatas. Merujuk pada konteks pendidikan tinggi di Indonesia and ketersediaan sumber daya, uji coba akan difokuskan pada sekelompok mahasiswa dari angkatan tertentu di institusi tertentu.

I.5 Metodologi

Pelaksanaan tugas akhir ini akan mengadopsi and mengadaptasi metodologi yang digunakan oleh Vesin dkk. (2022) dalam penelitian mereka mengenai asesmen adaptif and rekomendasi konten. Metodologi ini terdiri atas beberapa tahapan utama yang sistematis, dimulai dari studi pendahuluan hingga analisis data sebagai .

1. **Studi Literatur:** Melakukan tinjauan sistematis terhadap penelitian terkait asesmen adaptif, pembelajaran kolaboratif, and implementasi sistem serupa.
2. **Perancangan and Pengembangan Sistem:** Merancang arsitektur perangkat lunak serta mengimplementasikan modul-modul sistem, termasuk integrasi algoritma asesmen adaptif and antarmuka pengguna kolaboratif.
3. **Sesi Pengguna (Pengujian and Evaluasi):** Melaksanakan studi dengan partisipan sebagai sampel populasi pengguna untuk mengumpulkan data kuantitatif and kualitatif mengenai penggunaan and pengalaman mereka terhadap purwarupa sistem. Data yang dikumpulkan dapat mencakup data interaksi (*click-streams*, *log files*), hasil asesmen (peringkat yang dihasilkan), serta umpan balik pengguna (misalnya melalui survei atau wawancara).
4. **Analisis Data:** Menganalisis data yang terkumpul untuk mengevaluasi fungsionalitas purwarupa and efektivitas sistem dalam konteks asesmen adaptif and kolaboratif, guna menjawab rumusan masalah serta tujuan penelitian.
5. **Penarikan Kesimpulan and Pelaporan:** Menyusun laporan tugas akhir berdasarkan hasil analisis and temuan penelitian.

BAB II

STUDI LITERATUR

II.1 Pembelajaran Adaptif dan Asesmen Adaptif

Lingkungan pembelajaran adaptif (*adaptive learning environments*) bertujuan untuk meningkatkan perolehan pembelajaran individu dan pengalaman siswa dalam lingkungan pembelajaran yang dipersonalisasi. Untuk mendukung pengembangan lingkungan pembelajaran adaptif secara efektif, diperlukan metode asesmen pengetahuan yang efisien untuk menilai keterampilan siswa secara empiris (Minn 2022). Penilaian pembelajar adalah salah satu momen utama dalam proses pendidikan.

Pembelajaran adaptif (*adaptive learning*), secara definisi, adalah metodologi untuk menyesuaikan dan mempersonalisasi proses pembelajaran, terutama konten, kepada seorang pembelajar, agar sesuai dengan situasi dan keadaan yang berbeda. Tujuan dari *adaptive learning system* (ALS) atau sistem pembelajaran adaptif adalah untuk mengubah instruksi menggunakan seperangkat aturan yang telah ditentukan untuk menyediakan materi pembelajaran yang disesuaikan dengan kebutuhan dan perilaku siswa. Pembelajaran adaptif memberikan kemungkinan untuk menjadikan pembelajar sebagai kolaborator dalam proses pendidikan alih-alih penerima informasi pasif, karena setiap pembelajar memiliki jalur pembelajaran optimal spesifik yang terdiri dari banyak titik terhubung, dan setiap titik mewakili komponen pengetahuan atau keterampilan (Ihichr dkk. 2024).

Pembelajaran adaptif mempertimbangkan banyak aspek, seperti tingkat pembelajar saat ini, kebutuhan individu, gaya belajar, dan interaksi yang berbeda dengan siswa untuk mengindividualisasi semua komponen proses pembelajaran: konten, antarmuka, gaya belajar, dan asesmen. Oleh karena itu, pembelajaran adaptif memungkinkan seorang siswa untuk maju ke materi yang lebih menantang berdasarkan kinerjanya, sambil di sisi lain tetap memberikan dukungan tambahan kepada siswa lainnya untuk menguasai keterampilan tertentu. Pendekatan ini memastikan bahwa pembelajar tidak dibatasi oleh kecepatan kelas tetapi dapat mengikuti kecepatan belajar mereka sendiri. Dengan demikian, instruktur dan pembelajar dapat membuat kepu-

tusan yang tepat pada saat yang tepat dengan mengikuti kurva belajar dan lintasan belajar (*learning path*). Singkatnya, pembelajaran adaptif berusaha untuk menyesuaikan pengalaman pendidikan untuk membantu siswa mencapai tujuan pembelajaran mereka dengan meniru interaksi personalisasi satu lawan satu antara seorang guru dan seorang pembelajar (Ihichr dkk. 2024).

Pernyataan oleh psikolog Lauren Resnick, "Apa yang kita nilai adalah apa yang kita hargai. Kita mendapatkan apa yang kita nilai, dan jika kita tidak menilainya, kita tidak mendapatkannya", menunjukkan pentingnya asesmen sebagai langkah utama dan kritis dalam proses pendidikan. Banyak sistem pembelajaran adaptif lebih fokus pada asesmen daripada konten. Data asesmen yang dikumpulkan dari respons siswa digunakan untuk mempersonalisasi proses pembelajaran, menciptakan jalur yang disesuaikan berdasarkan hasil. Jalur ini terus diperbarui dengan setiap asesmen. Dengan demikian, asesmen pembelajar dianggap sebagai faktor krusial untuk proses *e-learning* yang sukses (Ihichr dkk. 2024).

Berbeda dengan pengujian konvensional, yang didasarkan pada *item* tetap yang harus dihadapi setiap peserta ujian terlepas dari tingkat pengetahuan mereka, asesmen adaptif memungkinkan pemilihan pertanyaan berdasarkan kinerja peserta ujian. Sistem asesmen adaptif secara terus-menerus menyesuaikan kembali proses asesmennya sehubungan dengan tingkat kesulitan, dan sesuai dengan kinerja, preferensi, motivasi, pengetahuan, serta tujuan pendidikan yang diekspresikan oleh pembelajar (Halkiopoulou dan Gkintoni 2024). Asesmen adaptif menyediakan tes singkat yang dipersonalisasi, *item*-nya berubah tergantung pada respons siswa, dan kesulitan setiap pertanyaan berkorelasi dengan jawaban pertanyaan sebelumnya. Singkatnya, asesmen adaptif berusaha menghindari penyajian pertanyaan mudah kepada siswa yang mampu, yang kemungkinan akan menjawab dengan benar, dan pertanyaan menantang tidak disajikan kepada siswa yang kesulitan (Ihichr dkk. 2024).

II.1.1 Jenis Penilaian

Menurut Ihichr dkk. (2024), asesmen pengetahuan secara global dapat dibagi menjadi tiga jenis: sumatif, formatif, dan pra-asesmen. Umumnya, asesmen sumatif lebih dominan daripada asesmen formatif dalam *e-learning*, tetapi dua jenis terakhir telah menunjukkan potensi lebih, terutama dalam pembelajaran adaptif.

1. Asesmen sumatif juga dikenal sebagai asesmen pembelajaran (*assessment of learning*), jenis evaluasi ini terjadi di akhir siklus pembelajaran untuk mengukur pencapaian pembelajar dan memverifikasi penguasaan unit kurikulum. Asesmen ini bertujuan menilai kemajuan kumulatif pembelajar (Ihichr dkk.

2024). Informasi dari asesmen sumatif dapat digunakan secara formatif untuk memandu aktivitas mereka di pembelajaran selanjutnya (Minn 2022).

2. Asesmen formatif atau yang disebut juga asesmen untuk pembelajaran (*assessment for learning*), ini terjadi sepanjang siklus pembelajaran untuk memberikan informasi umpan balik kepada tutor dan pembelajar untuk membantu meningkatkan pengalaman belajar mereka. Jenis asesmen ini menilai kualitas pembelajaran dengan memposisikan asesmen antara pengajaran dan pembelajaran (kemajuan saat ini) alih-alih diposisikan hanya di akhir proses. Ketika asesmen formatif begitu tertanam dalam lingkungan pembelajaran sehingga pemisahan antara asesmen dan pembelajaran benar-benar kabur dan tidak terlihat oleh siswa, konsep ini dikenal sebagai *stealth assessment*. Asesmen formatif memungkinkan kita untuk menyempurnakan lintasan pembelajaran, meningkatkan keterlibatan dan antusiasme siswa untuk menguasai suatu materi pembelajaran dan mengembangkan disiplin dalam dirinya (Ihichr dkk. 2024).
3. Pra-asesmen atau yang dikenal sebagai asesmen diagnostik, jenis asesmen ini mengukur kompetensi awal setiap pembelajar, memberikan gambaran yang jelas kepada guru tentang tingkat keterampilan pembelajar. Ini seringkali diikuti oleh semacam instruksi kompensasi untuk menghilangkan hambatan dan menawarkan berbagai jenis kegiatan remedial. Pra-asesmen biasanya dilakukan di awal pembelajaran dan dirancang untuk mengukur pengetahuan yang sudah diperoleh sebelumnya oleh siswa untuk mengidentifikasi kebutuhan, kompetensi, prasangka, dan pengetahuan sebelumnya dari siswa tersebut, untuk mengarahkan mereka ke kurikulum yang paling sesuai (Ihichr dkk. 2024).

II.1.2 Luaran yang Dinilai

Ihichr dkk. (2024) mendefinisikan tiga hasil pembelajaran utama yang dinilai dalam pembelajaran daring, yaitu hasil pembelajaran kognitif, perilaku, dan afektif. Studi tersebut menunjukkan bahwa ketiga aspek ini saling berkorelasi.

1. **Luaran Kognitif:** luaran ini secara mendasar berkaitan dengan pengetahuan yang diperoleh dan keterampilan intelektual. Pengetahuan adalah semua informasi yang telah dipelajari siswa dari suatu topik, tetapi keterampilan intelektual menyangkut kemampuan yang berbeda, seperti penalaran, proses berpikir, dan pengambilan keputusan (Ihichr dkk. 2024).
2. **Luaran Perilaku:** luaran perilaku merujuk pada pengukuran keterlibatan pembelajar dengan memantau perilakunya selama pembelajaran seperti durasi dan waktu belajar, partisipasi dalam forum dan diskusi, pengumpulan tugas, dan penyelesaian tes (Ihichr dkk. 2024).
3. **Luaran Afektif:** luaran ketiga ini berkaitan dengan persepsi siswa, kepu-

asan mereka terhadap pembelajaran, apresiasi terhadap pengalaman belajar mereka, dan manfaat yang diharapkan oleh mereka ketika mendaftarkan diri mengikuti suatu pembelajaran. Sebagian besar pembelajaran dan asesmen di pendidikan tinggi berkonsentrasi pada hasil kognitif daripada hasil afektif dan perilaku (Ihichr dkk. 2024).

II.1.3 Taksonomi Bloom dalam Asesmen Kognitif

Kerangka kerja fundamental yang digunakan untuk mengklasifikasikan tujuan pendidikan dan mengukur kedalaman kognitif siswa adalah *Bloom's Revised Taxonomy*. Sebagaimana dijelaskan oleh Gosselin dan Okamoto (2018), taksonomi ini membagi domain kognitif menjadi enam tingkatan hierarkis, yang bergerak dari proses berpikir tingkat rendah (*lower-order cognition*) menuju tingkat tinggi (*high-level cognition*). Tingkatan tersebut dimulai dari *Remembering* (mengingat) dan *Understanding* (memahami) sebagai fondasi dasar, kemudian berlanjut ke *Applying* (menerapkan), *Analyzing* (menganalisis), *Evaluating* (mengevaluasi), hingga puncaknya pada *Creating* (mencipta). Dalam konteks asesmen, idealnya *Performance Indicators* (PI) dirancang dengan memadukan berbagai level ini sehingga siswa tidak hanya dituntut untuk mengingat fakta, tetapi juga menerapkan materi yang dipelajari dalam cara-cara yang kompleks. Penggunaan taksonomi ini memungkinkan penerjemahan luaran pembelajaran yang abstrak menjadi perilaku yang dapat diamati (*observable behaviors*) dan diukur secara konkret.

Penerapan taksonomi ini dalam sistem asesmen memerlukan instrumen yang presisi, seperti penggunaan *descriptive rubrics* (rubrik deskriptif). Gosselin dan Okamoto (2018) menekankan bahwa penggunaan rubrik deskriptif yang diselaraskan dengan kata kerja operasional Bloom dapat meningkatkan konsistensi penilaian antarevaluator dan memberikan umpan balik yang lebih bermakna dibandingkan sekadar skala numerik generik. Rubrik ini mendeskripsikan variasi tingkat kinerja untuk setiap kriteria secara spesifik. Misalnya, dalam menilai kemampuan desain teknik, indikator kinerja direvisi dari sekadar berbasis topik menjadi berbasis level kognitif, seperti bergerak dari kemampuan "mengidentifikasi prinsip sains" (*Understanding*) menuju kemampuan "membuat asumsi penyederhanaan dan mengevaluasi solusi" (*Evaluating*). Pendekatan ini sangat relevan untuk asesmen sejawat (*peer assessment*) karena rubrik yang terstruktur digunakan dalam asesmen untuk membantu siswa menilai kontribusi rekannya secara objektif berdasarkan deskripsi kinerja yang jelas, bukan sekadar persepsi subjektif.

Dalam disiplin ilmu komputasi, penggunaan kata kerja standar Bloom sering kali ti-

dak memadai untuk menangkap nuansa teknis dari tugas-tugas pemrograman dan sistem informasi. Untuk mengatasi keterbatasan ini, Computing Education in Community Colleges (2023) melalui *ACM Committee for Computing Education in Community Colleges* (CCECC) mengusulkan peningkatan taksonomi dengan menambahkan 56 kata kerja spesifik komputasi (*enhanced verbs*). Modifikasi ini memetakan aktivitas teknis ke dalam level kognitif yang sesuai. Sebagai contoh, aktivitas *Code* (mengodekan), *Build* (membangun), dan *Decrypt* (mendekripsi) dikategorikan ke dalam level *Applying*. Sementara itu, aktivitas yang membutuhkan pemecahan masalah lebih dalam seperti *Debug* (men-debug), *Optimize* (mengoptimalkan), dan *Refactor* diposisikan pada level *Evaluating*. Aktivitas sintesis seperti *Script* (membuat skrip), *Virtualize* (memvirtualisasi), dan *Program* (membuat program solusi) ditempatkan pada level tertinggi, yaitu *Creating*.

Integrasi kata kerja komputasi ini memungkinkan perancangan *competencies* yang lebih akurat, yang didefinisikan sebagai integrasi antara pengetahuan (*knowledge*), keterampilan (*skills*), dan disposisi (*dispositions*) dalam konteks tertentu (Computing Education in Community Colleges 2023). Dalam lingkungan pembelajaran adaptif, pemetaan ini krusial untuk melacak progresi siswa. Seorang siswa mungkin memulai pembelajaran pada level *Applying* dengan menerjemahkan spesifikasi menjadi kode, namun seiring waktu diharapkan berkembang ke level *Creating* dengan mengimplementasikan solusi untuk masalah abstrak. Computing Education in Community Colleges (2023) juga menyoroti bahwa disposisi atau aspek "sikap" (seperti *collaborative* dan *meticulous*) dapat dikaitkan dengan kompetensi teknis tersebut. Dengan demikian, sistem asesmen tidak hanya melacak kebenaran sintaksis kode, tetapi juga kedalaman pemahaman konseptual dan kemampuan kolaboratif siswa berdasarkan hierarki kognitif yang terstandarisasi.

II.2 Pemodelan Siswa (*Student Modeling*)

Dalam konteks lingkungan pembelajaran adaptif, asesmen pengetahuan diperlukan untuk membangun sebuah *student model* (model siswa). Model siswa adalah inti dari setiap sistem pendidikan adaptif, yang juga dikenal sebagai *learner model* (Brusilovsky dkk. 2016). Model ini berfungsi sebagai blok pembangunan fundamental (*fundamental building block*) dari asesmen pengetahuan (Minn 2022). Tujuan utamanya adalah untuk merepresentasikan keadaan pengetahuan domain (*domain knowledge*) siswa saat ini. Selain pengetahuan, *student model* juga dapat merepresentasikan informasi lain tentang siswa seperti tujuan pembelajaran (*learning goals*), sifat-sifat personal (*personal traits*), dan/atau preferensi. Dengan menggunakan *student model* inilah sebuah sistem adaptif dapat menyediakan berbagai in-

tervensi pembelajaran yang dipersonalisasi, seperti *mastery learning* atau *adaptive sequencing* (pengurutan adaptif) (Brusilovsky dkk. 2016).

Untuk membangun *student model* secara efektif, diperlukan sebuah *domain model* (model domain) sebagai landasan (Minn 2022). *Domain model* ini berfungsi untuk mengekstrak apa yang disebut sebagai **Knowledge Components** (KCs) atau keterampilan (*skills*) dan atribut laten (*latent attributes*) yang mendasari setiap tugas atau materi pembelajaran. *Knowledge Components* ini adalah faktor laten (*latents factors*) yang tidak pernah dapat diamati secara langsung, namun keberadaannya dianggap menentukan hasil atau kinerja siswa pada suatu tugas. Dalam kerangka kerja psikometri, pemetaan antara *item* (pertanyaan) dan KCs yang diperlukannya seringkali direpresentasikan dalam sebuah **Q-matrix** (Minn 2022). Oleh karena itu, berbagai teknik asesmen adaptif (yang akan dibahas berikutnya) pada dasarnya adalah algoritma yang digunakan untuk memperkirakan penguasaan siswa atas KCs yang tersembunyi ini.

Dalam sebagian besar sistem pembelajaran terpersonalisasi, *student model* bersifat tersembunyi atau tidak dapat diamati (*unobservable*) oleh siswa, dan hanya digunakan oleh sistem untuk menggerakkan adaptasi. Namun, sebuah pendekatan yang dikenal sebagai **Open Student Modeling** (OSM) atau Pemodelan Siswa Terbuka, berusaha membuat terobosan baru dengan secara sengaja memperlihatkan aspek-aspek model tersebut kepada pembelajar. Tujuan dari pendekatan OSM adalah untuk meningkatkan *self-reflection* (refleksi diri) siswa, *self-regulated learning* (pembelajaran mandiri), transparansi personalisasi, dan motivasi siswa (Brusilovsky dkk. 2016; Ihichr dkk. 2024).

Sebuah ekstensi yang lebih baru dan relevan dengan penelitian ini adalah **Open Social Student Modeling** (OSSM) atau Pemodelan Siswa Sosial Terbuka. Ide dari OSSM adalah untuk melengkapi aspek kognitif OSM dengan aspek sosial. Hal ini dicapai dengan mengizinkan siswa untuk mengeksplorasi model-model rekan siswa dan/atau model kelas yang diagregasi. Pendekatan ini memiliki kesamaan dengan teknik *gamification* seperti *leaderboards* (papan peringkat), yang bertujuan memanfaatkan perbandingan sosial untuk meningkatkan motivasi dan keterlibatan siswa. Penelitian telah menunjukkan bahwa antarmuka OSSM, seperti yang diimplementasikan dalam *MasteryGrids*, dapat "meningkatkan pembelajaran, terutama untuk siswa dengan pengetahuan awal yang lebih rendah" (Brusilovsky dkk. 2016).

II.3 Teknik dan Algoritma *Adaptive Assessment*

Dalam rangka mencapai adaptivitas, sistem pembelajaran perlu memperkirakan tingkat kompetensi siswa dan tingkat kesulitan konten pendidikan (Vesin dkk. 2022). Berbagai teknik dan algoritma telah dikembangkan untuk memungkinkan asesmen adaptif, masing-masing dengan dasar teoretis dan karakteristiknya sendiri. Bagian ini mengulas beberapa pendekatan utama yang digunakan dalam asesmen adaptif, dengan fokus pada *Item Response Theory* (IRT), IRT* atau *Bayesian IRT*, *Hidden Markov Models* (HMM), *Factor Analysis* (FA), *Bayesian Knowledge Tracing* (BKT), *Deep Knowledge Tracing* (DKT), dan sistem *Elo rating*.

II.3.1 *Item Response Theory* (IRT)

Item Response Theory (IRT) adalah salah satu teori yang paling banyak digunakan dalam asesmen adaptif, dengan asal-usulnya berasal dari Rasch dan Lord pada tahun 1950-an. Teori psikometri ini digunakan untuk memperkirakan pengetahuan pembelajar, mengembangkan pengukuran kognitif atau non-kognitif pembelajar, memilih pertanyaan berikutnya yang sesuai pada setiap momen, dan memutuskan kapan tes selesai (Ihichr dkk. 2024). Dalam IRT, probabilitas keberhasilan pada suatu tugas (*item*) dipetakan sebagai fungsi dari tingkat kemahiran (*ability*) yang mempertimbangkan keseluruhan tugas, dengan asumsi bahwa keadaan pengetahuan siswa statis selama ujian. Keadaan pengetahuan siswa θ dinilai berdasarkan kemahirannya saat tes dilakukan, dan setiap *item* yang diuji membantu memberikan informasi untuk menyempurnakan estimasi keadaan pengetahuan θ_i . Model IRT dasar mengasumsikan satu keterampilan tunggal dan bahwa *item* tes bersifat unidimensional (Minn 2022). Secara formal, model IRT dasar bisa diekspresikan dengan rumus matematika seperti berikut ini.

$$\begin{aligned} P_{ij} &= \sigma(\theta_i - \beta_j) \\ &= \frac{1}{1 + e^{\theta_i - \beta_j}} \end{aligned} \quad (\text{II.1})$$

Model IRT bisa dirancang dengan berbagai variasi parameter logistik. Model IRT dengan 1-Parameter Logistik (1PL) hanya melibatkan satu karakteristik *item*, yaitu kesulitan *item* (b), sedangkan model 2PL melibatkan kesulitan *item* (b) dan diskriminasi *item* (a), dan model 3PL menambahkan karakteristik ketiga, yaitu tebakan (*lower asymptote*) *item* (c) (Handayani dkk. 2025). IRT bukanlah pendekatan *Knowledge Tracing* karena mengasumsikan siswa tidak belajar selama proses pengujian;

ini dianggap sebagai pendekatan *Knowledge Assessment* (Minn 2022). Namun, IRT memiliki tantangan dalam hal kalibrasi pada sampel besar dan kesulitan komputasi untuk pembaruan yang sering karena estimasi keterampilan baru harus dihitung untuk setiap siswa setelah satu respons untuk satu tugas (Vesin dkk. 2022).

Selain pendekatan standar, model IRT juga dapat diterapkan dalam kerangka kerja Bayesian (*Bayesian framework*), pendekatan ini dalam Minn (2022) disebut sebagai IRT*. Pendekatan Bayesian untuk IRT memungkinkan peneliti untuk memasukkan informasi sebelumnya (*prior information*) tentang parameter model. *Prior* ini dapat ditentukan dengan berbagai cara, seperti menggunakan estimasi parameter dari studi sebelumnya atau menggunakan *prior* yang tidak informatif jika tidak ada informasi yang tersedia. Sebagai contoh, dalam kerangka kerja ini, tingkat kesulitan sebuah *item* dapat diperkirakan dari *item* lain yang serupa, atau kemampuan siswa dapat diperkirakan dari kinerjanya (*performance*) pada tugas-tugas lain. Pendekatan ini memanfaatkan pendekatan Bayesian dan melakukan regularisasi terhadap $\log P_{ij}$ dengan menerapkan distribusi standard *normal prior* independen ke setiap θ_i dan β_j . Dengan demikian, model ini memaksimalkan probabilitas log posterior dari θ_i, β_j jika diketahui data respons $r: (i, j, r, t) \in D$, dengan r adalah respons biner (nilainya antara 0 dan 1), t adalah waktu ketika respons diberikan, dan D adalah kumpulan *tuple* (i, j, r, t) yang menunjukkan semua respons yang diberikan oleh siswa i pada *item* j pada waktu t . Dalam penelitian oleh Minn (2022), model IRT* dapat dirumuskan sebagai berikut.

$$\begin{aligned} \log P(\{\theta_i\}, \{\beta_j\} | D) = & \sum_{(i,j,r,t) \in D} r \log \sigma(\theta_i - \beta_j) + (1 - r) \\ & \log(1 - \sigma(\theta_i - \beta_j)) - \frac{1}{2} \sum_i \theta_i^2 - \frac{1}{2} \sum_j \beta_j^2 + C \quad (\text{II.2}) \end{aligned}$$

II.3.2 Factor Analysis (FA)

Factor Analysis (FA) atau Analisis Faktor adalah teknik psikometri yang menjelaskan korelasi antar variabel yang teramati (*observed variables*). Dalam konteks asesmen adaptif, FA utamanya berfungsi untuk membangun model pembelajar, khususnya komponen kognitif, dengan mengeksplorasi faktor-faktor yang memengaruhi proses pembelajaran. Faktor-faktor ini mungkin termasuk pengetahuan sebelumnya (*prior knowledge*), kemampuan kognitif, dan motivasi. FA membantu dalam menentukan *item* yang paling baik mengukur kemahiran pembelajar dan dalam meng-

hasilkan umpan balik adaptif (Ihichr dkk. 2024).

Model berbasis FA memperkirakan kemahiran siswa pada setiap atribut (keterampilan) sebagai variabel laten kontinu. Model FA dapat dibagi menjadi dua kategori: *exploratory factor analysis* (EFA) dan *confirmatory factor analysis* (CFA). EFA digunakan untuk mengidentifikasi struktur faktor yang mendasari (*underlying factor structure*) dan mengurangi jumlah total *item* tes. CFA, di sisi lain, digunakan untuk memverifikasi apakah struktur faktor yang dihipotesiskan konsisten dengan data respons siswa. Dalam CFA, peneliti perlu menentukan terlebih dahulu jumlah faktor laten dan *item* mana yang terkait dengan faktor mana sebelum melakukan analisis (Minn 2022).


II.3.3 Hidden Markov Models (HMM) dan Bayesian Knowledge Tracing (BKT)

Hidden Markov Model (HMM) adalah model statistik yang mengasumsikan bahwa sistem yang dimodelkan adalah proses Markov dengan keadaan yang tidak teramati (*hidden states*). Dalam konteks asesmen pengetahuan, keadaan tersembunyi adalah penguasaan siswa terhadap suatu keterampilan. HMM memiliki dua asumsi utama. Asumsi pertama adalah bahwa keadaan pada waktu t hanya bergantung pada keadaan pada waktu $t - 1$. Asumsi kedua adalah bahwa observasi (misalnya, jawaban siswa) pada waktu t hanya bergantung pada keadaan pada waktu t . Dalam model ini, keadaan pengetahuan siswa dimodelkan sebagai variabel laten yang bertransisi antar keadaan (misalnya, dari "belum dipelajari" ke "dipelajari"), dan probabilitas transisi ini diperbarui berdasarkan urutan kinerja siswa yang teramati (Minn 2022).

Salah satu penerapan HMM yang paling luas dalam asesmen adaptif adalah *Bayesian Knowledge Tracing* (BKT), suatu pendekatan yang didasarkan pada *Bayesian Networks* (BNs). Pendekatan ini mencoba memodelkan keterampilan pembelajar dengan menghitung probabilitas penguasaan keterampilan berdasarkan seperangkat parameter: menebak (*guessing*), terpeleset (*slipping*), probabilitas bahwa keterampilan sudah dikuasai sebelumnya, dan probabilitas bahwa keterampilan akan dipelajari. BKT memperhitungkan urutan waktu untuk memperkirakan keterampilan baru dan mengasumsikan bahwa setiap keterampilan yang dipelajari tidak pernah dilupakan (Ihichr dkk. 2024).

BKT adalah pendekatan paling awal untuk memodelkan keadaan pengetahuan pembelajar yang berubah dan merupakan model pertama yang melonggarkan asumsi keadaan pengetahuan statis. Dalam BKT standar, satu keterampilan tunggal diuji per *item* dan keadaan penguasaan keterampilan pembelajar disimpulkan pada setiap langkah waktu berdasarkan urutan hasil sebelumnya. BKT mengandalkan model

Markov untuk menyimpulkan keadaan penguasaan, dari ”belum dipelajari” menjadi ”dipelajari”. Berbagai ekstensi BKT telah diperkenalkan, seperti memperhitungkan pengetahuan sebelumnya siswa atau kesulitan *item* (Minn 2022).



Gambar II.1 Contoh Model Konseptual dari BKT Standard yang Mengestimasi Transisi *State* siswa dari Belum Dipelajari (*Not Learned*) menjadi Sudah Dipelajari (*Learned*) (diadaptasi dari Minn (2022))

II.3.4 Deep Knowledge Tracing (DKT)

Deep Knowledge Tracing (DKT), sebuah algoritma perintis yang menggunakan jaringan neural rekuren dalam (*deep recurrent neural networks*) untuk memodelkan pembelajaran siswa dan melacak pengetahuan mereka, digunakan untuk mengekstrak struktur laten antar asesmen. DKT bergantung pada model RNN dan LSTM, yang menawarkan keuntungan signifikan dengan menangkap representasi pengetahuan yang kompleks dari asesmen dari waktu ke waktu. Kemampuan ini memungkinkan kinerja prediksi yang jauh lebih baik di seluruh dataset dari asesmen sebelumnya. Selain itu, model yang dipelajari dapat digunakan untuk merancang asesmen berikutnya yang lebih sesuai untuk siswa (Ihichr dkk. 2024).

DKT menggunakan data yang diperoleh dari pengujian keterampilan dan hasil pengujiannya digunakan untuk memprediksi upaya urutan pembelajaran di masa mendatang. DKT menggunakan sejumlah besar neuron buatan untuk mewakili keadaan pengetahuan laten bersama dengan struktur dinamis temporal yang memungkinkan model untuk mempelajari keadaan pengetahuan siswa dari data. Namun, seperti model *deep learning* lainnya, DKT seringkali berfungsi sebagai *black box* dengan

sejumlah besar parameter dan struktur yang kompleks sehingga sulit untuk memberikan penjelasan yang bermakna secara psikologis yang mencerminkan teori evolusi kognitif manusia (Minn 2022).

II.3.5 Sistem *Elo rating*

Sistem *Elo rating*, yang awalnya dikembangkan untuk memberi peringkat pemain catur, baru-baru ini digunakan dalam pendidikan untuk mengatasi beberapa celah yang ditimbulkan oleh model IRT. *Elo rating* sepenuhnya bergantung pada evaluasi kuantitatif kinerja siswa, dan dapat memodelkan keterampilan yang berubah seiring waktu. Ketika *item* baru ditambahkan dalam sistem, tidak perlu menetapkan kesulitan *item* awal yang benar, karena sistem akan belajar dan menetapkan tingkat kesulitan untuk konten pendidikan, berdasarkan kebenaran jawaban siswa. Terakhir, algoritma *Elo rating* dapat memberikan estimasi kesulitan tugas yang akurat dengan ukuran sampel kecil, sesuatu yang tidak mungkin dilakukan dengan model IRT (Vesin dkk. 2022). Adaptasi *Elo rating* ke bidang pendidikan mengasumsikan bahwa siswa adalah pemain dan *item* konten (misalnya, latihan penulisan kode program) adalah lawan.

Peringkat *Elo* siswa dan konten diwakili oleh angka, yang meningkat atau menurun tergantung pada tindakan siswa dengan sumber belajar. Perbedaan peringkat antara siswa dan *item* berfungsi sebagai prediktor hasil tindakan. Algoritma *Elo rating* merupakan algoritma yang hemat sumber daya komputasi, sangat sederhana untuk diimplementasikan, dan cocok untuk praktik adaptif dalam pendidikan (Vesin dkk. 2022). Implementasi yang diusulkan oleh Vesin dkk. (2022) memperluas *Elo rating* klasik dengan mempertimbangkan parameter tambahan seperti jumlah upaya dan waktu yang digunakan, bukan hanya status terselesaikan atau tidak, untuk memberikan adaptivitas dan rekomendasi dalam tugas pemrograman *open-ended*.

Secara spesifik, metode yang diusulkan menerapkan dua strategi, (1) memperbarui peringkat berdasarkan performa siswa pada materi pembelajaran dibandingkan nilai ekspektasinya dan (2) tingkat kesulitan konten pembelajaran diperbarui berdasarkan tingkat pemahaman siswa yang berhasil, ataupun gagal dalam latihan. Secara matematis, cara ini mengestimasi probabilitas seorang siswa i mampu menyelesaikan latihan j berdasarkan peringkat siswa saat ini dan tingkat kesulitan latihan j . Peringkat siswa dan kesulitan latihan kemudian diperbarui menurut rumus berikut.

$$R_i = R_{i-1} + K(W - W_e) \quad (\text{II.3})$$

$$D_j = D_{j-1} + K(W_e - W) \quad (\text{II.4})$$

dengan R_i adalah peringkat siswa setelah menyelesaikan latihan ke- i , R_{i-1} adalah peringkat siswa sebelum menyelesaikan latihan ke- i , D_j adalah tingkat kesulitan latihan ke- j setelah siswa menyelesaikannya, D_{j-1} adalah tingkat kesulitan latihan ke- j sebelum siswa menyelesaikannya, K adalah faktor penyesuaian yang menentukan seberapa besar perubahan peringkat atau tingkat kesulitan, nilai ini dikurangi secara bertahap seiring siswa menyelesaikan lebih banyak latihan, W merepresentasikan hasil dari penyelesaian latihan yang direkomendasikan (dengan kata lain adalah tingkat keberhasilan), yang dihitung berdasarkan formula berikut.

$$W = \left(\frac{(A_s + A_o)T_c}{2A_oT_p} \right) (a_i d_i - a_i t_i). \quad (\text{II.5})$$

Rumus II.5 di atas adalah kunci modifikasi algoritma *Elo rating* dari riset oleh Vesin dkk. (2022), variabel-variabelnya dijelaskan dalam laporan hasil risetnya dengan definisi di bawah ini:

- A_s : banyaknya upaya yang berhasil untuk latihan tertentu
- A_o : banyaknya total upaya untuk latihan tertentu
- T_c : banyaknya latihan yang sudah diselesaikan
- T_p : banyaknya latihan yang diselesaikan dengan benar
- a_i : bobot yang menentukan seberapa penting kecepatan (waktu) memengaruhi skor akhir
- d_i : merepresentasikan batas waktu
- t_i : merepresentasikan waktu yang dibutuhkan untuk menyelesaikan latihan


Terakhir adalah komponen W_e , komponen ini merepresentasikan probabilitas seorang siswa mampu menyelesaikan latihan tertentu, yang dihitung berdasarkan rumus elo standard (Elo 1978):

$$W_e = \frac{1}{1 + 10^{\frac{R_{i-1} - D_{j-1}}{400}}}. \quad (\text{II.6})$$

II.3.6 Posisi Teknik dan Algoritma dalam Sistem Asesmen Adaptif Individual

Berbagai teknik yang telah dibahas di atas (IRT, Elo rating, dll.) umumnya diimplementasikan dalam sebuah siklus sistem. Model konseptual siklus sistem yang dominan untuk asesmen adaptif saat ini adalah siklus yang berpusat pada pembela-

jar tunggal. Sebuah contoh representatif dari alur kerja ini diimplementasikan dalam sistem ProTuS oleh Vesin dkk. (2022), seperti yang ditunjukkan pada Gambar II.2.



Gambar II.2 Model Konseptual Alur Proses Sistem Adaptif Individual (diadaptasi dari Vesin dkk. (2022))

Menurut Vesin dkk. (2022) alur proses dalam model ini terdiri dari tiga tahap yang diulang secara terus-menerus:

1. **Sesi Pembelajaran (*Learning Sessions*):** Siswa berinteraksi dengan sumber daya pembelajaran yang disediakan, seperti membaca materi atau menyelesaikan latihan pengkodean.
2. **Asesmen Adaptif (*Adaptive Assessment*):** Saat siswa menyelesaikan aktivitas, sistem memperbarui peringkat mereka berdasarkan kinerja individu. Peringkat siswa (*student ratings*) dan tingkat kesulitan konten (*difficulty level of content*) dihitung menggunakan metode seperti *Elo rating* yang dimodifikasi.

3. **Rekomendasi (*Recommendation*):** Sistem kemudian merekomendasikan aktivitas pembelajaran lebih lanjut yang sesuai dengan kemahiran siswa saat ini. Tahap modifikasi kesulitan konten pembelajaran mungkin tidak ada di semua sistem karena beberapa teknik seperti IRT mengharuskan kesulitan konten ditetapkan sebelumnya. Namun, secara umum akan melalui siklus seperti di atas, dan teknik serta algoritma yang dibahas sebelumnya berperan secara khusus dalam tahap asesmen adaptif.

II.3.7 Karakteristik Ukuran Bank Soal dalam Implementasi Asesmen Adaptif Skala Kelas

Penelitian oleh Hadi, Asriadi, dan Rahim (2022) dilatarbelakangi oleh permasalahan metode pengujian tradisional di sekolah vokasi yang sering kali gagal dalam membedakan kemampuan awal siswa secara akurat. Untuk mengatasi masalah tersebut, studi tersebut bertujuan untuk mengembangkan dan menguji kelayakan alat asesmen kelas menggunakan *Computerized Adaptive Test (CAT)* berbasis *Learning Management System (LMS)*. Penelitian ini difokuskan secara spesifik pada program studi Teknik Instalasi Tenaga Listrik untuk memberikan penilaian yang lebih representatif bagi siswa. Metodologi yang digunakan dalam penelitian ini adalah pendekatan *Research and Development (R&D)* yang mencakup konstruksi skala dan pengumpulan bank soal. Proses pengembangan tersebut melibatkan pengumpulan data dari responden ahli serta siswa untuk memastikan validitas instrumen yang dibangun.

Instrumen yang berhasil dikembangkan dalam penelitian Hadi, Asriadi, dan Rahim (2022) tersebut terdiri dari 60 butir soal pilihan ganda yang diintegrasikan ke dalam modul kuis adaptif pada LMS Moodle. Analisis butir soal dilakukan menggunakan Model Rasch dan Teori Tes Klasik (*Classical Test Theory*) untuk mengevaluasi sifat psikometrik dari bank soal tersebut. Hasil pengujian menunjukkan bahwa instrumen ini memiliki tingkat validitas dan reliabilitas yang sangat tinggi dengan nilai koefisien Alpha mencapai 0,934. Studi tersebut menyimpulkan bahwa pengujian adaptif berbasis LMS ini mampu memberikan pengukuran yang lebih presisi dengan jumlah pertanyaan yang lebih sedikit dibandingkan tes konvensional. Dengan demikian, penelitian ini membuktikan bahwa integrasi CAT ke dalam LMS sekolah sangat layak diterapkan untuk mendukung pengambilan keputusan instruksional dan pembelajaran terpersonalisasi.

II.4 Pembelajaran Kolaboratif dan CSCL

Tantangan untuk beralih dari model pedagogi yang berpusat pada instruktur menjadi berpusat pada siswa (Ryoo dan Winkelmann 2021) sejalan dengan penekanan Strate-

gi Nasional KA Indonesia pada pentingnya ekosistem kolaboratif (Kelompok Kerja Penyusun Strategi Nasional untuk Kecerdasan Artifisial 2020). Dalam konteks pendidikan, filosofi kolaboratif ini sering dimediasi oleh teknologi melalui *Computer-Supported Collaborative Learning* (CSCL). Bagian ini membahas prinsip-prinsip dan tantangan dari pendekatan sosial ini, yang menjadi landasan untuk komponen ”sosial” dari sistem yang diusulkan.

II.4.1 Prinsip Pembelajaran Kolaboratif berbasis Teknologi

Alih-alih mendefinisikannya secara kaku, pendekatan modern melihat pembelajaran kolaboratif sebagai proses yang memanfaatkan teknologi untuk mendukung interaksi sosial. Prinsip-prinsip utamanya meliputi:

1. **Konstruksi Pengetahuan Sosial:** Sistem pembelajaran dapat didasarkan pada pendekatan konstruktivis sosial. Dalam model ini, pembelajaran muncul melalui interaksi baik dengan rekan yang berpengetahuan (*knowledgeable peers*) atau dengan sistem AI. Tujuannya adalah untuk mendorong formasi kelompok yang heterogen untuk memaksimalkan keragaman kognitif dan mendorong refleksi kritis (Halkiopoulou dan Gkintoni 2024).
2. **Interaksi dalam Komunitas Praktik (*Communities of Practice*):** Teknologi dapat memfasilitasi pembentukan *Communities of Practice* (CoP). Sistem *Computer-Supported Collaborative Work* (CSCW) atau proyek berbasis tim (*team-based projects*) memungkinkan pembelajar untuk berinteraksi dalam ruang tiga dimensi yang sama meskipun secara fisik berada di lokasi yang jauh (Ryoo dan Winkelmann 2021).

Meskipun prinsip pembentukan kelompok heterogen telah diakui kepentingannya, tantangan teknis dalam sistem adaptif adalah menentukan standar kuantitatif yang baku untuk menilai apakah perbedaan kemampuan antar-siswa sudah cukup signifikan untuk disebut heterogen.

II.4.2 Pengukuran Heterogenitas Kelompok dan *Effect Size*

Dalam ranah ilmu perilaku dan pendidikan, pengukuran perbedaan antara dua kelompok atau individu tidak cukup hanya dengan melihat selisih nilai mentah (*raw score differences*), karena nilai tersebut sangat bergantung pada satuan skala yang digunakan. Untuk mengatasi hal ini, Cohen (1988) memperkenalkan konsep *Effect Size* (ES) sebagai indeks standar yang independen dari satuan pengukuran asal. Salah satu indeks ES yang paling fundamental dan banyak digunakan untuk membandingkan dua rata-rata adalah *Cohen's d*. Secara konseptual, *Cohen's d* didefinisikan sebagai selisih antara dua rata-rata populasi ($m_A - m_B$) yang dibagi dengan standar deviasi populasi (σ). Rasio ini merepresentasikan jarak antara dua rata-rata dalam

satuan unit variabilitas standar, memberikan ukuran murni mengenai seberapa jauh dua distribusi nilai terpisah satu sama lain.

Dalam praktiknya, ketika parameter populasi tidak diketahui, nilai d diestimasi menggunakan statistik sampel. Cohen (1988) merumuskan penghitungan d untuk dua sampel independen dengan menggunakan *pooled standard deviation* (σ_{pooled}) sebagai penyebut, yang merupakan rata-rata akar kuadrat dari varians kedua kelompok. Rumus formal untuk menghitung jarak atau indeks perbedaan ini dinyatakan sebagai:

$$d = \frac{|\bar{x}_A - \bar{x}_B|}{\sigma_{pooled}} \quad (\text{II.7})$$

$$\sigma_{pooled} = \sqrt{\frac{(n_A - 1)s_A^2 + (n_B - 1)s_B^2}{n_A + n_B - 2}} \quad (\text{II.8})$$

dengan $\bar{x}_A$ dan $\bar{x}_B$ adalah nilai rata-rata (atau skor kemampuan individu) dari dua entitas yang dibandingkan, s_A^2 dan s_B^2 adalah varians masing-masing, serta n_A dan n_B adalah ukuran sampel. Jika diaplikasikan pada perbandingan antar-individu (dengan $n = 1$), penyebut dapat disederhanakan menjadi standar deviasi gabungan dari populasi referensi atau data historis sistem. Nilai d yang dihasilkan adalah nilai skalar tak berdimensi yang memungkinkan perbandingan yang adil lintas konteks yang berbeda.

Untuk memberikan makna interpretatif pada nilai numerik d , Cohen (1988) menetapkan standar konvensi yang telah menjadi rujukan universal dalam analisis kuantitatif. Konvensi ini dirancang untuk memetakan besaran statistik ke dalam dampak kualitatif yang dapat diamati di dunia nyata.

1. **Efek Kecil** ($d = 0.2$): Perbedaan yang nyata namun sulit dideteksi tanpa analisis statistik yang cermat.
2. **Efek Sedang** ($d = 0.5$): Perbedaan yang cukup besar untuk dapat dilihat oleh mata telanjang pengamat yang berpengalaman (*visible to the naked eye*).
3. **Efek Besar** ($d = 0.8$): Perbedaan yang sangat mencolok, setara dengan perbedaan tinggi badan antara remaja usia 13 dan 18 tahun.

Standar operasional ini memberikan landasan teoretis yang kokoh untuk menetapkan ambang batas (*threshold*) dalam menentukan apakah dua entitas (atau kelompok) dapat dikategorikan "berbeda secara signifikan" atau heterogen dalam konteks intervensi pendidikan.

II.4.3 Aktivitas Pembelajaran Sosial dan Dampaknya

Selain prinsip-prinsip umum yang telah dibahas pada Subbab II.4.1, penting untuk mengidentifikasi bentuk-bentuk aktivitas pembelajaran sosial spesifik yang telah terbukti secara empiris memiliki dampak positif terhadap hasil belajar. Aktivitas-aktivitas inilah yang menjadi kandidat utama untuk diintegrasikan dan dinilai dalam sebuah sistem adaptif.

1. **Penilaian sejawat (*Peer Assessment*):** Penilaian sejawat adalah aktivitas pendidikan yang mengajak siswa saling menilai pekerjaan rekannya, artinya dalam penilaian ini ”penilai (*assessor*) dan yang dinilai (*assessed*) memiliki status yang sama” (Ihichr dkk. 2024).

Evaluasi terhadap kinerja asesor dalam *peer assessment* tidak cukup hanya didasarkan pada akurasi skor (*rating accuracy*), tetapi juga harus meninjau kualitas umpan balik tekstual yang diberikan secara terukur. Kerman dkk. (2024) mengembangkan skema pengkodean yang membagi fitur umpan balik ke dalam tiga elemen utama: (1) *Affective* (afektif), yang mencakup emosi positif seperti pujian atau emosi negatif; (2) *Cognitive* (kognitif), yang terdiri dari deskripsi ringkasan (*description*), identifikasi masalah (*identification*), dan justifikasi masalah (*justification*), serta (3) *Constructive* (konstruktif) yang mencakup rekomendasi solusi.

Keunggulan dari pendekatan ini adalah kemampuannya untuk mengkuantifikasi kualitas umpan balik secara granular. Dalam rubrik yang diusulkan Kerman dkk. (2024), setiap fitur dinilai dengan skor dari nol (kualitas buruk) hingga dua (kualitas baik). Sebagai contoh, pada dimensi *Constructive*, skor 0 diberikan jika tidak ada rekomendasi, skor 1 jika hanya ada rekomendasi tanpa rencana aksi, dan skor 2 jika terdapat rekomendasi beserta rencana aksi (*action plans*) untuk perbaikan lebih lanjut. Penjumlahan poin-poin ini merepresentasikan skor keseluruhan kualitas umpan balik yang dihasilkan oleh siswa.

Pentingnya menekankan aspek kognitif dan konstruktif didukung oleh temuan empiris bahwa fitur-fitur inilah yang menjadi prediktor kesuksesan revisi tugas. Kerman dkk. (2024) menemukan bahwa siswa yang sukses (*successful students*) cenderung menerima umpan balik yang berfokus pada *identification* (identifikasi masalah), sedangkan umpan balik yang murni *affective* atau sekadar deskriptif lebih banyak diterima oleh siswa yang kurang berhasil. Hal ini menunjukkan bahwa untuk meningkatkan kompetensi, sistem harus mendorong siswa untuk memberikan komentar yang tidak hanya menyentuh aspek emosional, tetapi memberikan identifikasi masalah dan solusi konkret.

2. **Pembelajaran Berbasis Proyek (*Project-Based Learning*):** Pembelajaran berbasis proyek (PBL) adalah model pembelajaran inkuiri yang berpusat pada siswa, dengan tujuan "menghasilkan sebuah karya proyek yang lengkap" untuk memecahkan masalah dunia nyata (Zhang dan Ma 2023). Berbeda dengan pembelajaran tradisional, PBL menempatkan siswa dalam peran aktif untuk berkolaborasi, mengintegrasikan berbagai disiplin ilmu, dan menerapkan pengetahuan (Ryoo dan Winkelmann 2021). Sebuah meta-analisis oleh Zhang dan Ma (2023) terhadap 66 studi eksperimental menemukan bahwa PBL secara signifikan "meningkatkan hasil belajar siswa" dibandingkan dengan model pengajaran tradisional. Dampak positif ini terukur pada tiga dimensi luaran pembelajaran, yaitu "pencapaian akademik (*academic achievement*), sikap afektif (*affective attitudes*), dan keterampilan berpikir (*thinking skills*)" (Zhang dan Ma 2023).
3. **Pendampingan Sejawat (*Peer Mentoring*):** *Peer mentoring* adalah mekanisme "bimbingan individual yang diberikan oleh siswa senior untuk membantu siswa lain" (Le, Sok, dan Heng 2024). Aktivitas ini dirancang untuk membantu siswa baru (*mentee*) dalam menavigasi tantangan transisi ke pendidikan tinggi, baik secara akademik maupun sosial. Sebuah tinjauan sistematis baru-baru ini yang mencakup 27 studi empiris mengidentifikasi empat kategori manfaat fundamental dari *peer mentoring* bagi *mentee*. Manfaat tersebut adalah: (1) peningkatan "kinerja akademik" (*academic performance*), (2) peningkatan "tingkat retensi" (*retention rates*) atau persistensi, (3) peningkatan "kesejahteraan emosional dan psikologis" (*emotional and psychological wellbeing*), dan (4) "integrasi sosial" (*social integration*) yang lebih baik di lingkungan kampus (Le, Sok, dan Heng 2024).
4. **Sesi Diskusi Terbuka:** Interaksi sosial langsung melalui diskusi juga terbukti berdampak pada hasil belajar. Sebuah studi oleh Daif-Allah dan Khan (2016) menginvestigasi dampak dari "Sesi Diskusi Terbuka" (*Open Discussion Sessions*) yang diadakan sebagai kegiatan ekstrakurikuler untuk meningkatkan kemampuan komunikasi lisan siswa. Hasil studi menunjukkan adanya "perkembangan signifikan dalam kemampuan berbicara siswa". Keberhasilan ini diatribusikan pada faktor-faktor kunci dari desain aktivitas tersebut, yaitu penyediaan "lingkungan belajar yang santai tanpa rasa khawatir" (*relaxed learning environment void of worry*) dan "keterlibatan aktif dengan situasi komunikatif nyata" (*active involvement with real communicative situations*) (Daif-Allah dan Khan 2016).
5. **Bermain Peran (*Role-Playing*):** metode bermain peran adalah "metode pe-

ngajaran simulasi situasional”. Pada metode ini, siswa diminta untuk mengambil peran spesifik untuk mensimulasikan skenario dunia nyata. Pendekatan ini memindahkan fokus dari transmisi pengetahuan teoretis ke penerapan praktis dan pengembangan keterampilan. Sebuah meta-analisis yang mensintesis 22 ukuran efek dari 12 artikel menemukan bahwa pengajaran menggunakan metode bermain peran memiliki ”efek positif yang signifikan” ($ES=0.818$) pada siswa dibandingkan dengan kelompok kontrol yang menggunakan pengajaran tradisional. Secara khusus, ditemukan bahwa metode bermain peran memiliki dampak paling signifikan pada peningkatan ”Keterampilan” (*Skills*) siswa (Fu dan Li 2025).

II.4.4 Tantangan dalam Menilai Kolaborasi

Meskipun manfaat pedagogisnya jelas, menilai pembelajaran kolaboratif secara adil menghadirkan tantangan yang signifikan. Masalah utamanya adalah bagaimana mengukur kontribusi individu secara akurat di dalam upaya kelompok.

Salah satu tantangan utama adalah bahwa metode untuk menilai kinerja dalam kelompok yang tujuannya adalah pemecahan masalah secara kreatif, perlu bisa mengukur bagaimana setiap orang secara personal berkontribusi pada kelompok mereka, dan bagaimana efek dari kontribusi individual tersebut terhadap kuantitas maupun kualitas hasil akhir dari penyelesaian masalah (Ryoo dan Winkelmann 2021).

Untuk mengatasi ini, *peer assessment* (penilaian sejawat) sering digunakan. Ini dijelaskan sebagai aktivitas pendidikan yang menghadirkan penilai (*assessor*) dan yang dinilai (*assessed*) dalam status yang sama, dan masing-masing menilai hasil belajar, kualitas, dan level satu sama lain (Ihichr dkk. 2024). Studi oleh Ihichr dkk. (2024) mencatat bahwa siswa mendapat lebih banyak manfaat dari bertindak sebagai penilai daripada hanya dinilai.

Tantangan kedua, yang secara khusus relevan dengan penelitian ini, adalah risiko ”personalisasi berlebih” (*overpersonalization*) dalam sistem adaptif berbasis AI. Sistem yang terlalu fokus pada optimasi jalur belajar individu dapat menyebabkan pembelajar yang mendapat manfaat dari pembelajaran bersama (*shared learning*) akan terasingkan dalam sistem. Personalisasi berlebih ini kemungkinan akan menjadi penghalang ketika siswa seharusnya dapat memperoleh manfaat dari aspek komunal pembelajaran. Oleh karena itu, sistem asesmen adaptif modern harus mampu menyeimbangkan antara personalisasi individu dengan fasilitasi interaksi sosial yang bermakna (Halkiopoulou dan Gkintoni 2024).

II.4.5 Metode Pembobotan Penilaian Terintegrasi

Dalam mengintegrasikan skor kemahiran personal dan performa sosial, penentuan bobot yang adil menjadi tantangan tersendiri. Penelitian oleh Demetroulis dkk. (2024) mengusulkan skema pembobotan di mana kontribusi individu diberikan porsi sebesar 80%, sementara performa kelompok secara keseluruhan diberikan porsi 20%. Rasio 80:20 ini bertujuan untuk menghargai input kognitif dan strategis individu dalam tim yang mungkin tidak selalu terlihat dalam hasil akhir, namun tetap memberikan insentif terhadap keberhasilan kerja sama kelompok. Fokus utama dari pembobotan ini adalah pada proses kolaboratif individu alih-alih hanya mengandalkan hasil akhir kolektif (*collaborative outcome*).


II.5 Upaya Integrasi Penilaian Personal dalam Lingkungan Kolaboratif yang Sudah Ada Saat Ini

Tinjauan literatur menunjukkan bahwa sebagian besar penelitian dan implementasi sistem pembelajaran adaptif hingga saat ini berfokus secara dominan pada pembelajar individu. Sistem *e-learning* yang ada seringkali dirancang untuk mengadaptasi konten dan urutan penyampaiannya sesuai dengan kemampuan pembelajar secara individual (Halkiopoulou dan Gkintoni 2024). Fokus pada personalisasi ini terlihat jelas dalam model-model asesmen dominan seperti *Item Response Theory* (IRT), *Bayesian Knowledge Tracing* (BKT), dan *Deep Knowledge Tracing* (DKT), yang pada intinya memodelkan keadaan pengetahuan laten seorang siswa tunggal (Minn 2022).

Meskipun personalisasi ini menawarkan manfaat yang substansial, Halkiopoulou dan Gkintoni (2024) memperingatkan adanya risiko "personalisasi berlebih" (*over-personalization*). Pendekatan yang terlalu terindividualisasi ini dapat menciptakan situasi yang menyebabkan pembelajar yang seharusnya bisa mendapat manfaat dari pembelajaran bersama (*shared learning*) malah terasingkan sehingga menghambat perolehan manfaat dari aspek komunal pembelajaran.

Beberapa penelitian memang telah mengeksplorasi penggunaan AI dalam konteks kolaboratif, tetapi seringkali secara terpisah dari *loop* asesmen adaptif inti. Sebagai contoh, Nalli, Amendola, dan Smith (2022) menggunakan algoritma *Artificial Intelligence* (secara spesifik, teknik *clustering*) untuk membantu pengajar dalam pembentukan kelompok heterogen. Dalam studi ini, AI digunakan sebagai alat bantu persiapan (*setup tool*) yang efektif untuk formasi kelompok, bukan sebagai mesin yang secara dinamis menilai kolaborasi atau mengadaptasi konten secara *real-time* berdasarkan interaksi kelompok.

Upaya yang lebih dekat dengan integrasi ini adalah *Open Social Student Modeling* (OSSM) yang diperkenalkan oleh Brusilovsky dkk. (2016).



Gambar II.3 Model Konseptual Antarmuka Pembelajaran Sosial (OSSM)
(diadaptasi dari Brusilovsky dkk. (2016))

Dalam implementasinya pada sistem MasteryGrids, OSSM melengkapi aspek kognitif dengan aspek sosial melalui antarmuka yang menampilkan visualisasi perbandingan kinerja "Me vs group" (Saya vs grup) dan baris "Group" (Grup). Meskipun studi mereka menemukan bahwa fitur eksplorasi sosial ini dapat meningkatkan pembelajaran, terutama bagi siswa dengan pengetahuan awal rendah, pendekatan ini pada utamanya bersifat visualisasi sosial. Brusilovsky dkk. (2016) menempatkan aspek sosial sebagai *output* untuk memotivasi siswa, namun tidak merinci bagaimana data perbandingan sosial ini diintegrasikan kembali sebagai *input* ke dalam algoritma asesmen inti (seperti *Elo rating* atau BKT) untuk mengubah perhitungan kemahiran individu secara dinamis atau merekomendasikan intervensi kolaboratif.

II.6 Overpersonalization dalam Konteks Pendidikan

Implementasi algoritma personalisasi dalam sistem pembelajaran adaptif bertujuan untuk mengoptimalkan efisiensi akuisisi pengetahuan dengan menyesuaikan materi terhadap profil unik setiap siswa. Namun, optimasi yang terlalu agresif terhadap parameter individu tanpa mempertimbangkan aspek eksplorasi dan keberagaman informasi dapat memicu fenomena *overpersonalization* (Halkiopoulou dan Gkintoni 2024). Risiko ini muncul ketika sistem menciptakan lingkungan yang terlalu tertutup, sehingga membatasi paparan siswa terhadap konsep-konsep baru yang krusial bagi pengembangan kognitif yang holistik. Subbab berikut akan mengulas manifestasi dari kondisi tersebut serta metrik yang digunakan untuk mengukurnya.

II.6.1 Manifestasi *Overpersonalization* dalam Pembelajaran

Manifestasi dari *overpersonalization* dalam lingkungan pendidikan dapat diamati melalui perubahan perilaku kognitif pembelajar saat berinteraksi dengan sistem yang terlalu terpersonalisasi. Menurut penelitian Bahg, Sloutsky, dan Turner (2025), pelajar dalam ekosistem kognitif yang membatasi keberagaman informasi cenderung melakukan sampling informasi secara lebih selektif. Hal ini menyebabkan pembentukan representasi kategori (materi pembelajaran) yang tidak tepat karena pembelajar hanya terpapar pada subset data yang sempit dan homogen. Secara fundamental, fenomena ini mengindikasikan bahwa dampak negatif *overpersonalization* tidak hanya terbatas pada isolasi informasi, tetapi juga menyebabkan distorsi pemahaman, bias dalam pengambilan sampel informasi, serta generalisasi pengetahuan yang tidak tepat (Bahg, Sloutsky, dan Turner 2025). Dampak ini diperparah oleh pembentukan *filter bubble* yang, sebagaimana ditunjukkan oleh Jiang, Sun, dan Fu (2025), menyebabkan penurunan diversifikasi konsumsi informasi secara signifikan, yang pada akhirnya membatasi cakrawala intelektual siswa.

II.6.2 Pengukuran *Overpersonalization* dalam Pembelajaran

Pengukuran terhadap tingkat *overpersonalization* memerlukan metrik yang mampu menangkap aspek keberagaman dalam rekomendasi konten edukasi. Dalam domain sistem rekomendasi secara umum, Ren dkk. (2025) menyatakan bahwa pengukuran tingkat diversitas dapat dilakukan menggunakan metrik variansi atau entropi, seperti *Shannon Entropy*, untuk mengkuantifikasi seberapa luas sebaran entitas dan relasi yang dikonsumsi oleh pengguna dibandingkan dengan total ruang pengetahuan yang tersedia. Dalam konteks spesifik pembelajaran, indikasi *overpersonalization* juga dapat dideteksi melalui kemunculan fenomena *learning plateau* (Halkiopoulou dan Gkintoni 2024). Fenomena ini ditandai dengan stagnasi kemajuan belajar siswa yang disebabkan oleh kurangnya variasi terhadap tantangan atau tingkat kesulitan yang dihadapi. Ketika sistem terus-menerus menyajikan materi yang terlalu selaras dengan zona nyaman siswa tanpa memberikan paparan terhadap konsep-konsep baru yang beragam, siswa kehilangan stimulasi kognitif yang diperlukan untuk keluar dari stagnasi tersebut.


II.7 Upaya Penyelesaian Masalah *Overpersonalization* yang Ada Saat Ini

Setelah memahami manifestasi kognitif dan metrik pengukuran dari *overpersonalization* sebagaimana dibahas pada bagian sebelumnya, diperlukan tinjauan terhadap solusi teknis yang telah dikembangkan untuk memitigasi dampak tersebut. Masalah *overpersonalization* telah menjadi perhatian utama dalam penelitian sistem rekomendasi modern karena dampaknya dalam menciptakan *filter bubbles* dan *echo*

chambers yang menghambat pertumbuhan pengetahuan. Untuk mengatasi isolasi pengguna ini tanpa mengorbankan relevansi secara signifikan, peneliti telah mengeksplorasi berbagai pendekatan yang berusaha menyeimbangkan antara akurasi personalisasi dengan kebutuhan akan keberagaman informasi. Tiga pendekatan yang paling menonjol dan relevan melibatkan penggunaan rekomendasi berbasis kelompok (*Group Recommender Systems*), pemberian kendali kepada pengguna (*User Controllable Systems*), dan pemodelan komunitas secara implisit (*Implicit Community Modeling*).

II.7.1 Sistem Rekomendasi yang Dapat Dikontrol Pengguna (*User Controllable Recommender Systems*)

Pendekatan pertama adalah pendekatan yang dikenal sebagai *User Controllable Recommender System* (UCRS), pendekatan ini menerapkan sistem yang memungkinkan pengguna memiliki hak untuk memutuskan apakah ingin menghindari *filter bubble* sehingga bisa melakukan pemilihan "bubble" mana yang akan menghindari. Secara fungsional, Wang dkk. (2022) menjelaskan bahwa UCRS dapat mengingatkan pengguna jika mereka terjebak dalam *filter bubble*, mendukung empat jenis perintah kontrol bagi pengguna untuk memitigasi *bubble* pada tingkat granularitas (tingkat kedetailan) yang berbeda (*fine-grained* dan *coarse-grained*), serta merespons kontrol tersebut dan menyesuaikan rekomendasi secara langsung (*on the fly*). Sistem ini menyediakan perintah kontrol terkait fitur pengguna atau fitur item, seperti perintah *fine-grained* untuk meningkatkan item yang disukai oleh kelompok pengguna lain atau item dalam kategori target tertentu (Wang dkk. 2022).



Gambar II.4 Model Konseptual Sistem Rekomendasi yang Dapat Dikontrol Pengguna (UCRS) (diadaptasi dari Wang dkk. (2022))

Tantangan teknis utama dalam merespons kontrol pengguna adalah memblokir efek dari representasi pengguna yang sudah kedaluwarsa (*out-of-date*), yang mengandung informasi historis yang tidak konsisten dengan perintah kontrol. Untuk mengatasi hal ini, dikembangkan kerangka kerja ***User Controllable Inference*** (UCI) yang ditingkatkan dengan kausalitas, yang memeriksa prosedur pembuatan rekomendasi dari pandangan kausal dan memanfaatkan inferensi kontrafaktual (*counterfactual inference*) untuk memitigasi efek dari representasi pengguna yang kedaluwarsa tersebut (Wang dkk. 2022). Secara khusus, UCI membayangkan dunia kontrafaktual yang di dalamnya representasi pengguna yang kedaluwarsa dibuang, dan mengestimasi efeknya sebagai perbedaan antara dunia faktual dan kontrafaktual, lalu mengurangi efek tersebut dalam prediksi akhir.


II.7.2 Pendekatan Berbasis Kelompok (*Group Recommender Systems*)

Pendekatan kedua menggunakan ***Group Recommender Systems*** (GRS) untuk memitigasi masalah *filter bubble* dan *echo chamber* dengan fokus pada kelompok pengguna yang besar. Dokoupil (2022) mengusulkan aplikasi baru GRS yang melibatkan konstruksi kelompok pengguna skala besar dan berfokus pada keadilan jangka panjang (*long-term fairness*) dari kelompok-kelompok ini, yang berbeda dengan penelitian yang sudah ada sebelumnya yang berkonsentrasi pada kelompok kecil yang bersifat sementara. GRS perlu mengatasi heterogenitas preferensi anggota kelompok dan menghasilkan rekomendasi dengan utilitas keseluruhan yang tinggi sambil tetap mempertimbangkan rasa keadilan di antara anggota kelompok (Dokoupil 2022).

Secara spesifik untuk skenario pengguna tunggal, pendekatan ini mengusulkan pembangunan "*virtual groups*" atau kelompok virtual yang kemudian diteruskan ke GRS untuk mendapatkan rekomendasi akhir bagi pengguna tersebut. Hipotesis awalnya adalah bahwa anggota kelompok virtual seharusnya fokus pada topik yang serupa, tetapi dapat memiliki sikap yang beragam terhadap topik tersebut (Dokoupil 2022). Dengan menerapkan GRS pada kelompok yang seimbang (mungkin besar) alih-alih rekomendasi individu, pendekatan ini bertujuan untuk meningkatkan pluralitas opini atau mengurangi polarisasi, sehingga membantu memecahkan masalah *filter bubble*. Meskipun demikian, perlu dicatat bahwa pekerjaan ini masih merupakan rencana penelitian untuk aplikasi baru GRS sehingga penulis masih baru merencanakan investigasi terhadap efek ukuran kelompok pada kinerja GRS serta evaluasi menggunakan grup yang dihasilkan secara sintetis maupun data publik (Dokoupil 2022).

II.7.3 Pemodelan Komunitas Implisit untuk Memecahkan *Echo Chamber*

Pendekatan ketiga adalah **FRediECH** (*A Friend Recommender for breaking Echo Chambers*), sebuah pendekatan rekomendasi teman yang sadar akan *echo chamber* dan bertujuan merekomendasikan teman yang relevan dan beragam dari luar jangkauan pengaruh *echo chamber* pengguna. Pendekatan ini didasarkan pada pembelajaran representasi pengguna dan *echo chamber* secara dinamis berdasarkan konten yang dibagikan dan interaksi komunitas pengguna, alih-alih bergantung pada penemuan komunitas secara eksplisit yang mungkin kompleks secara komputasi (Tommasel, Rodriguez, dan Godoy 2021). Masalah rekomendasi diformulasikan untuk mempelajari fungsi yang mengestimasi kekuatan interaksi potensial antar pengguna berdasarkan interaksi masa lalu dan konten yang dibagikan, pada formulasi ini kekuatan interaksi potensial yang lebih tinggi menunjukkan keseimbangan yang lebih baik antara relevansi pengguna dan jaraknya dari *echo chamber* pengguna lain.



Gambar II.5 Diagram Arsitektur FRediECH (diadaptasi dari Tommasel, Rodriguez, dan Godoy (2021))

Pada gambar II.5 terlihat arsitektur FRediECH yang terinspirasi oleh **Graph Convolutional Network** (GCN) dan arsitektur **Deep & Wide**, yang menggabungkan kesadaran *echo chamber* dan representasi pengguna untuk menyeimbangkan relevansi, keragaman, dan kebaruan rekomendasi. Tommasel, Rodriguez, dan Godoy (2021) menggunakan GCN paralel untuk mempelajari kontribusi spesifik dari jenis interaksi tertentu (seperti *reply*, *mention*, atau *retweet*) terhadap set lengkap hubungan pengguna, kemudian menggabungkan outputnya untuk menghasilkan representasi pengguna perantara. Fungsi kerugian (*loss function*) didefinisikan berdasarkan jarak antara pengguna dan jumlah interaksi, yang bertujuan untuk memberikan bobot pada interaksi sedemikian rupa sehingga interaksi antara pengguna yang berasal da-

ri *echo chamber* yang berbeda membawa bobot yang lebih tinggi daripada interaksi dalam *echo chamber* yang sama sehingga mempromosikan keragaman rekomendasi dengan mempelajari struktur komunitas secara implisit (Tommasel, Rodriguez, dan Godoy 2021).

II.7.4 Mitigasi Dampak *Echo Chamber* Melalui *Constraint-Based Re-ranking*

Salah satu pendekatan algoritmik terbaru yang secara spesifik menangani dampak rekomendasi terhadap perilaku pengguna adalah kerangka kerja yang diusulkan oleh Biasio dkk. (2023). Penelitian ini membedakan dirinya dari pendekatan diversifikasi umum dengan memfokuskan pada perlindungan kelompok pengguna "sensitif" (*sensitive users*) dari paparan berlebih terhadap konten "berpengaruh" (*influential items*) yang dapat memperburuk kondisi perilaku mereka, seperti polarisasi ekstrem atau isolasi sosial.

Dalam model Biasio dkk. (2023), masalah *echo chamber* tidak dipandang seragam untuk semua pengguna, melainkan diklasifikasikan berdasarkan kerentanan:

1. **Pengguna Sensitif (*Sensitive Users*):** Kelompok pengguna yang perilakunya rentan dipengaruhi secara negatif oleh pola konsumsi konten yang homogen atau bias.
2. **Item Berpengaruh (*Influential Items*):** Kategori konten yang memiliki dampak signifikan terhadap perilaku pengguna sensitif. Item ini dibagi menjadi dua:
 - (a) *Controversial Items*: Item yang jika dikonsumsi berlebihan dapat memperburuk isolasi atau perilaku negatif.
 - (b) *Favorable Items*: Item yang dapat memberikan dampak positif atau memecah isolasi (*bubble*) jika direkomendasikan dengan proporsi yang cukup.

Pendekatan ini sangat relevan untuk konteks pembelajaran adaptif karena "pengguna sensitif" dapat dipetakan sebagai siswa yang terisolasi secara akademik, dan "favorable items" sebagai interaksi dengan rekan yang memiliki kompetensi berbeda (heterogen).

Untuk memitigasi dampak negatif rekomendasi pada pengguna sensitif tanpa memerlukan pelatihan model ulang, Biasio dkk. (2023) mengusulkan algoritma *greedy re-ranking*. Algoritma ini bekerja pada tahap pasca-pemrosesan dengan menyusun ulang daftar skor prediksi awal ($\hat{r}_u$) agar memenuhi batasan proporsi item tertentu.

Pada kode II.1 diperlihatkan pseudocode dari algoritma *re-ranking* tersebut sebagaimana didefinisikan dalam penelitian aslinya.

Listing II.1 Algoritma Re-ranking

```
1 ALGORITHM Re-ranking
2   INPUT:
3       u      : User identifier
4       S      : Set of sensitive users
5       r_hat  : Scores predicted by backbone model for user u
6       alpha  : Minimum percentage of favorable items allowed
7       beta   : Maximum percentage of controversial items allowed
8       k      : Number of items to be recommended
9   OUTPUT:
10      Y_star : Top-k items to recommend to user u
11  BEGIN
12      IF u NOT IN S THEN
13          RETURN Argsort(r_hat, order='descending')[0:k]
14
15      ELSE
16          Y_star <- EmptySet
17          SortedItems <- Sort(r_hat, order='descending')
18
19          FOR EACH item j IN SortedItems DO
20              IF Size(Y_star) < k THEN
21
22                  CondAlpha <- ((f_j + Sum(f_i for i in Y_star))
23 / k) >= alpha
24
25                  CondBeta  <- ((c_j + Sum(c_i for i in Y_star))
26 / k) <= beta
27
28                  IF CondAlpha AND CondBeta THEN
29                      Add j to Y_star
30                  END IF
31              ELSE
32                  BREAK
33              END IF
34          END FOR
35
36          RETURN Y_star
37      END IF
38  END
39 END ALGORITHM
```

Secara matematis, algoritma memastikan bahwa probabilitas terpilihnya suatu item y_i dalam rekomendasi untuk pengguna sensitif ($s_u = 1$) memenuhi pertidaksamaan

berikut,

$$\mathbb{P}(y_i = 1 \mid s_u = 1, f_i = 1) \geq \alpha \quad (\text{II.9})$$

$$\mathbb{P}(y_i = 1 \mid s_u = 1, c_i = 1) \leq \beta \quad (\text{II.10})$$

dengan:

- Persamaan (II.9) menetapkan bahwa proporsi item *favorable* (yang memecah isolasi) harus lebih besar atau sama dengan ambang batas α .
- Persamaan (II.10) menetapkan bahwa proporsi item *controversial* (yang memperburuk isolasi) harus lebih kecil atau sama dengan ambang batas β .

Algoritma *re-ranking* ini bekerja dengan menyusun ulang daftar rekomendasi $\mathcal{Y}_{u,k}$ secara iteratif. Pada setiap langkah penambahan item ke dalam daftar rekomendasi final, algoritma memeriksa apakah penambahan item tersebut akan melanggar batasan α atau β .

- Jika daftar rekomendasi saat ini kekurangan item *favorable* (di bawah ambang α), algoritma akan secara paksa mengambil item *favorable* dari daftar cadangan, meskipun skor relevansinya sedikit lebih rendah, untuk menggantikan item non-favorable.
- Mekanisme ini menjamin terjadinya "eksposur paksa" (*forced exposure*) terhadap konten yang beragam, yang merupakan syarat utama untuk memecahkan *filter bubble* secara efektif (Biasio dkk. 2023).

Keunggulan utama pendekatan ini adalah sifatnya yang *model-agnostic* and efisien secara komputasi karena menggunakan pendekatan *greedy* pada tahap *post-processing*, sebagaimana dijelaskan secara teknis oleh Biasio dkk. (2023). Hal ini membuatnya lebih layak diimplementasikan pada kondisi data terbatas (*cold-start*) dibandingkan metode berbasis *Deep Learning* yang membutuhkan pelatihan ekstensif.

II.8 Metodologi Evaluasi Purwarupa Sistem Pembelajaran

II.8.1 Pengukuran Efektivitas dengan *Normalized Learning Gain*

Dalam ranah penelitian pendidikan fisika and teknologi pembelajaran, pengukuran efektivitas intervensi instruksional sering kali menghadapi tantangan bias yang disebabkan oleh perbedaan tingkat pengetahuan awal siswa. Untuk mengatasi hal ini, Richard Hake memperkenalkan konsep *average normalized gain* (g) sebagai metrik standar. Secara teoretis, *normalized gain* didefinisikan sebagai rasio antara peningkatan skor aktual yang dicapai (*actual gain*) terhadap peningkatan skor maksimum

yang mungkin dicapai (*maximum possible gain*). Penggunaan metrik ini bertujuan untuk memisahkan efek pembelajaran dari pengaruh skor *pre-test* sehingga memungkinkan perbandingan yang objektif antara populasi siswa yang memiliki latar belakang kemampuan yang heterogen (Nissen dkk. 2018).

Secara matematis, perhitungan *normalized gain* untuk rata-rata kelas atau individu pada umumnya dinyatakan dalam persamaan berikut:

$$g = \frac{\text{post} - \text{pre}}{\text{maksimum} - \text{pre}} \quad (\text{II.11})$$

dengan pre merepresentasikan skor pada tes awal sebelum instruksi diberikan, post adalah skor pada tes akhir, dan maksimum adalah batas atas skor yang dapat dicapai. Pada sistem yang menggunakan pengukuran skala kontinu seperti *Elo rating*, nilai maksimum ini disesuaikan dengan ambang batas *Elo* tertinggi (baik secara teoretis maupun empiris). Coletta dan Steinert (2020) menegaskan bahwa metrik ini memiliki keunggulan teoretis dibandingkan perhitungan selisih skor mentah atau *effect size* standar (seperti Cohen's *d*), terutama dalam menangani distribusi data yang mengalami *floor effect* atau *ceiling effect* ekstrem, sebuah efek yang mengakibatkan siswa dengan skor awal tinggi memiliki ruang peningkatan yang lebih sempit dibandingkan siswa dengan skor rendah.

Sebagai standar interpretasi efektivitas yang berlaku umum dalam literatur, Hake menetapkan kriteria ambang batas untuk mengkategorikan tingkat keberhasilan pembelajaran. Nilai *g* diklasifikasikan ke dalam tiga kategori: (1) **Rendah** (*Low-g*) jika $g < 0.3$; (2) **Sedang** (*Medium-g*) jika $0.3 \leq g < 0.7$; and (3) **Tinggi** (*High-g*) jika $g \geq 0.7$. Klasifikasi ini menyediakan kerangka kerja komparatif yang konsisten bagi para peneliti untuk mengevaluasi apakah sebuah metode pedagogis mampu menghasilkan peningkatan pemahaman konsep yang substansial terlepas dari kesulitan materi yang diajarkan (Coletta dan Steinert 2020).

II.8.2 Penentuan Ukuran Sampel dalam Studi Pilot

Dalam pengujian purwarupa sistem yang bersifat eksploratif, metodologi yang digunakan sering kali dikategorikan sebagai studi pilot atau penelitian pendahuluan (*preliminary research*). Menurut Sukserm (2024), penentuan ukuran sampel yang tepat sangat krusial untuk memastikan bahwa hasil pengujian dapat memberikan gambaran valid mengenai kelayakan instrumen dan desain penelitian.

Berdasarkan tinjauan yang dilakukan oleh Sukserm (2024), para peneliti merekomendasikan rentang sampel antara 10 hingga 30 partisipan untuk studi pilot. Secara khusus, Johanson dan Brooks (2010) (sebagaimana dikutip dalam Sukserm (2024)) menyatakan bahwa jumlah minimal 10 partisipan sudah cukup memadai untuk mengidentifikasi masalah utama dalam desain dan memvalidasi instrumen sebelum melangkah ke studi skala besar. Dengan demikian, penggunaan angka 10 sebagai batas minimum jumlah partisipan per kelompok dalam penelitian ini dianggap sah secara metodologis untuk mengevaluasi fungsionalitas purwarupa.

II.9 Evaluasi Kebenaran Kueri SQL

Dalam perancangan sistem pembelajaran yang menggunakan kueri SQL sebagai subjek penugasan, terdapat tantangan teknis dalam memvalidasi kebenaran jawaban siswa secara algoritmik. SQL (*Structured Query Language*) adalah bahasa deklaratif; kueri yang disusun menyatakan informasi apa yang ingin diambil, bukan bagaimana sistem harus secara algoritmik mengambilnya (Silberschatz, Korth, dan Sudarshan March 2019). Akibatnya, ada banyak cara sintaksis yang berbeda untuk menghasilkan hasil yang sama secara semantik.

Menurut Silberschatz, Korth, dan Sudarshan (March 2019), mengevaluasi dua kueri relasional untuk menentukan apakah keduanya setara secara semantik (*semantic equivalence*) adalah permasalahan komputasi yang sangat kompleks, bahkan termasuk dalam kategori NP-Hard dalam ilmu teori komputasi. Oleh karena itu, membangun sistem penilaian otomatis yang membandingkan Pohon Sintaksis Abstrak (*Abstract Syntax Tree*) atau representasi aljabar relasional dari kueri siswa dengan kueri kunci jawaban menjadi sangat sulit dan rawan kesalahan. Kesulitan inilah yang menjadikan pendekatan perbandingan himpunan hasil (*result set comparison*) dengan eksekusi pada basis data tiruan (*sandbox*) menjadi standar de-facto yang paling pragmatis dan sering digunakan dalam mengukur kebenaran kueri secara utuh.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Mayoritas sistem asesmen adaptif yang ada saat ini dibangun di atas asumsi bahwa pembelajaran adalah proses soliter. Algoritma pelacakan pengetahuan (*knowledge tracing*) yang dominan bekerja dengan memproses data interaksi biner (benar/salah) antara siswa dan mesin secara eksklusif (Minn 2022).

Implikasi dari desain ini adalah terjadinya *algorithmic blindness* terhadap konteks sosial. Sistem mampu memodelkan kemahiran individu dengan presisi tinggi, namun ”buta” terhadap fakta bahwa siswa mungkin terjebak dalam isolasi materi atau *filter bubble* akademik, hanya mengerjakan tipe soal yang dikuasai dan tidak pernah terekspos pada perspektif rekan sejawat (Halkiopoulos dan Gkintoni 2024). Akibatnya, sistem berisiko memberikan skor kompetensi tinggi pada siswa yang sebenarnya rapuh secara kolaboratif, menciptakan fenomena ”kompetensi semu”.

Dalam kondisi saat ini, aktivitas sosial seringkali hanya ditempatkan sebagai fitur tambahan (*add-on*) yang berjalan paralel namun terpisah dari mesin asesmen utama. Data berharga dari interaksi sosial seperti kemampuan siswa dalam mengevaluasi pekerjaan orang lain atau memberikan argumen seringkali terbuang dan tidak dikonversi menjadi sinyal kompetensi yang dapat mengubah rekomendasi materi (Ihichr dkk. 2024).

Upaya yang ada untuk mengatasi masalah isolasi pembelajaran sejauh ini cenderung mengandalkan inisiatif pengguna, seperti pendekatan *User Controllable Recommender Systems* (UCRS) (Wang dkk. 2022) atau visualisasi sosial (OSSM) (Brusilovsky dkk. 2016). Namun, pendekatan ini memiliki kelemahan fundamental dalam konteks pendidikan, pendekatan ini berasumsi bahwa pengguna menyadari bahwa mereka sedang terisolasi.

Dalam realitas algoritma adaptif, fenomena *overpersonalization* yang terealisasi dengan gejala *filter bubble* atau *echo-chamber* seringkali bersifat tidak terlihat (*invi-*

sible). Sistem secara otomatis menyaring konten yang tidak sesuai dengan profil historis sehingga siswa tidak pernah terekspos pada opsi alternatif dan menganggap bahwa materi yang mereka terima adalah satu-satunya yang tersedia. Oleh karena itu, menyerahkan kendali mitigasi sepenuhnya kepada pengguna berisiko tidak efektif karena pengguna tidak dapat memilih apa yang tidak mereka lihat. Sistem saat ini kekurangan mekanisme intervensi otomatis yang mampu "memaksa" terjadinya diversifikasi interaksi ketika pola isolasi terdeteksi oleh algoritma. Dari analisis kondisi di atas, disimpulkan bahwa menambahkan fitur kolaborasi konvensional tidak akan menyelesaikan masalah *overpersonalization* selama mesin asesmennya masih bekerja secara terisolasi.

Kebutuhan mendesak saat ini adalah melakukan rekayasa ulang (*re-engineering*) pada arsitektur asesmen. Diperlukan sebuah sistem yang mampu mengintegrasikan aktivitas sosial sebagai dimensi kompetensi komplementer yang bekerja sinergis dengan aktivitas pengerjaan soal. Sistem harus memiliki kapabilitas untuk: (1) mengkuantifikasi aktivitas kolaboratif menjadi metrik kontribusi sosial yang terukur, dan (2) menggabungkan metrik tersebut dengan skor kemahiran akademik untuk memberikan gambaran profil siswa yang lebih holistik. Dengan pendekatan multidimensi ini, sistem dapat memitigasi risiko isolasi pembelajaran secara sistematis tanpa mengabaikan integritas penilaian kognitif individu.

III.2 Analisis Kebutuhan

Berdasarkan analisis kondisi saat ini pada Subbab III.1, sistem yang dibutuhkan harus mampu menjembatani keterpisahan antara personalisasi individu dengan lingkungan sosialnya untuk memitigasi risiko *overpersonalization*. Kebutuhan ini dirumuskan tanpa membatasi teknik implementasi spesifik, guna memungkinkan eksplorasi berbagai alternatif solusi (seperti *peer assessment*, *mentoring*, atau rekomendasi jejaring) pada tahap pemilihan solusi.

III.2.1 Kebutuhan Fungsional

Daftar kebutuhan fungsional sistem dari sisi pengguna (siswa) dan logika sistem disajikan pada Tabel III.1.

Tabel III.1 Kebutuhan Fungsional (FR) Sistem

Kode	Deskripsi Kebutuhan Fungsional
Interaksi Pengguna (Siswa)	
FR-01	Sistem harus menyediakan mekanisme otentikasi bagi siswa untuk mengakses lingkungan pembelajaran personal mereka.
FR-02	Sistem harus menyajikan materi pembelajaran yang telah disesuaikan tingkat kesulitannya dengan kemahiran siswa saat ini.
FR-03	Sistem harus memfasilitasi interaksi pembelajaran antar-pengguna yang memungkinkan terjadinya pertukaran informasi atau kolaborasi akademik di dalam platform.
FR-04	Sistem harus menyediakan informasi mengenai konteks sosial pembelajaran (misalnya, aktivitas komunitas atau capaian kolektif) untuk membangun kesadaran sosial (<i>social awareness</i>).
Logika Adaptasi & Pemrosesan Data (Sistem)	
FR-05	Sistem harus memiliki algoritma untuk mengestimasi tingkat kemahiran pengetahuan individu siswa secara dinamis berdasarkan riwayat aktivitasnya.
FR-06	Sistem harus mampu mengkuantifikasi data interaksi sosial (dari FR-03) menjadi parameter numerik yang dapat diproses lebih lanjut (misalnya, skor keterlibatan atau skor kinerja kolaboratif).
FR-07	Sistem harus memiliki mekanisme untuk menggabungkan parameter kemahiran individu (FR-05) dan parameter sosial (FR-06) dalam satu model komputasi terpadu.
FR-08	Sistem harus menggunakan metrik kuantitatif untuk menentukan materi atau aktivitas berikutnya yang paling optimal bagi siswa.
FR-09	Sistem harus mampu merekomendasikan intervensi sosial spesifik (misalnya, merekomendasikan orang untuk berinteraksi atau topik untuk didiskusikan) guna mencegah isolasi pembelajaran.

III.2.2 Kebutuhan Nonfungsional

Kebutuhan nonfungsional disesuaikan untuk mendukung interaksi sosial yang responsif tanpa menentukan metode spesifik. Tabel III.2 merinci kebutuhan nonfungsional sistem yang diusulkan.

Tabel III.2 Kebutuhan Nonfungsional (NFR) Sistem

Kode	Deskripsi Kebutuhan Nonfungsional
NFR-01	(Usability) Antarmuka interaksi sosial harus terintegrasi secara intuitif dalam platform yang sama dengan platform pembelajaran, meminimalkan beban kognitif siswa saat berpindah antara belajar mandiri dan berkolaborasi.
NFR-02	(Interpretability) Sistem harus mampu memberikan indikasi alasan rekomendasi (baik materi maupun interaksi sosial).
NFR-03	(Performance) Pembaruan model pengguna (baik skor individu maupun sosial) harus terjadi dalam waktu nyata (<i>near real-time</i>) setelah interaksi selesai dilakukan.
NFR-04	(Scalability) Sistem harus mampu menangani konkurensi interaksi sosial dari satu kelas (± 50 pengguna) secara simultan.
NFR-05	(Privacy) Mekanisme interaksi sosial harus dirancang sedemikian rupa sehingga data privasi spesifik (seperti nilai asesmen mentah) tidak terekspos ke pengguna lain.
NFR-06	(Accessibility) Sistem dapat diakses melalui peramban web standar.

III.2.3 Pemetaan Kebutuhan

Tabel III.3 memetakan tujuan penanganan masalah ke fungsi spesifik yang telah digeneralisasi.

Tabel III.3 Pemetaan Masalah dan Kebutuhan Fungsional

Fokus Penanganan Masalah	Implementasi Fungsional (FR)
Model Kompetensi Individu	FR-02, FR-05
Fasilitasi Interaksi Sosial	FR-01, FR-03, FR-04
Kuantifikasi Aspek Sosial	FR-06
Integrasi Model	FR-07
Adaptasi	FR-08, FR-09

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Untuk menjawab kebutuhan sistem dalam memitigasi *overpersonalization*, diperlukan pemilihan komponen teknologi yang tidak hanya akurat, tetapi juga fleksibel untuk diintegrasikan. Pemilihan solusi dilakukan pada tiga dimensi utama: (1) teknik asesmen kemahiran individu, (2) teknik interaksi dan asesmen sosial, dan (3) teknik spesifik pencegahan *echo chamber*.

III.3.1.1 Alternatif Teknik Asesmen Kemahiran Individu (R1)

Komponen ini berfungsi memodelkan kompetensi siswa. Dalam konteks pencegahan *overpersonalization*, kriteria utamanya adalah apakah model tersebut cukup fleksibel untuk "diintervensi" oleh parameter sosial tanpa merusak integritas matematisnya.

1. **Item Response Theory (IRT) dan Bayesian IRT (IRT*)**: Pendekatan psikometri standar yang memodelkan probabilitas jawaban benar berdasarkan parameter siswa (θ) dan butir soal (b) (Handayani dkk. 2025). **Analisis terhadap Overpersonalization**: Model IRT cenderung statis dan mengasumsikan parameter invarian. Sulit untuk mengintegrasikan "bobot sosial" ke dalam rumus IRT secara dinamis untuk mengubah rekomendasi konten pembelajaran secara *real-time* saat terdeteksi adanya isolasi pembelajaran (Vesin dkk. 2022).
2. **Factor Analysis (FA)**: Teknik statistik yang digunakan untuk mengidentifikasi struktur faktor laten (seperti pengetahuan awal atau kemampuan kognitif) yang mendasari kinerja siswa (Ihichr dkk. 2024). **Analisis terhadap Overpersonalization**: FA lebih cocok digunakan untuk validasi struktur tes atau analisis *post-hoc* (setelah data terkumpul) daripada pelacakan dinamis. Teknik ini tidak dirancang untuk pembaruan parameter *real-time* yang diperlukan untuk merespons perubahan perilaku sosial siswa.
3. **Bayesian Knowledge Tracing (BKT)**: Model BKT ini adalah model berbasis *Hidden Markov Models* (HMM) yang melacak transisi biner status pengetahuan dari "belum belajar" ke "sudah belajar" (Minn 2022). **Analisis terhadap Overpersonalization**: BKT memiliki struktur probabilitas yang kaku (mengandalkan parameter *guess* dan *slip*). Memasukkan variabel sosial kontinu ke dalam probabilitas transisi BKT sangat kompleks dan berisiko melanggar asumsi dasar model bahwa keterampilan tidak akan "dilupakan" (Ihichr dkk. 2024), padahal isolasi sosial mungkin menghasilkan penurunan skor yang memicu intervensi.
4. **Deep Knowledge Tracing (DKT)**: Menggunakan jaringan saraf tiruan (*Recur-*

rent Neural Networks) untuk melacak pengetahuan (Minn 2022). **Analisis terhadap Overpersonalization:** Meskipun akurasi tinggi, sifatnya yang *black-box* membuat sistem sulit mendeteksi alasan mengapa seorang siswa terjebak dalam pola soal tertentu. Intervensi algoritmik untuk memecahkan *bubble* sulit dilakukan secara terukur karena kompleksitas parameternya.

5. **Sistem Elo rating:** Memodelkan interaksi siswa-konten sebagai kompetisi dengan rumus pembaruan sederhana: $R_{baru} = R_{lama} + K(S - E)$ (Vesin dkk. 2022). **Analisis terhadap Overpersonalization:** Ini adalah kandidat terkuat karena keberadaan faktor K (koefisien bobot). Faktor ini dapat dimodifikasi secara eksplisit menjadi fungsi dari aktivitas sosial (misalnya, siswa yang kurang bersosialisasi mendapat K yang memaksa perubahan peringkat lebih cepat).

III.3.1.2 Alternatif Teknik Interaksi dan Asesmen Sosial (R2 & R3)

Komponen ini bertujuan memfasilitasi interaksi yang bermakna. Untuk memecahkan *filter bubble*, aktivitas sosial harus memaksa siswa terpapar pada perspektif atau materi di luar preferensi historis mereka.

1. **Pembelajaran Berbasis Proyek (Project-Based Learning / PBL):** Model pembelajaran ini adalah model yang di dalamnya siswa didukung berkolaborasi untuk menghasilkan artefak proyek nyata (Zhang dan Ma 2023). **Analisis terhadap Overpersonalization:** Sangat baik untuk kolaborasi mendalam, namun memiliki kendala besar dalam penilaian otomatis. Sulit bagi sistem untuk memisahkan kontribusi individu dari hasil kelompok (*free-rider problem*) secara akurat tanpa intervensi manual dosen (Ryoo dan Winkelmann 2021) sehingga sulit dijadikan input data *real-time* untuk algoritma adaptif.
2. **Pendampingan Sejawat (Peer Mentoring):** Mekanisme bimbingan *one-on-one* antara siswa senior dan junior (Le, Sok, dan Heng 2024). **Analisis terhadap Overpersonalization:** Hubungan ini seringkali bersifat hierarkis dan searah (senior mengajar junior), bukan kolaborasi setara. Hal ini kurang efektif untuk tujuan memecahkan *echo chamber* yang membutuhkan paparan terhadap berbagai perspektif sejawat yang beragam, bukan sekadar transfer pengetahuan vertikal.
3. **Formasi Kelompok Berbasis Klustering (Group Formation):** Menggunakan algoritma seperti K-Means untuk membentuk kelompok heterogen di awal pembelajaran (Nalli, Amendola, dan Smith 2022). **Analisis terhadap Overpersonalization:** Efektif untuk "memaksa" keberagaman di awal (*cold start*). Namun, karena sifatnya statis, teknik ini tidak menghasilkan data kinerja kontinu yang bisa digunakan sistem untuk memantau apakah siswa kembali meng-

isolasi diri setelah kelompok terbentuk.

4. **Sesi Diskusi Terbuka (*Open Discussion*):** Memfasilitasi forum bebas untuk pertukaran ide (Daif-Allah dan Khan 2016). **Analisis terhadap *Overpersonalization*:** Dalam forum bebas, siswa cenderung mencari teman yang sepe-mikiran (*homophily*), yang justru memperkuat *echo chamber* alih-alih memecahkannya. Selain itu, sulit menilai kualitas interaksi secara otomatis tanpa NLP yang kompleks.
5. **Penilaian Sejawat (*Peer Assessment*):** Siswa menilai pekerjaan rekan lain berdasarkan rubrik dengan status yang setara (Ihichr dkk. 2024). **Analisis terhadap *Overpersonalization*:** Teknik ini paling potensial karena sistem memegang kendali penuh atas "siapa menilai siapa". Sistem dapat menugaskan siswa untuk menilai rekan yang memiliki sudut pandang bertentangan atau tingkat kemampuan berbeda (di luar *bubble*-nya). Selain itu, kualitas umpan balik (R3) dapat diukur sebagai metrik keterbukaan siswa terhadap kolaborasi (Lu dan Zhang 2012).

III.3.1.3 Alternatif Teknik Pencegahan *Echo Chamber* dan *Filter Bubble*

Subbab ini mengevaluasi pendekatan spesifik yang telah dikembangkan dalam literatur sistem rekomendasi untuk mengatasi masalah isolasi, guna melihat kesesuaiannya untuk diadopsi ke dalam sistem asesmen pendidikan.

1. ***User Controllable Recommender Systems (UCRS)*:** Pendekatan yang memberikan fitur kendali eksplisit kepada pengguna untuk mengatur tingkat diversifikasi rekomendasi mereka sendiri (Wang dkk. 2022). **Analisis:** Pendekatan ini sangat bergantung pada kesadaran pengguna. Dalam konteks pendidikan, siswa seringkali tidak menyadari bahwa mereka berada dalam *bubble* kompetensi ("*unconscious incompetence*"). Mengandalkan siswa untuk secara manual meminta materi yang "tidak mereka sukai" berisiko tidak efektif dibandingkan intervensi otomatis.
2. ***Group Recommender Systems (GRS)*:** Teknik yang merekomendasikan konten berdasarkan preferensi agregat dari sekelompok pengguna untuk meningkatkan keadilan (*fairness*) dan pluralitas (Dokoupil 2022). **Analisis:** GRS cenderung memprioritaskan konsensus kelompok atau rata-rata preferensi. Dalam pembelajaran adaptif, hal ini berisiko mengorbankan personalisasi spesifik yang dibutuhkan siswa *outlier* (sangat mahir atau sangat tertinggal), karena rekomendasi akan tertarik ke arah "pusat" kelompok, yang bisa menyebabkan *under-personalization*.
3. **Pemodelan Komunitas Implisit (*FRediECH*):** Sebuah teknik rekomendasi teman yang dirancang khusus untuk memecahkan *echo chamber* dengan

merekomendasikan koneksi sosial yang beragam namun relevan, berdasarkan pembelajaran representasi interaksi pengguna menggunakan *Graph Neural Networks* (Tommasel, Rodriguez, dan Godoy 2021). **Analisis:** Teknik ini sangat kuat untuk memecah polarisasi opini. Namun, kelemahan utamanya adalah kebutuhan akan data pelatihan yang besar untuk membangun graf interaksi awal (*cold-start problem*) sehingga sulit diterapkan pada fase awal implementasi sistem tanpa dataset historis.

4. ***Constraint-based Re-ranking*:** Metode pasca-pemrosesan (*post-processing*) yang menyusun ulang daftar rekomendasi awal agar memenuhi batasan (*constraints*) distribusi tertentu, misalnya menetapkan persentase minimum item yang bersifat "favorable" atau beragam (Biasio dkk. 2023). **Analisis:** Pendekatan ini bersifat agnostik terhadap model dasar dan bekerja berdasarkan aturan logis (α dan β) pada daftar rekomendasi yang ada. Keunggulan utamanya adalah efisiensi komputasi dan kemampuan untuk langsung berfungsi tanpa memerlukan pelatihan model data yang ekstensif (*training-free*), menjadikannya solusi yang sangat potensial untuk kondisi data terbatas.

III.3.2 Analisis Penentuan Solusi

Penentuan solusi teknis dilakukan menggunakan metode *Weighted Decision Matrix* (Matriks Keputusan Terbobot). Pendekatan ini digunakan untuk memilih komponen sistem secara objektif berdasarkan kriteria yang diturunkan dari Batasan Masalah (Bab I) dan Tinjauan Literatur (Bab II).

Analisis dibagi menjadi tiga keputusan terpisah untuk memilih: (1) Teknik Asesmen Individu, (2) Teknik Interaksi Sosial, dan (3) Teknik Mitigasi *Overpersonalization*.

III.3.2.1 Penentuan Teknik Asesmen Individu

Tujuannya adalah memilih algoritma pelacakan pengetahuan. Berdasarkan tinjauan literatur, kandidat utamanya adalah IRT, FA, BKT, DKT, dan Elo rating.

Tabel III.4 Matriks Keputusan Teknik Asesmen Individu

Kriteria	Bobot	IRT	FA	BKT	DKT	Elo
Efisiensi Komputasi	30%	2	1	3	1	5
Kebutuhan Data Awal (Cold Start)	30%	2	2	3	2	5
Akurasi Pelacakan	20%	4	3	3	5	4
Interpretabilitas	20%	4	3	4	1	5
Skor Terbobot	100%	2.8	2.1	3.2	2.1	4.8

Rasionalisasi Objektif dan Analisis *Trade-off*:

1. **Efisiensi & Kebutuhan Data (Bobot Tinggi - 60%):** Kriteria ini diberi bobot tertinggi mengingat batasan masalah pengembangan purwarupa yang mungkin tidak memiliki dataset historis besar. **Elo rating** unggul mutlak (skor 5) karena algoritma ini dirancang untuk bekerja tanpa pra-kalibrasi yang rumit dan efisien secara komputasi (Vesin dkk. 2022). Sebaliknya, **IRT** dan **FA** membutuhkan sampel besar untuk kalibrasi parameter butir soal, dan **DKT** membutuhkan data pelatihan masif untuk melatih jaringan saraf (Minn 2022).
2. **Akurasi vs. Kelayakan (*Trade-off*):** **DKT** memiliki skor akurasi tertinggi (5) karena kemampuannya menangkap pola kompleks (Minn 2022). Namun, terjadi *trade-off* signifikan pada aspek **Interpretabilitas** (skor 1) karena sifat *black-box*-nya, yang menyulitkan sistem untuk menjelaskan alasan rekomendasi kepada siswa. **Elo rating** dipilih bukan karena merupakan teknik paling akurat, tetapi karena Elo rating adalah solusi paling layak (*feasible*) untuk diimplementasikan dalam skenario data terbatas dengan akurasi yang masih dapat diterima.

III.3.2.2 Penentuan Teknik Interaksi Sosial

Tujuannya adalah memilih bentuk aktivitas sosial yang dapat memfasilitasi kolaborasi sekaligus menghasilkan data yang dapat diolah sistem.

Tabel III.5 Matriks Keputusan Teknik Interaksi Sosial

Kriteria	Bobot	PBL	Mentor	Group	Diskusi	Peer Assmt.
Keterukuran Data (Measurability)	35%	2	3	1	1	5
Kesetaraan Interaksi	25%	5	2	5	5	5
Potensi Eksposur Keberagaman	25%	4	2	3	3	5
Kompleksitas Implementasi	15%	2	3	4	3	4
Skor Terbobot	100%	3.25	2.5	3.0	2.8	4.85

Rasionalisasi Objektif dan Analisis *Trade-off*:

1. **Keterukuran Data (35%):** Sistem membutuhkan input kuantitatif untuk algoritma (FR-06). **Peer Assessment** mendapatkan skor tertinggi (5) karena menghasilkan artefak terstruktur (skor rubrik dan teks umpan balik) yang mudah dikuantifikasi (Ihichr dkk. 2024). Sebaliknya, **Diskusi Terbuka** dan **PBL** (Project-Based Learning) sangat sulit dinilai kontribusi individunya secara otomatis tanpa intervensi manual dosen (Ryoo dan Winkelmann 2021).
2. **Kesetaraan & Eksposur (*Trade-off*):** **Mentoring** mendapat skor rendah pada kesetaraan (2) karena sifatnya hierarkis (senior-junior) (Le, Sok, dan Heng 2024), yang kurang cocok untuk memecah *echo chamber* dibandingkan interaksi setara. **PBL** sebenarnya sangat baik dalam kesetaraan dan kolaborasi mendalam (skor 5), namun dipilihnya **Peer Assessment** merupakan *trade-off* logis karena PBL memiliki kompleksitas implementasi yang tinggi dan risiko *free-rider* yang sulit dideteksi sistem (Zhang dan Ma 2023). Peer Assessment dipilih karena memungkinkan sistem "mengatur" siapa menilai siapa untuk memaksa eksposur keberagaman.

III.3.2.3 Penentuan Teknik Mitigasi *Overpersonalization*

Keputusan ini bertujuan memilih mekanisme teknis untuk memecahkan *echo chamber* yang dapat beroperasi secara otomatis dan layak diimplementasikan segera tanpa data pelatihan (*cold-start*).

Tabel III.6 Matriks Keputusan Teknik Mitigasi Isolasi

Kriteria	Bobot	(UCRS)	(GRS)	(FRediECH)	(Re-rank)
Otomasi Intervensi	35%	1	4	5	5
Kelayakan Cold-Start	35%	5	4	1	5
Preservasi Personalisasi	30%	5	2	4	4
Skor Terbobot	100%	3.6	3.4	3.3	4.7

Rasionalisasi Objektif dan Analisis *Trade-off*:

1. **Automasi Intervensi (35%):** UCRS mendapat skor terendah (1) karena bergantung pada inisiatif pengguna yang seringkali bias atau pasif. **FRediECH** dan **Re-ranking** unggul (5) karena sistem secara proaktif melakukan intervensi untuk memecah *bubble* tanpa menunggu tindakan pengguna.
2. **Kelayakan Cold-Start (35%):** Kriteria ini krusial untuk purwarupa. **FRediECH** mendapat penalti besar (1) karena berbasis *Deep Learning* yang membutuhkan data historis masif untuk pelatihan awal. Sebaliknya, **Re-ranking** mendapat skor sempurna (5) karena algoritma ini bekerja secara *greedy* pada daftar yang ada berdasarkan aturan logis sehingga bisa langsung berjalan sejak hari pertama implementasi (Biasio dkk. 2023).
3. **Preservasi Personalisasi (30%):** **GRS** cenderung menarik rekomendasi ke rata-rata kelompok, mengorbankan preferensi unik individu (skor 2). **Re-ranking** dinilai baik (4) karena hanya memodifikasi sebagian kecil daftar rekomendasi (sesuai parameter α) untuk menyuntikkan keberagaman, sementara sisa daftar tetap mempertahankan personalisasi berbasis kompetensi individu.
4. **Kesimpulan: Constraint-based Re-ranking** (Biasio dkk. 2023) dipilih. Metode *re-ranking* ini adalah metode yang menawarkan keseimbangan terbaik karena merupakan metode yang otomatis seperti FRediECH dalam memecahkan isolasi, namun fleksibel seperti UCRS dalam hal implementasi tanpa data (*cold-start*). Sistem akan menggunakan algoritma ini untuk memfilter calon pasangan *peer assessment*, guna memastikan setiap siswa terpapar pada rekan dengan tingkat kemahiran yang beragam (heterogen) sesuai batasan statistik yang ditentukan.

III.3.3 Keputusan Akhir Pemilihan Solusi

Berdasarkan analisis komparatif yang telah dilakukan melalui matriks keputusan, penelitian ini menetapkan arsitektur solusi yang terdiri dari tiga komponen utama yang saling terintegrasi. Pemilihan ini didasarkan pada prinsip efisiensi komputasi, ketersediaan data pada fase awal (*cold-start*), dan validitas pedagogis untuk mitigasi risiko *overpersonalization*.

Komponen pertama yang menjadi fondasi pelacakan kompetensi adalah **Sistem Elo rating**. Berbeda dengan model probabilitas statis seperti IRT atau model berbasis *Deep Learning* seperti DKT yang membutuhkan dataset historis masif, Elo rating dipilih karena kemampuannya untuk beradaptasi secara dinamis dengan ukuran sampel yang kecil (*small sample size*). Algoritma ini akan berfungsi sebagai mesin utama untuk mengestimasi parameter kemahiran siswa secara *real-time* setelah setiap interaksi, memberikan landasan data yang akurat namun ringan secara komputasi untuk proses adaptasi selanjutnya (Vesin dkk. 2022).

Sebagai mekanisme interaksi sosial, sistem akan mengimplementasikan **Peer Assessment** (penilaian sejawat). Keputusan ini diambil karena aktivitas ini menawarkan keuntungan ganda: secara teknis, ia menghasilkan artefak data kuantitatif (skor penilaian) yang terstruktur dan mudah diolah oleh algoritma; secara pedagogis, ia memberikan manfaat metakognitif tertinggi bagi siswa yang berperan sebagai penilai (*assessor*) (Lu dan Zhang 2012). Aktivitas ini menjadi wadah strategis bagi sistem untuk menyuntikkan intervensi sosial yang terukur, menggantikan interaksi diskusi bebas yang sulit dikuantifikasi.

Komponen krusial yang mengikat kedua elemen di atas untuk memecahkan isolasi pembelajaran adalah algoritma **Constraint-based Re-ranking**. Diadaptasi dari kerangka kerja Biasio dkk. (2023), teknik ini dipilih sebagai strategi mitigasi utama karena keunggulannya dalam menangani masalah *cold-start* dibandingkan pendekatan berbasis neural network seperti FRediECH. Sistem akan menggunakan algoritma ini untuk memfilter daftar calon pasangan *peer assessment* dengan menerapkan batasan (*constraint*) statistik α . Batasan ini memastikan bahwa setiap siswa terpapar pada proporsi minimum rekan yang memiliki tingkat kemahiran berbeda (heterogen), yang dihitung berdasarkan jarak skor Elo mereka. Dengan demikian, sistem menjamin terjadinya diversifikasi perspektif dan pemecahan *echo chamber* kompetensi secara otomatis sejak hari pertama operasional.

Penerapan mekanisme ini secara fundamental mengubah definisi "konten pembel-

jaran” dalam sistem. Umpan balik (*feedback*) yang dihasilkan dari aktivitas penilaian sejawat diperlakukan sebagai **artefak pembelajaran dinamis**. Berbeda dengan soal latihan yang direkomendasikan secara personal (homogen) oleh algoritma Elo, umpan balik dari rekan sejawat yang dipilih secara heterogen merepresentasikan **eksposur terhadap konten yang tidak terpersonalisasi**. Hal ini memaksa siswa untuk menghadapi perspektif, logika penyelesaian masalah, atau kritik yang berada di luar ”zona nyaman” yang terpersonalisasi oleh algoritma sehingga secara efektif meminimalkan risiko *overpersonalization* tanpa merusak jalur belajar (*learning path*) individu.

BAB IV

PERANCANGAN ARSITEKTUR DAN INTERAKSI SISTEM

Bab ini menguraikan rancangan konsep solusi yang diusulkan melalui dua perspektif pemodelan utama: pemodelan konteks-interaksi untuk menggambarkan batasan dan fungsionalitas sistem, serta pemodelan struktur-perilaku untuk merinci mekanisme kolaborasi antar-komponen internal.

IV.1 Model Konteks dan Interaksi (*Use Case Diagram*)


Model ini mendefinisikan batasan sistem (*system boundary*), mana saja yang menjadi fitur yang diimplementasikan di dalam sistem dan mana saja yang berada di luar sistem, terutama aktor. Selain itu, bisa dijelaskan juga interaksi yang terjadi antara aktor eksternal dengan fitur-fitur utama sistem.

Use case didefinisikan berdasarkan pemetaan terhadap kebutuhan fungsional yang telah diuraikan pada subbab III.2 bisa dilihat pada tabel IV.1.

Tabel IV.1 Pemetaan Kebutuhan Fungsional ke Use Case

ID UC	Nama Use Case	Kebutuhan Fungsional (FR)
UC-01	Kelola Akun	FR-01 (Autentikasi)
UC-02	Mengerjakan Latihan Adaptif	FR-02 (Sajian Materi), FR-08 (Rekomendasi Konten)
UC-03	Melakukan <i>Peer Assessment</i>	FR-03 (Memberi Feedback), FR-09 (Intervensi Sosial)
UC-04	Melihat Umpan Balik Rekan	FR-03 (Menerima Feedback)
UC-05	Memantau Profil Kompetensi	FR-05 (Elo Personal), FR-06 (Elo Sosial), FR-07 (Model Terpadu)
UC-06	Memantau Konteks Sosial	FR-04 (Visualisasi Kelas)

Penggambaran dari setiap *use case* di atas dan interaksinya dengan aktor luar, tercermin pada gambar IV.1 di bawah ini.



Gambar IV.1 Use Case Diagram - Interaksi Siswa dengan Sistem Asesmen Adaptif Kolaboratif

Adapun penjelasan dari setiap *use case* secara lebih terperinci disajikan pada tabel-tabel berikut ini.

Tabel IV.2 Deskripsi Use Case Kelola Akun (UC-01)

Nama Use Case	Kelola Akun
Aktor	Siswa
FR Terkait	FR-01
Deskripsi	Proses autentikasi pengguna untuk memastikan keamanan akses terhadap data profil kompetensi dan riwayat pembelajaran.
Kondisi sebelum	Siswa memiliki akun yang terdaftar di dalam basis data sistem.
Kondisi sesudah	Sesi pengguna aktif; Sistem memuat profil Elo rating siswa.
Main Flow	1. Siswa memasukkan kredensial akun (<i>username/password</i>). 2. Sistem memvalidasi kesesuaian data. 3. Sistem menginisialisasi sesi pembelajaran. 4. Sistem menampilkan dasbor utama.

Tabel IV.3 Deskripsi Use Case Mengerjakan Latihan Adaptif (UC-02)

Nama Use Case	Mengerjakan Latihan Adaptif
Aktor	Siswa
FR Terkait	FR-02, FR-08
Deskripsi	Siswa mengerjakan soal latihan yang dipilih secara dinamis oleh sistem berdasarkan estimasi kemampuan saat ini untuk meningkatkan kompetensi.
Kondisi sebelum	Siswa telah login; Nilai parameter Elo rating (θ) siswa tersedia.
Kondisi sesudah	Skor Elo siswa diperbarui; Sistem mengevaluasi tren variabilitas skor (deteksi stagnasi).
Main Flow	1. Sistem memilih latihan soal dengan tingkat kesulitan setara ($D_j \approx R_i$). 2. Sistem menampilkan soal kepada siswa. 3. Siswa menginputkan jawaban. 4. Sistem memvalidasi jawaban dan menghitung skor aktual. 5. Sistem memperbarui profil kompetensi siswa.

Tabel IV.4 Deskripsi Use Case Melakukan *Peer Assessment* (UC-03)

Nama Use Case	Melakukan <i>Peer Assessment</i>
Aktor	Siswa
FR Terkait	FR-03, FR-09
Deskripsi	Siswa mengevaluasi pekerjaan rekan sejawat menggunakan rubrik terstruktur. Aktivitas ini dipicu oleh sistem untuk memecahkan isolasi kompetensi.
Kondisi sebelum	Sistem mendeteksi stagnasi pembelajaran; Algoritma <i>Re-ranking</i> telah menemukan pasangan heterogen.
Kondisi sesudah	Skor Elo <i>Assessee</i> diperbarui (berdasarkan nilai tugas); Skor Elo <i>Assessor</i> diperbarui (berdasarkan kualitas reuiu).
Main Flow	1. Siswa menerima notifikasi tugas reuiu. 2. Sistem menampilkan jawaban rekan tanpa identitas (anonim) beserta rubrik penilaian. 3. Siswa mengisi penilaian kuantitatif dan kualitatif. 4. Sistem memproses hasil untuk memperbarui Elo rating kedua belah pihak.

Tabel IV.5 Deskripsi Use Case Melihat Umpan Balik Rekan (UC-04)

Nama Use Case	Melihat Umpan Balik Rekan
Aktor	Siswa
FR Terkait	FR-03
Deskripsi	Siswa meninjau hasil evaluasi dan komentar yang diberikan oleh rekan sejawat terhadap tugas yang telah dikerjakan sebelumnya.
Kondisi sebelum	Proses <i>peer assessment</i> oleh rekan telah selesai; Notifikasi tersedia.
Kondisi sesudah	Status notifikasi umpan balik menjadi ”terbaca”.
Main Flow	1. Siswa memilih notifikasi hasil asesmen. 2. Sistem menampilkan rincian skor dan komentar dari rekan. 3. Siswa mempelajari masukan yang diberikan. 4. Siswa menutup tampilan umpan balik.

Tabel IV.6 Deskripsi Use Case Memantau Profil Kompetensi (UC-05)

Nama Use Case	Memantau Profil Kompetensi
Aktor	Siswa
FR Terkait	FR-05, FR-06, FR-07
Deskripsi	Siswa melihat visualisasi perkembangan kemahiran individu, termasuk kontribusi dari aktivitas individu dan sosial.
Kondisi sebelum	Data riwayat aktivitas pembelajaran siswa tersedia.
Kondisi sesudah	Informasi profil ditampilkan; Tidak ada perubahan data.
Main Flow	1. Siswa mengakses menu profil. 2. Sistem mengambil data histori skor Elo. 3. Sistem menampilkan grafik tren kompetensi (θ) terhadap waktu. 4. Sistem menampilkan statistik partisipasi sosial.

Tabel IV.7 Deskripsi Use Case Memantau Konteks Sosial (UC-06)

Nama Use Case	Memantau Konteks Sosial
Aktor	Siswa
FR Terkait	FR-04
Deskripsi	Siswa melihat posisi relatif kemahirannya dibandingkan dengan distribusi kemampuan kelas secara anonim (<i>Social Awareness</i>).
Kondisi sebelum	Data agregat kemampuan seluruh kelas tersedia.
Kondisi sesudah	Visualisasi distribusi kelas ditampilkan.
Main Flow	1. Siswa mengakses menu wawasan kelas. 2. Sistem mengagregasi data pengguna aktif. 3. Sistem menampilkan grafik distribusi normal kelas. 4. Sistem menyoroti posisi siswa pada grafik tersebut.

Berdasarkan pemodelan *use case* yang telah dijelaskan di atas, karakteristik interaksi sistem yang diusulkan menunjukkan pergeseran dari paradigma sistem yang pasif

menjadi sistem dengan intervensi aktif. Perbedaan utamanya terletak pada mekanisme *System-initiated Intervention*, khususnya pada UC-03. Berbeda dengan sistem pembelajaran konvensional yang mengandalkan motivasi atau kesadaran siswa untuk melakukan kolaborasi, sistem yang diusulkan ini akan secara proaktif memantau kondisi model kompetensi siswa melalui hasil algoritma Elo rating. Ketika terjadi stagnasi dalam perubahan skor, maka sistem akan ”mendorong” aktivitas kolaboratif sebagai response otomatis. Hal ini memperluas cakupan sistem dari sekadar penyaji konten pembelajaran adaptif menjadi fasilitator pembelajaran otonom yang menjamin terjadinya eksposur sosial terhadap keberagaman kompetensi.

IV.2 Model Struktur dan Perilaku (Communication Diagram)

Untuk memodelkan bagaimana komponen internal berkolaborasi dalam menjalankan logika asesmen adaptif, digunakan *Communication Diagram* dengan pendekatan *Boundary-Control-Entity (BCE)*.


Pemilihan pola analisis BCE didasarkan pada kesesuaiannya dalam menjembatani spesifikasi *Use Case* (fungsionalitas) menuju perancangan komponen logis, dengan karakteristik sebagai berikut:

1. **Abstraksi Konseptual:** Berbeda dengan pola arsitektur implementasi seperti MVC (*Model-View-Controller*) yang terikat pada kerangka kerja teknis, BCE berfokus pada peran semantik objek dalam menyelesaikan skenario bisnis tanpa bias teknologi.
2. **Pemisahan Logika Intervensi:** Pola ini secara eksplisit memisahkan objek *Control* (pengendali alur logika) dari *Entity* (data persisten). Hal ini krusial untuk menggambarkan letak algoritma *Re-ranking* dan *Elo rating* yang bertindak sebagai ”otak” sistem, terpisah dari data profil siswa.

Gambar IV.2 memvisualisasikan kolaborasi objek menggunakan pola ini.

Diagram di atas menunjukkan interaksi yang diawali oleh Aktor **Siswa** dan melibatkan kolaborasi tiga jenis objek analisis:

1. **Boundary Object (:LearningInterface):** Objek yang membatasi sistem dengan aktor luar. Bertanggung jawab menangkap pemicu kejadian (*event*) berupa jawaban siswa dan menyajikan umpan balik visual.
2. **Control Objects (:AssessmentController & :ReRankingService):** Objek pengendali yang merepresentasikan logika bisnis dinamis.
 - (a) :AssessmentController mengorkestrasi alur penilaian dan pengecekan kondisi stagnasi.
 - (b) :ReRankingService adalah objek kontrol yang secara spesifik meng-



Gambar IV.2 *Communication Diagram* - Alur Interaksi pada Sistem

enkapsulasi algoritma *Constraint-based Re-ranking* (Biasio dkk. 2023) untuk memproses logika seleksi mitra.

3. **Entity Objects (currentTask & currentUser):** Objek yang merepresentasikan konsep data persisten yang berumur panjang. Objek ini menyimpan **state** penting seperti parameter tingkat kesulitan soal (D_j) serta skor kemahiran siswa yang mencakup dimensi kemampuan individu dan kontribusi sosialnya dalam sistem. Data ini menjadi basis perhitungan utama bagi objek *Control*.

Alur pesan (*Message Flow*) pada diagram menunjukkan bahwa interaksi tidak hanya terjadi antar-modul, melainkan melibatkan manipulasi langsung terhadap objek data (*Entities*). Misalnya, pesan `updateElo()` dikirimkan ke objek `currentUser`, dan pesan `getDifficulty()` diambil dari objek `currentTask`.

Alur pertukaran pesan pada Gambar IV.2 dirancang untuk menangani transisi mulus antara aktivitas pengerjaan tugas individu dan intervensi sosial. Berikut adalah penjelasan rasionalisasi untuk setiap tahapan interaksi:

1. **Inisiasi dan Evaluasi (Pesan 1-4):** Interaksi dimulai ketika aktor *User* mengirimkan jawaban (`submitAnswer`) ke `:LearningInterface`. Antarmuka meneruskan data ke `:AssessmentController`, yang bertindak sebagai koordinator pusat. Kontroller kemudian meminta atribut kesulitan (D_j) dari objek `currentTask` untuk menghitung probabilitas keberhasilan. Setelah perhitungan selesai, kontroller memerintahkan objek `currentUser` untuk memperbarui skor Elo-nya (`updateElo`).
2. **Deteksi Stagnasi (Pesan 5):** Segera setelah pembaruan skor, kontroller mengirim pesan `checkStagnation()` ke objek `currentUser`. Langkah ini diran-

cang untuk mendeteksi fenomena *learning plateau* (Halkiopoulos dan Gkintoni 2024), yaitu kondisi stagnasi kognitif akibat personalisasi berlebihan. Deteksi dilakukan secara algoritmik dengan menghitung nilai variansi dari perubahan skor (*variance of $\Delta\theta$*) pada beberapa aktivitas terakhir. Jika nilai variansi berada di bawah ambang batas (ϵ) tertentu, hal tersebut diinterpretasikan sebagai konvergensi prematur yaitu kondisi yang mengindikasikan tantangan sistem sudah terlalu selaras dengan kemampuan siswa saat ini sehingga tidak lagi mendorong pertumbuhan kognitif.

3. **Delegasi Mitigasi (Pesan 6-7):** Jika status stagnasi bernilai *true*, kontroller tidak menangani pencarian rekan sendiri, melainkan mendelegasikannya ke objek :ReRankingService melalui pesan `findHeterogeneousPeer()`. Pemisahan ini dilakukan untuk mengisolasi logika algoritma *Constraint-based Re-ranking* (Biasio dkk. 2023) yang kompleks. Layanan ini bertanggung jawab menerapkan batasan statistik berdasarkan indeks *Effect Size* (seperti *Cohen's $d \geq 0.5$*) untuk menyaring daftar kandidat rekan, memastikan bahwa rekan yang terpilih memiliki perbedaan tingkat kemampuan yang cukup signifikan untuk memecahkan isolasi kompetensi siswa.
4. **Eksekusi Intervensi (Pesan 8):** Setelah mendapatkan umpan balik yang valid, :AssessmentController akan mengirimkan pesan `showPeerTask()` ke :LearningInterface. Pesan ini secara dinamis mengubah mode tampilan antarmuka dari "mode pengerjaan soal" menjadi "mode penilaian sejawat" beserta rubriknya. Perubahan konteks yang diinisiasi sistem ini memaksa siswa untuk terlibat dalam aktivitas sosial tanpa perlu menavigasi menu secara manual, menjamin terjadinya eksposur terhadap perspektif baru.

IV.3 Perbandingan dengan Sistem Saat Ini

Berdasarkan pemodelan konteks, interaksi, struktur, dan perilaku yang telah diuraikan, Tabel IV.8 merangkum transformasi fundamental dari desain sistem konvensional (*As-Is*) menuju sistem yang diusulkan (*To-Be*).

Tabel IV.8 Perbandingan Desain Sistem *As-Is* vs *To-Be*

Dimensi Kom-parasi	Sistem Saat Ini (As-Is)	Sistem Usulan (To-Be)
Paradigma Interaksi	<i>Sistem pasif:</i> Sistem menunggu inisiatif siswa untuk berkolaborasi. Fitur sosial (forum/diskusi) bersifat opsional dan terpisah dari alur belajar utama.	<i>Sistem proaktif:</i> Sistem secara aktif menginterupsi alur belajar mandiri dengan tugas kolaboratif (<i>mandated intervention</i>) ketika mendeteksi stagnasi, mengubah peran siswa menjadi responden aktif.
Arsitektur Data & Asesmen	<i>Pembaruan satu sumber:</i> Model pengetahuan siswa hanya diperbarui oleh satu sumber data: hasil pengerjaan tugas individu. Aktivitas sosial tidak diquantifikasi menjadi metrik kompetensi.	<i>Siklus pembaruan dua sumber:</i> Model profil siswa diperbarui dari dua jalur: (1) skor tugas individu (dominan), dan (2) kualitas rewiu sejawat. Aktivitas sosial dikonversi menjadi dimensi kontribusi sosial yang menjadi komponen komplementer dalam pemodelan profil siswa yang komprehensif.
Logika Rekomendasi	<i>Heterogenitas opsional:</i> Algoritma cenderung merekomendasikan konten yang "nyaman" (sesuai tingkat kemampuan), berisiko menciptakan <i>competency bubble</i> dan kompetensi semu.	<i>Heterogenitas secara Desain:</i> Algoritma <i>Re-ranking</i> secara eksplisit memaksakan batasan statistik (α) untuk menyuntikkan mitra belajar dengan perbedaan tingkat kemampuan yang signifikan berdasarkan indeks <i>Effect Size</i> (seperti <i>Cohen's d</i>), memecahkan isolasi melalui eksposur diversitas.
Mekanisme Mitigasi Isolasi	<i>Kesadaran manual:</i> Mengandalkan kesadaran metakognitif siswa (misal: lewat grafik OSSM) untuk menyadari bahwa mereka perlu berinteraksi dengan orang lain.	<i>Batasan terautomasi:</i> Menggunakan batasan algoritmik otomatis. Sistem tidak menunggu siswa "sadar", melainkan langsung mengubah antarmuka menjadi mode <i>Peer Assessment</i> saat parameter stagnasi terpenuhi.

BAB V

IMPLEMENTASI MEKANISME MITIGASI DAN IMPLEMENTASI SISTEM

Bab ini menguraikan realisasi dari rancangan sistem yang telah dibahas pada bab sebelumnya. Penjelasan dimulai dari spesifikasi lingkungan pengembangan, persiapan instrumen materi pembelajaran, hingga detail implementasi teknis sisi peladen (*backend*) dan antarmuka (*frontend*).

V.1 Lingkungan Pengembangan Sistem

Realisasi sistem Equilibria membutuhkan infrastruktur yang mendukung proses komputasi asinkron dan isolasi eksekusi kode guna menjamin keamanan data operasional. Sistem ini diimplementasikan menggunakan arsitektur *client-server* modern dengan rincian perangkat lunak sebagai berikut:

1. **Backend:** Menggunakan **FastAPI (Python 3.12)** sebagai *framework* web asinkron utama. Logika numerik didukung oleh pustaka **NumPy**, sementara interaksi basis data dikelola melalui **SQLAlchemy 2.0** sebagai ORM.
2. **Frontend:** Dibangun menggunakan **React.js 18.x** dengan *build tool* **Vite 5.x**. Editor kode SQL menggunakan integrasi **CodeMirror 6.x**.
3. **Basis Data:** Menggunakan **PostgreSQL 15.x** yang dipisahkan secara logis menjadi dua skema: skema `public` untuk data operasional sistem dan skema `sandbox` untuk lingkungan eksekusi *query* SQL siswa.

V.2 Persiapan Materi dan Instrumen Bank Soal

Sebelum melakukan implementasi algoritma, dilakukan penyusunan instrumen materi yang menjadi basis pembelajaran adaptif. Bagian ini merinci struktur kurikulum serta logika penetapan parameter instrumen.

V.2.1 Struktur Kurikulum dan Distribusi Bank Soal

Materi pembelajaran disusun berdasarkan kurikulum mata kuliah **IF2040 - Pemodelan Basis Data** STEI ITB tahun 2024. Materi dibagi ke dalam tiga modul hierarkis: (1) CH01 (*Basic Selection*), (2) CH02 (*Aggregation*), dan (3) CH03 (*Advanced*

Querying).

Setiap modul dilengkapi dengan bank soal berisi **20 butir soal** dengan tingkat kesulitan yang bervariasi, sehingga total keseluruhan materi mencakup **60 butir soal**. Penentuan kuantitas ini merujuk pada temuan Vesin dkk. (2022) yang menyatakan bahwa konvergensi optimal kemahiran siswa dalam sistem adaptif tercapai dalam rata-rata **10 iterasi**. Dengan menyediakan 20 soal per modul, sistem menjamin variasi yang cukup untuk mencegah siswa menghafal jawaban (*answer memorization*) serta memberikan ruang bagi algoritma untuk melakukan kalibrasi ulang terhadap tingkat kesulitan soal secara dinamis. Selain itu, penggunaan total 60 butir soal ini juga sejalan dengan penelitian Hadi, Asriadi, dan Rahim (2022) yang membuktikan bahwa bank soal dengan ukuran tersebut sudah memadai dan andal untuk implementasi sistem asesmen adaptif skala kelas.

V.2.2 Kalkulasi Ambang Batas Transisi Modul

Sistem menerapkan batasan skor Elo untuk mengontrol progres siswa antar modul dengan ambang batas: CH01 (0), CH02 (1300), dan CH03 (1500), basis nilai tengah 1300 diadaptasi dari Vesin dkk. (2022). Penetapan selisih 200 poin antara CH02 dan CH03 didasarkan pada asumsi 10 iterasi sukses untuk mencapai penguasaan modul. Berdasarkan kalkulasi algoritma Elo yang dimodifikasi, estimasi kenaikan skor rata-rata per soal ($\Delta\theta$) dihitung dengan asumsi siswa menjawab benar pada median waktu pengerjaan ($t_i = 0,5d_i$) sebagai berikut:

1. Diketahui parameter diskriminasi waktu $a_i = 10^{-6}$ (diadopsi dari Vesin dkk. (2022)) dan batas waktu $d_i = 300.000\text{ms}$ (dari penelitian Vesin dkk. (2022) juga), maka komponen waktu $a_i(d_i - t_i) = 10^{-6}(300.000 - 150.000) = 0,15$.
2. Nilai keberhasilan dihitung melalui Persamaan II.5 (asumsi pengerjaan benar dalam satu kali percobaan): $W = 1 \times (1 + 0,15) = 1,15$.
3. Dengan $K = 30$ (diambil dari Vesin dkk. (2022) juga) dan $W_e = 0,5$ (saat kemampuan setara kesulitan), maka $\Delta\theta = 30(1,15 - 0,5) = 19,5 \approx 20$.

Dengan kenaikan ≈ 20 poin per soal, maka 10 iterasi sukses akan menghasilkan peningkatan kemahiran sebesar 200 poin, yang menjadi dasar logis perpindahan ke modul berikutnya.

V.2.3 Evaluasi Kualitas Umpan Balik Berbasis NLP

Penilaian pada aktivitas kolaboratif (*Social Elo*) diimplementasikan melalui modul evaluasi teks otomatis yang menguantifikasi kualitas umpan balik dari siswa sebagai *reviewer*. Sistem menggunakan model *embedding* bahasa alami untuk menilai kedalaman semantik dan relevansi komentar siswa:

1. **Model Bahasa Multilingual MiniLM:** Sistem memanfaatkan model *paraphrase-multilingual-MiniLM-L12-v2* untuk merepresentasikan teks umpan balik ke dalam vektor dimensi tinggi (*Word-Level Semantic Max*). Penggunaan model ini merupakan titik keseimbangan (*sweet spot*) desain arsitektur yang ideal; pendekatan pencocokan kata kunci (*keyword matching*) terbukti terlalu kaku untuk mengidentifikasi frasa dengan makna yang mirip, sementara pengerahan model *Deep Learning* skala besar (seperti LLM penuh) akan sangat memboroskan sumber daya komputasi peladen untuk sebuah modul yang bukan merupakan fungsionalitas utama sistem.
2. **Inferensi Efisien dengan FastEmbed:** Untuk merealisasikan komputasi yang ringan, proses *embedding* dijalankan menggunakan pustaka **FastEmbed**. Hal ini memungkinkan kalkulasi kemiripan semantik terhadap jangkak domain (*domain relevance anchor*) dilakukan langsung secara lokal di sisi peladen (*CPU-optimized inference*) tanpa membebani memori dan tanpa ketergantungan pada API eksternal berbayar.
3. **Kalkulasi Skor dan Social Elo:** Luaran dari analisis semantik dikonversi menjadi nilai probabilitas $[0, 1]$ yang merepresentasikan tingkat kualitas umpan balik. Nilai ini kemudian digunakan sebagai input bagi algoritma *Social Elo* untuk memperbarui rating kontribusi sosial siswa terhadap standar netral (0,5), sesuai dengan kerangka teoretis yang diusulkan dalam spesifikasi teknis v4.3.

V.3 Implementasi Teknis *Backend*

Bagian ini membahas detail implementasi sisi peladen yang bertanggung jawab atas seluruh logika adaptivitas dan keamanan sistem.

V.3.1 Arsitektur API dan Standardisasi

Implementasi *backend* dibangun menggunakan *framework* **FastAPI** yang mendukung operasi *asynchronous I/O* secara *non-blocking*, yang krusial untuk menangani permintaan eksekusi *query* SQL dan kalkulasi Elo secara simultan. Arsitektur ini mengadopsi beberapa standar industri:

1. **Modularitas Router:** Logika API dipecah ke dalam beberapa modul `APIRouter` (seperti `auth.py`, `session.py`, `collaboration.py`) untuk memisahkan domain tanggung jawab. Setiap *endpoint* dilengkapi dengan skema validasi data menggunakan **Pydantic V2**, yang menjamin tipe data yang masuk ke sistem selalu konsisten dengan kontrak API.
2. **Standardisasi JSend:** Untuk mempermudah penanganan *error* pada sisi *front-end*, sistem menggunakan format respons JSend yang terdiri dari:

- **status:** Berupa *success* (2xx) artinya permintaan diterima dan server berhasil menemukan sumber daya yang diminta, *fail* (4xx) artinya permintaan gagal karena kesalahan pengguna, atau *error* (5xx) artinya terjadi kesalahan internal server.
 - **code:** Kode status HTTP spesifik untuk semantik logika aplikasi.
 - **data:** *Payload* utama yang dikirimkan kepada pengguna.
 - **message:** Pesan deskriptif jika terjadi kegagalan sistem.
3. **Keamanan dan Autentikasi:** Setiap permintaan ke *endpoint* sensitif diwajibkan menyertakan **JSON Web Token (JWT)** pada *header* otorisasi. Sistem menerapkan *dependency injection* pada FastAPI (`get_current_user`) untuk mendekripsi token HS256 dan memvalidasi identitas pengguna sebelum mengeksekusi logika bisnis. Hal ini memastikan bahwa model kompetensi seorang siswa tidak dapat dimanipulasi oleh pengguna lain secara tidak sah.

V.3.2 Mesin Elo dan Deteksi Stagnasi

Inti logika sistem berada pada modul `elo_engine.py`. Modul ini mengelola dua aspek utama:

1. **Siklus Pembaruan Skor dan Evaluasi Parsial:** Pembaruan rating dilakukan satu kali setiap kali siswa menyelesaikan atau beralih dari suatu soal (*event next*). Mekanisme ***multi-attempt*** (maksimal 3 upaya) ini diimplementasikan secara spesifik untuk memfasilitasi rumus keberhasilan (*success rate*) usulan Vesin dkk. (2022), yang menghitung rasio upaya yang berhasil terhadap total upaya (A_s/A_o). Pembatasan maksimal tiga upaya diterapkan untuk mencegah proses tebak-tebakan (*trial-and-error*) berlebihan yang dapat mendistorsi pemodelan kemahiran siswa.

Selain itu, terdapat penyesuaian pada parameter pengujian (*test ratio*). Pada sistem ProTuS asli yang berfokus pada bahasa pemrograman prosedural (seperti Java), keberhasilan dapat diukur secara parsial melalui persentase *unit test* yang lolos (T_c/T_p). Namun, sebagaimana diuraikan pada Subbab II.9, dalam konteks *query* SQL penilaian parsial secara praktis jauh lebih sulit untuk diimplementasikan. Mengevaluasi ekuivalensi semantik *query* hanya karena strukturnya hampir benar (misal: klausa SELECT benar namun WHERE salah) membutuhkan analisis Pohon Sintaksis Abstrak (*Abstract Syntax Tree*) yang amat kompleks dan secara komputasional tergolong permasalahan NP-Hard (Silberschatz, Korth, dan Sudarshan March 2019). Oleh karena itu, sistem Equilibria mengadaptasi dan menyederhanakan rasio T_c/T_p menjadi evaluasi biner (0 jika himpunan luaran berbeda, 1 jika luaran tabel identik sepenuhnya).

dengan *sandbox*). Ketiadaan gradasi nilai dari *unit test* ini kemudian dikompensasi secara proporsional oleh penggunaan rasio multi-upaya (A_s/A_o) tadi, sehingga kalibrasi Elo tetap memiliki gradasi skor (1, 0; 0, 5; atau 0, 33) yang akurat dan berkeadilan.

2. **Kalkulasi Numerik Stagnasi:** Deteksi stagnasi dihitung berdasarkan variansi populasi dari perubahan skor ($\Delta\theta$) pada jendela lima aktivitas terakhir. Berdasarkan kalibrasi empiris pada spesifikasi sistem, ambang batas variansi yang digunakan adalah $\epsilon = 165$. Nilai ini dipilih sebagai titik tengah antara dua skenario perhitungan $\Delta\theta = K \times (W - W_e)$ dengan $K = 30$:

- **Batas Bawah (Stagnasi Konvergen):** Saat kemampuan siswa konvergen atau terjebak dalam *plateau* (probabilitas ekspektasi $W_e \approx 0,5$ dan pengerjaan berfluktuasi tipis), nilai $\Delta\theta$ bergerak pada rentang kecil (sekitar ± 6). Rangkaian simulasi konvergensi prematur seperti $\Delta\theta = [-6, +6, -4, +5, -3]$ menghasilkan variansi $\sigma^2 \approx 25$.
- **Batas Atas (Fluktuasi Normal):** Saat siswa masih dalam fase pertumbuhan dan pembelajaran (skor berfluktuasi signifikan, misal $\Delta\theta$ mencapai $+27$ jika cepat dan benar, atau -18 jika salah semua), rangkaian simulasi fluktuasi normal seperti $\Delta\theta = [+27, -18, +15, -12, +20]$ menghasilkan variansi $\sigma^2 \approx 310$.

Dengan menetapkan ambang batas median di angka 165, deteksi dapat dilakukan secara cukup sensitif tanpa salah menafsirkan fluktuasi normal sebagai stagnasi. Selain itu, diterapkan pula mekanisme *fallback* (cadangan) berupa rasio jawaban salah $> 50\%$ dari $N = 9$ soal terakhir untuk mencegah pengguna Grup A terjebak tanpa intervensi. Pemilihan angka 9 didasarkan pada temuan Vesin dkk. (2022) bahwa konvergensi terjadi pada rentang 7–10 iterasi, dengan titik tengah 8,5 yang dibulatkan menjadi 9. Pertimbangan rasio $> 50\%$ adalah karena ketika siswa sudah seharusnya konvergen namun masih mayoritas salah, hal tersebut mengindikasikan terjadinya *overpersonalization*. Pseudocode untuk kedua fungsi ini disajikan pada Kode V.1.

Listing V.1 Algoritma Deteksi Stagnasi dan Fallback

```

1 function DetectStagnation (UserID : string, ModuleID : string
    , DB : Database) -> boolean
2 { Mengirimkan true jika stagnasi terdeteksi (variansi < 165),
    false jika tidak }
3
4 KAMUS LOKAL
5 Last5Logs : List of AssessmentLog
6 Deltas : List of float
7 Variance : float

```

```

8
9 ALGORITMA
10 if (ModuleID = "CH03") then { Konvergensi di modul akhir
    bukan stagnasi }
11     -> false
12 else
13     Last5Logs <- GetLastFinalAttempts(DB, UserID, 5)
14     if (NBEltlist(Last5Logs) < 5) then
15         -> false
16     else
17         Deltas <- CalculateThetaDeltas(Last5Logs)
18         Variance <- CalculatePopulationVariance(Deltas)
19         -> (Variance < 165)
20
21
22 function CheckFallbackTrigger (GroupID : char, ModuleID :
    string, IsNextUnlocked : boolean, RecentLogs : List of
    AssessmentLog) -> boolean
23 { Mengirimkan true jika > 4 jawaban salah dari 9 attempt
    terakhir }
24
25 KAMUS LOKAL
26 WrongCount : integer
27 Log : AssessmentLog
28
29 ALGORITMA
30 if (GroupID != 'A' or ModuleID = "CH03" or IsNextUnlocked =
    true) then
31     -> false
32 else
33     if (NBEltlist(RecentLogs) < 9) then
34         -> false
35     else
36         WrongCount <- 0
37         Log <- FirstElmt(RecentLogs)
38         while (Log != Nil) do
39             if (not IsCorrect(Log)) then
40                 WrongCount <- WrongCount + 1
41                 Log <- Next(Log)
42         -> (WrongCount > 4)

```

3. **Integrasi Skor Kemahiran (*Theta Display*):** Sistem menghitung skor akhir yang digunakan untuk pemeringkatan secara *on-the-fly*. Skema pembobotan ini mengadopsi rasio 80:20 (Demetroulis dkk. 2024) yang bertujuan untuk menjaga dominasi kompetensi individual sekaligus memberikan pengakuan

terhadap kontribusi sosial (lihat Subbab II.4.5).

V.3.3 Mekanisme Perekaman Data Trajektori (*Data Logging*)

Analisis pergerakan momentum kemahiran siswa (*slope* $\Delta\theta$) sangat bergantung pada data *time-series* yang direkam secara presisi. Oleh karena itu, sistem diimplementasikan untuk melakukan *logging* secara komprehensif pada modul `session.py` setiap kali titik akhir (*endpoint*) API `/next` dipanggil. Kode V.2 mengilustrasikan logika perekaman data tersebut, yang menyimpan status kemahiran sebelum dan sesudah pengerjaan beserta status deteksi stagnasi.

Listing V.2 Algoritma Perekaman Data Trajektori

```
1 procedure LogTrajectory (input SessionID : string, input UserID :  
    string, input QuestionID : string, input IsCorrect : boolean,  
    input DB : Database)  
2 { I.S. Sesi aktif dan pengguna meminta soal berikutnya melalui  
    endpoint /next }  
3 { F.S. Data perubahan Elo dan status stagnasi tersimpan di basis  
    data }  
4  
5 KAMUS LOKAL  
6 ThetaBefore, ThetaAfter : float  
7 StagnationDetected : boolean  
8 NewLog : AssessmentLog  
9  
10 ALGORITMA  
11 ThetaBefore <- GetCurrentTheta(DB, UserID)  
12  
13 { Perbarui skor Elo berdasarkan jawaban }  
14 ThetaAfter <- UpdateEloRating(ThetaBefore, QuestionID, IsCorrect)  
15  
16 { Deteksi stagnasi setelah skor diperbarui }  
17 StagnationDetected <- DetectStagnation(UserID, CurrentModule, DB)  
18  
19 { Rekam ke basis data }  
20 NewLog.SessionID <- SessionID  
21 NewLog.UserID <- UserID  
22 NewLog.QuestionID <- QuestionID  
23 NewLog.IsFinalAttempt <- true  
24 NewLog.ThetaBefore <- ThetaBefore  
25 NewLog.ThetaAfter <- ThetaAfter  
26 NewLog.StagnationDetected <- StagnationDetected  
27  
28 InsertToDB(DB, NewLog)
```

V.3.4 Keamanan Eksekusi dan *Sandbox SQL*

Keamanan eksekusi merupakan aspek paling krusial karena sistem mengizinkan input kode mentah dari pengguna. Implementasi keamanan dilakukan melalui strategi multi-lapis untuk mencegah serangan *SQL Injection* maupun akses data ilegal:

1. **Isolasi Skema dan Data:** Sistem memisahkan skema *sandbox* yang berisi tabel-tabel simulasi (seperti *student*, *course*, *instructor*) dari skema operasional *public*. Data pada skema *sandbox* bersifat statis dan tidak mengandung informasi sensitif pengguna.
2. **Principle of Least Privilege:** Eksekusi *query* dilakukan menggunakan akun basis data khusus (*sandbox_executor*) yang hak aksesnya dibatasi secara ketat melalui perintah *REVOKE ALL* pada skema *public* dan hanya diberikan izin *SELECT* pada skema *sandbox*. Hal ini memastikan bahwa meskipun filter keamanan pada aplikasi berhasil ditembus, basis data tetap terlindungi dari operasi destruktif.
3. **Sanitasi Query dan Blocklist:** Sebelum dikirim ke *database engine*, modul *sandbox_executor.py* melakukan pemindaian *case-insensitive* terhadap kata kunci manipulatif. Selain perintah DDL/DML dasar (*DROP*, *UPDATE*, *DELETE*, *TRUNCATE*, *ALTER*), sistem juga memblokir kata kunci administratif seperti *GRANT*, *REVOKE*, *PG_* (untuk mencegah akses ke metadata PostgreSQL), serta karakter komentar SQL (*--*) yang sering digunakan untuk menyembunyikan serangan.
4. **Kontrol Sumber Daya (Resource Limiting):** Untuk mencegah serangan *Denial of Service* (DoS) melalui *query* yang sengaja dibuat berat (*intensive*), sistem menerapkan *statement_timeout* sebesar 5000 ms. Selain itu, luaran eksekusi dibatasi hanya pada sejumlah baris tertentu guna menjaga stabilitas memori pada sisi peladen.

V.4 Implementasi Teknis *Frontend*

Implementasi sisi klien berfokus pada penyajian antarmuka yang reaktif dan informatif untuk mendukung alur belajar adaptif secara *real-time*. Bagian ini merinci arsitektur perangkat lunak sisi klien, manajemen *state*, serta detail komponen antarmuka yang digunakan dalam sistem.

V.4.1 Arsitektur Perangkat Lunak dan Antarmuka

Frontend dibangun menggunakan **React 18** dengan *build tool* **Vite** untuk menjamin performa pengembangan yang optimal. Desain antarmuka mengadopsi pendekatan modern menggunakan **Tailwind CSS** untuk penataan gaya yang efisien dan komponen dari **Shadcn UI**. Penggunaan komponen berbasis **Radix UI** ini memastikan

aksesibilitas dan konsistensi visual di seluruh aplikasi. Sistem juga menggunakan **Lucide React** untuk ikonografi yang konsisten dan **Framer Motion** untuk memberikan umpan balik visual melalui animasi transisi antar modul pengerjaan.

V.4.2 Manajemen *State* Global dengan Zustand

Sistem menggunakan **Zustand** sebagai solusi manajemen *state* global yang modular. Pendekatan ini memisahkan logika aplikasi ke dalam beberapa *store* khusus:

1. **Auth Store** (`authStore.ts`): Mengelola status autentikasi pengguna, penyimpanan profil (*theta_individu*, *theta_sosial*), serta persistensi token JWT.
2. **Session Store** (`sessionStore.ts`): Mengelola siklus hidup sesi aktif, termasuk pelacakan progres soal, jumlah upaya (*attempts*), dan status pengerjaan siswa.

V.4.3 Editor Kode dan Eksekusi Query

Antarmuka pengerjaan soal mengintegrasikan **CodeMirror 6** sebagai komponen editor kode SQL utama. Editor ini dikonfigurasi dengan fitur *syntax highlighting* PostgreSQL dan *autocomplete* untuk membantu siswa dalam menyusun *query*. Siswa berinteraksi dengan editor untuk menulis solusi, yang kemudian dikirim ke *backend* untuk dieksekusi pada skema *sandbox*.

V.4.4 Visualisasi Kemahiran dan Umpan Balik Pengerjaan

Sistem memberikan umpan balik instan kepada siswa tanpa menggunakan pustaka grafik eksternal, melainkan melalui komponen kustom yang dioptimalkan:

1. **Indikator Kemahiran (*Theta Progress*)**: Progres kemahiran siswa divisualisasikan menggunakan *progress bar* berbasis CSS yang memetakan nilai *theta* dalam rentang $[1000, 1800]$. Hal ini memberikan indikasi langsung mengenai pertumbuhan kompetensi siswa tanpa beban komputasi grafik yang berat.
2. **Umpan Balik Hasil Query**: Melalui komponen `QueryResultDisplay`, sistem menampilkan hasil eksekusi SQL siswa secara detail. Jika jawaban benar, sistem menampilkan tabel hasil data; jika salah, sistem menyajikan pesan kesalahan atau perbandingan luaran untuk membantu siswa melakukan perbaikan pada percobaan berikutnya.
3. **Papan Peringkat (*Leaderboard*)**: Halaman papan peringkat menyajikan urutan siswa berdasarkan nilai *theta_display*. Nilai ini dihitung secara *on-the-fly* menggunakan skema pembobotan terintegrasi: $(0,8 \times \theta_{individu}) + (0,2 \times \theta_{sosial})$. Pembobotan ini merujuk pada justifikasi teoretis bahwa kontribusi individu harus tetap dominan dalam penilaian agar tetap mencerminkan kemahiran personal (Demetroulis dkk. 2024) (lihat Subbab II.4.5). Fitur ini

dirancang untuk memberikan motivasi belajar melalui perbandingan prestasi antar rekan sejawat dalam lingkungan yang teranonimisasi.

V.4.5 Routing dan Keamanan Sisi Klien

Sistem routing dikelola menggunakan **React Router 6** dengan mekanisme perlindungan rute:

- **ProtectedRoute**: Membatasi akses ke fitur inti hanya bagi pengguna yang telah terautentikasi.
- **PretestGate**: Memastikan setiap pengguna baru menyelesaikan sesi *pre-test* sebelum dapat mengakses modul pembelajaran utama, guna menjamin akurasi kalibrasi awal sistem.

V.5 Integrasi dan Deployment

Seluruh komponen sistem disatukan dalam ekosistem kontainer menggunakan **Docker Compose** untuk menjamin konsistensi lingkungan. Purwarupa dideploy menggunakan layanan **Railway** dengan strategi *Continuous Deployment* dari repositori GitHub. Penggunaan paket *Hobby Railway* (5 USD) dipilih untuk menjamin ketersediaan layanan selama jam sibuk pengujian tanpa hambatan batasan waktu *deployment* yang ada pada paket gratis.

BAB VI

EVALUASI DAN PEMBAHASAN

Bab ini menyajikan hasil dari pengujian sistem Equilibria melalui studi laboratorium terkontrol (*Controlled Lab Study*) dan analisis kesesuaian pelaksanaan proyek. Evaluasi dilakukan untuk mengukur efektivitas sistem dalam meningkatkan hasil belajar siswa serta kemampuannya dalam memitigasi efek *overpersonalization*.

VI.1 Analisis Kesesuaian Pelaksanaan

Bagian ini mengevaluasi pelaksanaan proyek dari perspektif manajemen waktu dan anggaran, membandingkan antara rencana awal dengan realisasi aktual selama proses pengembangan sistem.

VI.1.1 Kesesuaian Linimasa Pelaksanaan

Realisasi pengembangan sistem secara umum mengalami keterlambatan satu bulan dibandingkan rencana awal. Tahap pengujian (*Controlled Lab Study*) baru dapat dilaksanakan pada minggu pertama Mei 2026. Realisasi jadwal pelaksanaan aktual disajikan pada Gambar VI.1 dengan sel berwarna abu-abu menunjukkan alokasi waktu awal dan sel berwarna merah, kuning, dan biru menunjukkan realisasi aktual waktu pengerjaan setiap fase.

ID	Aktivitas	Januari				Februari				Maret				April				Mei			
		W1	W2	W3	W4	W1	W2	W3	W4	W1	W2	W3	W4	W1	W2	W3	W4	W1	W2	W3	W4
1	FASE PENGEMBANGAN BACKEND																				
1a	Perancangan skema basis data																				
1b	Implementasi algoritma elo-rating																				
1c	Pengembangan layanan re-ranking																				
2	FASE PENGEMBANGAN FRONTEND & INTEGRASI																				
2a	Pengembangan antarmuka (rubrik dan soal)																				
2b	Integrasi API																				
2c	Input bank soal & kalibrasi kesulitan																				
3	FASE PENGUJIAN & ANALISIS																				
3a	Peluncuran ke Cloud & Uji Fungsional																				
3b	Pelaksanaan Controlled Lab Study (uji pengguna)																				
3c	Evaluasi Kualitas Feedback (Multi-LLM)																				
3d	Analisis Data																				

Gambar VI.1 Gantt Chart Realisasi Pelaksanaan Implementasi dan Pengujian

VI.1.2 Kesesuaian Anggaran Biaya

Realisasi biaya operasional sistem disajikan pada Tabel VI.1. Terjadi efisiensi biaya pada komponen LLM yang tidak digunakan, namun terdapat pengeluaran untuk konsolidasi infrastruktur *cloud* guna menjaga kelancaran pengembangan.

Tabel VI.1 Realisasi Anggaran Biaya Implementasi

No	Komponen	Spesifikasi/Layanan	Biaya (Rp)
1	<i>Consolidated Hosting</i>	Railway (<i>Hobby Tier</i>)	Rp 80.000
2	<i>Domain</i>	Subdomain Provider	Rp 0
3	Layanan LLM	Tidak digunakan	Rp 0
4	Perangkat & Internet	Aset Pribadi / <i>Sunk Cost</i>	Rp 0
Total Biaya Aktual			Rp 80.000

VI.2 Prosedur Pengujian Laboratorium (*Lab Study*)

Pengujian dilakukan menggunakan metode *Ablation Study Two-Group Pretest Post-test* yang dimodifikasi, dengan pembagian peserta ke dalam Grup A (dengan intervensi kolaboratif) dan Grup B (tanpa intervensi/kontrol). Partisipan terdiri dari 10 mahasiswa yang telah menyelesaikan mata kuliah pemodelan basis data program studi Sistem dan Teknologi Informasi ITB (IF2040), yang kemudian dibagi menjadi dua kelompok. Sesi pengujian berlangsung selama kurang lebih 105 menit yang mencakup tahap *pre-test* untuk kalibrasi awal, interaksi sistem (75 menit), dan tahap akhir untuk pengumpulan umpan balik kualitatif. Berbeda dengan metode klasik, pengujian ini tidak melaksanakan ujian *post-test* secara terpisah, melainkan metrik *post-test* diwakili (diproksi) oleh nilai kemahiran akhir (*final individual theta*) yang dicapai pengguna pada sistem di penghujung sesi interaksi.

VI.3 Hasil dan Analisis Peningkatan Hasil Belajar

Efektivitas pembelajaran diukur menggunakan metrik *Normalized Learning Gain* (NLG) untuk membandingkan peningkatan pengetahuan antara Grup A dan Grup B secara objektif.

VI.3.1 Uji Kesetaraan Awal (*Baseline Equivalence*)

Sebelum mengukur peningkatan hasil belajar, perlu dipastikan bahwa kedua kelompok partisipan memulai pengujian dari titik kemampuan yang setara. Hal ini penting untuk menjamin validitas eksperimen *Two-Group*. Analisis kesetaraan awal dilakukan menggunakan *Mann-Whitney U Test* terhadap nilai praktikum (sebagai representasi kemampuan historis) dan skor *pre-test* (sebagai representasi kemampuan awal pada sistem).

Berdasarkan pengolahan data menggunakan uji statistik non-parametrik *Mann-Whi-*

tney U Test, diperoleh hasil yang menunjukkan tidak adanya perbedaan yang signifikan antara kedua kelompok sebelum intervensi diberikan. Pada metrik nilai praktikum historis, rata-rata Grup A adalah 47,67 dan Grup B adalah 45,96, dengan nilai $p\text{-value} = 0,7619$ ($p > 0,05$). Serupa dengan hal tersebut, pada skor *pre-test* di dalam sistem, rata-rata kemahiran awal Grup A berada pada angka 1313,33 dan Grup B pada angka 1300,00, dengan nilai $p\text{-value} = 0,9062$ ($p > 0,05$). Hasil ini membuktikan bahwa Grup A dan Grup B memulai pengujian dari titik kemahiran yang setara secara statistik, sehingga asumsi ekuivalensi dasar pada metode *Two-Group* terpenuhi. Hal ini menjamin bahwa perbedaan peningkatan performa (*gain*) di akhir sesi dapat diatribusikan secara valid pada efek keberadaan intervensi kolaboratif.

VI.3.2 Perbandingan Skor Pre-test dan Post-test

Mengingat asesmen dilakukan secara terintegrasi, skor *pre-test* dan proksi *post-test* direpresentasikan menggunakan skala *Elo rating* (θ). Untuk menghitung metrik NLG menggunakan skala ini, digunakan dua pendekatan batas maksimum:

1. **Teoretis:** Menggunakan nilai *Elo* maksimal sebesar 1500 (berdasarkan rentang kesulitan sistem pada studi Vesin dkk. (2022)).
2. **Empiris:** Menggunakan nilai *Elo* tertinggi yang secara empiris dicapai oleh peserta selama pengujian sebagai batas maksimum.

Tabel VI.2 menyajikan rekapitulasi skor rata-rata berdasarkan skala *Elo* tersebut, beserta nilai NLG teoretis dan empirisnya.

Tabel VI.2 Perbandingan Skor Rata-rata Pre-test dan Post-test

Kelompok	Rata-rata Pre-test	Rata-rata Post-test	NLG Teoretis	NLG Empiris
Grup A (Intervensi)	1313,33	1445,08	0,69	0,57
Grup B (Kontrol)	1300,00	1236,59	-0,21	-0,19

VI.3.3 Analisis Signifikansi Peningkatan (NLG)

Berdasarkan Tabel VI.2, terlihat bahwa Grup A mengalami peningkatan hasil belajar yang sangat positif, dengan nilai NLG Teoretis sebesar 0,69 dan NLG Empiris sebesar 0,57. Merujuk pada kriteria interpretasi Hake, nilai ini tergolong ke dalam kategori peningkatan sedang hingga tinggi (*medium to high gain*). Sebaliknya, Grup B justru mengalami penurunan performa dengan nilai NLG Teoretis $-0,21$ dan Empiris $-0,19$. Penurunan skor pada grup kontrol ini secara empiris mengindikasikan terjadinya kelelahan kognitif (*cognitive fatigue*) atau demotivasi akibat terjebak berulang kali dalam soal-soal sulit (*stagnasi*) tanpa adanya bantuan eksternal.


Untuk menguji signifikansi perbedaan metrik tersebut, dilakukan analisis statistik menggunakan *Mann-Whitney U Test*. Hasil pengujian menunjukkan bahwa nilai *p*-value untuk distribusi skor NLG adalah 0,0095. Karena nilai $p < 0,05$, maka Hipotesis Nol (H_0) ditolak. Dapat disimpulkan secara meyakinkan bahwa keberadaan intervensi kolaboratif memberikan dampak yang positif dan signifikan secara statistik terhadap peningkatan hasil belajar siswa dibandingkan dengan kelompok yang hanya belajar mandiri.

VI.4 Hasil dan Analisis Efektivitas Mitigasi *Overpersonalization*

Analisis ini berfokus pada kemampuan sistem dalam mendeteksi stagnasi dan mengembalikan momentum pertumbuhan kemahiran siswa melalui intervensi kolaboratif.

VI.4.1 Analisis Perubahan Kemahiran (*Slope $\Delta\theta$*)

Evaluasi dilakukan dengan membandingkan gradien (*slope*) perubahan skor Elo sebelum dan sesudah intervensi pada titik stagnasi terdeteksi.



Gambar VI.2 Visualisasi Perubahan Momentum Belajar Sebelum dan Sesudah Titik Pertama Stagnasi

Berdasarkan visualisasi pada Gambar VI.2, terlihat adanya perubahan tren pergerakan kemahiran (*trajectory*) antara fase sebelum (*pre*) dan sesudah (*post*) titik stagnasi. Temuan ini dikonfirmasi oleh fakta statistik bahwa rerata gradien tren kemahiran (*slope post-intervention*) pengguna Grup A secara konsisten kembali naik dengan rata-rata perbedaan gradien positif sebesar +0,67 setelah titik stagnasi. Di sisi lain, meskipun secara matematis Grup B mencatatkan rata-rata perbedaan gradien akhir yang juga positif (+1,01), nilai tersebut bersifat semu karena memiliki simpangan baku yang sangat besar ($SD = 2,47$). Pemeriksaan data individual menunjukkan bahwa angka ini terdistorsi oleh satu partisipan pencilon (*outlier*) yang mengalami lonjakan ekstrem, sedangkan mayoritas partisipan Grup B lainnya mencatatkan per-

tumbuhan yang nyaris datar (mendekati nol). Distribusi peningkatan Grup A yang jauh lebih merata ($SD = 0,68$), menunjukkan indikasi positif terkait efektivitas intervensi dalam mengembalikan momentum belajar yang konsisten dan lebih merata bagi seluruh populasi kelompok yang sebelumnya mengalami stagnasi.

VI.4.2 Validitas Pemicuan Stagnasi (*Trigger Rate*)

Mekanisme deteksi stagnasi yang menggunakan ambang batas variansi $\epsilon = 165$ pada awalnya dirancang untuk mendeteksi pola *learning plateau*. Berdasarkan data log pengujian, tingkat keberhasilan pemicuan mencapai 100%, artinya seluruh pengguna di Grup A berhasil memicu mekanisme kolaboratif ini (dengan rata-rata 15 kejadian stagnasi per pengguna). Hal ini secara nominal melampaui target awal pelaksanaan pengujian yang mengharapkan setidaknya 50% pengguna mendapatkan kesempatan intervensi. Namun, tingginya angka pemicuan ini mengekspos sebuah kelemahan desain sistem yaitu, parameter variansi yang ditetapkan ternyata terlalu sensitif (*hypersensitive*). Sebagai gambaran ekstrem, rata-rata 30 kejadian stagnasi (seperti yang dicatat oleh data internal sistem untuk pengguna Grup B) dalam rentang pengujian yang hanya berisi sekitar 60 aktivitas pengerjaan soal mengimplikasikan bahwa sistem mendeteksi stagnasi belajar hampir di setiap dua soal. Secara pedagogis, frekuensi interupsi seketat ini kurang masuk akal karena fluktuasi kognitif minor atau jeda berpikir normal pengguna rentan tertafsirkan sebagai stagnasi akut.

Meskipun algoritma utamanya terbukti terlalu sensitif, kombinasi dengan pemicu cadangan (*fallback trigger* pada $N = 9$ aktivitas terakhir) tetap memberikan jaring pengaman (*safety net*) komprehensif. Secara konseptual, keberadaan *fallback trigger* memastikan bahwa pengguna dengan profil skor yang sangat fluktuatif ke arah bawah akibat perilaku menebak asal, yang secara matematis luput dari deteksi *variance* konvergen, tetap terjamin mendapatkan intervensi. Berdasarkan analisis *syslogs* sistem, pemicu cadangan ini sebenarnya tidak pernah aktif selama sesi pengujian karena seluruh kejadian stagnasi telah tercakup oleh algoritma variansi yang hipersensitif. Namun demikian, keberadaan mekanisme gabungan ini secara aktual terbukti berhasil memecah isolasi pembelajaran tanpa ada satu pun siswa Grup A yang luput dari pantauan sistem.

VI.5 Hasil dan Analisis Komponen Kolaboratif

Bagian ini mengevaluasi kualitas interaksi sosial yang terjadi dalam sistem serta validitas algoritma *Social Elo* dan mekanisme *Re-ranking*.

VI.5.1 Validitas Algoritma *Constraint-based Re-ranking*

Algoritma *Re-ranking* dirancang untuk secara spesifik memastikan bahwa pengguna yang sedang mengalami stagnasi tidak dipasangkan dengan sejawat yang memiliki tingkat kompetensi identik, guna memastikan terjadinya transfer pengetahuan yang bermakna. Berdasarkan ekstraksi data *syslogs* sistem terkait kejadian (*events*) pembuatan sesi kolaboratif, tercatat 10 kali pemicuan pencarian sejawat heterogen (*find_heterogeneous_peer*) yang berhasil.

Data log menunjukkan bahwa perbedaan kemahiran absolut (*theta difference*) antara peminta (*requester*) dan peninjau (*reviewer*) memiliki rata-rata sebesar 112,56 poin Elo. Lebih penting lagi, validasi terhadap indeks *Effect Size* menunjukkan bahwa seluruh pasangan menghasilkan nilai *Cohen's d* di atas batas minimal desain ($d \geq 0,5$), dengan nilai terendah $d = 0,61$ dan rata-rata keseluruhan mencapai $d = 1,186$ (kategori efek sangat besar). Metrik ini mengonfirmasi bahwa algoritma sistem telah berfungsi dengan tepat dan sesuai dengan kerangka teoretis, yakni berhasil mencegah isolasi kompetensi dengan menyajikan keberagaman sudut pandang dari sejawat yang memiliki perbedaan pemahaman yang signifikan secara statistik.

VI.5.2 Kualitas Umpan Balik Sejawat (*Peer Feedback Quality*)

Kualitas umpan balik dievaluasi berdasarkan skor yang dihasilkan oleh mesin NLP (*system_score*) dan penilaian subjektif penerima (*is_helpful*).

Tabel VI.3 Statistik Kualitas Umpan Balik Kolaboratif

Metrik	Nilai Rata-rata
Skor Sistem (NLP)	0,404
Tingkat Kebergunaan (<i>Helpfulness Rate</i>)	100%

Berdasarkan Tabel VI.3, terdapat perbedaan yang cukup mencolok antara skor otomatis dari sistem (0,404) dengan tingkat kebergunaan subjektif menurut pengguna (100%). Rendahnya skor NLP ini merupakan indikasi adanya keterbatasan model *multilingual MiniLM* dalam menangani dialek teknis bahasa Indonesia informal yang digunakan partisipan saat memberikan ulasan. Meskipun demikian, validitas kualitas interaksi tetap terjaga karena sistem menggunakan mekanisme konfirmasi biner (*thumbs up/down*) dari penerima umpan balik sebagai metrik kualitas utama yang lebih merepresentasikan kebergunaan riil di lapangan.

VI.5.3 Konvergensi *Social Elo*

Perhitungan skor Elo Sosial pada sistem terbukti mampu menguantifikasi kualitas umpan balik sejawat. Dengan mengandalkan perhitungan NLP yang divalidasi oleh

penerima ulasan, nilai θ_{social} untuk setiap pengguna berubah secara dinamis. Rata-rata persentase *thumbs up* yang menyentuh angka absolut 100% mengindikasikan bahwa responden sangat menghargai bantuan dari sejawatnya. Meskipun demikian, dijumpai suatu fenomena keterbatasan dalam durasi pengujian singkat ini (75 menit), yaitu skala θ_{social} pada beberapa pengguna belum mencapai konvergensi yang matang sehingga pemanfaatannya dalam porsi bobot $\theta_{display}$ (sebesar 20%) belum sepenuhnya terlihat memisahkan rentang pemeringkatan antar siswa dengan jelas. Pada implementasi skala riilnya nanti, fitur ini akan memerlukan partisipasi jangka panjang agar model pemeringkat kolaboratifnya lebih matang dan stabil.

VI.6 Pembahasan Umum dan Ancaman terhadap Validitas

Analisis dari hasil pengujian menegaskan satu hal penting: membiarkan siswa belajar secara terisolasi dengan sistem asesmen adaptif konvensional menyimpan risiko *overpersonalization* berupa isolasi akademik (*filter bubble*). Ketika siswa berulang kali dihadapkan pada materi yang dinilai "sesuai" namun sesungguhnya memicu stagnasi karena mereka tidak kunjung mampu memecahkan masalah, sistem yang pasif hanya akan mencatat penurunan skor tanpa memberikan jalan keluar. Sebagaimana yang ditunjukkan oleh tren penurunan gradien elo-rating pada Grup B, isolasi ini menyebabkan frustrasi dan mematikan momentum pertumbuhan belajar siswa. Fenomena empiris ini sejalan dengan kerangka teoretis yang diajukan oleh Bahg, Sloutsky, dan Turner (2025), yang memperingatkan bahwa algoritma personalisasi sering kali mengorbankan diversitas informasi dan membatasi eksposur pengguna terhadap perspektif alternatif. Dalam konteks pembelajaran, lingkungan yang terlampau dipersonalisasi (*hyper-personalized*) dapat mendistorsi pemahaman siswa terhadap ruang masalah, mendorong pengambilan sampel informasi yang bias, serta memicu generalisasi pengetahuan yang keliru (*inaccurate generalization*) yang sering kali justru diiringi oleh rasa percaya diri yang semu (*overconfidence*).

Sebaliknya, keberadaan mekanisme intervensi terautomasi (*automated intervention*) pada Grup A berhasil memutus siklus stagnasi tersebut. Dengan "memaksa" terjadinya pertukaran perspektif melalui konten *peer-review* secara terkalibrasi, sistem tidak hanya berhasil mendiversifikasi eksposur siswa, tetapi secara statistik terbukti membangkitkan kembali grafik pertumbuhan kemahiran mereka. Terlihat dari perubahan gradien yang positif setelah titik terdeteksinya stagnasi dan nilai positif NLG yang signifikan secara statistik.

Meskipun memberikan hasil yang positif, terdapat beberapa faktor yang perlu diperhatikan sebagai ancaman terhadap validitas (*threats to validity*) eksperimen ini:

1. **Efek Pemanasan (*Testing Effect*):** Terdapat potensi bahwa kenaikan skor pada Grup A disebabkan oleh partisipan yang mulai ”mengingat kembali” (*warm-up*) materi Basis Data lama mereka. Namun, hal ini dapat dimitigasi dengan membandingkan performa Grup B (kontrol). Jika kenaikan tersebut murni karena efek pemanasan, maka Grup B seharusnya juga menunjukkan tren kenaikan skor. Faktanya, Grup B justru mengalami penurunan performa, yang membuktikan bahwa peningkatan pada Grup A secara dominan dipengaruhi oleh intervensi kolaboratif sistem.
2. **Generalisasi Hasil (*External Validity*):** Pengujian ini melibatkan jumlah sampel yang terbatas ($n = 10$) dan bersifat homogen (mahasiswa dari satu program studi). Sesuai dengan tujuan pengembangan purwarupa, penelitian ini dikategorikan sebagai *Pilot Study* yang merujuk pada metodologi Sukserm (2024), di mana fokus utama diletakkan pada pengujian validitas internal arsitektur dan pembuktian konsep (*proof-of-concept*) alih-alih generalisasi populasi luas.
3. **Bias Pengamatan (*Hawthorne Effect*):** Partisipan yang menyadari bahwa mereka sedang diobservasi dalam lingkungan laboratorium cenderung bersikap lebih patuh atau rajin dibandingkan kondisi belajar mandiri yang sebenarnya. Mitigasi terhadap hal ini dilakukan melalui penerapan sistem *double-blind* dan anonimitas total dalam pemberian ulasan sejawat, guna memastikan interaksi tetap berjalan secara objektif dan meminimalkan bias relasional antar-partisipan.

Implikasi dari studi ini menunjukkan bahwa desain sistem *e-learning* ke depannya tidak cukup lagi hanya dengan merekomendasikan soal yang selaras dengan kemahiran, melainkan harus memiliki fitur mitigasi sosial proaktif. Umpan balik kualitatif tambahan dari mahasiswa menunjukkan bahwa interupsi proaktif dari sistem membantu meringankan beban psikologis bagi siswa yang merasa ”malu/takut” untuk bertanya langsung pada sejawat. Adanya batasan anonimitas yang diatur secara algoritmik (*Constraint-based Re-ranking*) memberikan dorongan positif bagi mereka untuk meninjau kueri secara objektif tanpa bias. Hal ini meletakkan fondasi baru bagi perancangan sistem pendidikan adaptif yang lebih kolaboratif dan manusiawi.

BAB VII

PENUTUP

Bab ini menyajikan kesimpulan yang ditarik dari hasil rancang bangun, implementasi, serta evaluasi yang telah dilakukan terhadap purwarupa sistem Equilibria. Selain itu, bab ini juga memuat saran bagi pengguna sistem dan rekomendasi pengembangan lebih lanjut untuk menyempurnakan penelitian di masa depan.

VII.1 Kesimpulan

Berdasarkan hasil pelaksanaan tugas akhir yang mencakup proses perancangan, realisasi mekanisme, dan implementasi sistem asesmen adaptif kolaboratif Equilibria, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Telah berhasil dirancang sebuah arsitektur sistem asesmen adaptif yang mengintegrasikan parameter kemahiran individual berbasis algoritma *Elo rating* dengan dimensi kontribusi sosial secara holistik. Rancangan ini memungkinkan sistem untuk memodelkan profil siswa tidak hanya berdasarkan kemampuan pengerjaan soal secara mandiri, tetapi juga keterlibatan aktif dalam aktivitas kolaboratif.
2. Telah berhasil dikembangkan mekanisme mitigasi *overpersonalization* yang bekerja secara proaktif melalui deteksi stagnasi kognitif (berdasarkan variansi perubahan skor $\Delta\theta$) dan pemilihan mitra kolaborasi yang heterogen menggunakan algoritma *Constraint-based Re-ranking*. Mekanisme ini terbukti mampu memicu intervensi sosial secara otomatis untuk memecah isolasi pembelajaran (*filter bubble*) yang dialami siswa.
3. Telah berhasil diimplementasikan purwarupa sistem asesmen adaptif kolaboratif bernama Equilibria pada domain pembelajaran kueri SQL. Implementasi ini mencakup integrasi lingkungan eksekusi *query (sandbox)* yang aman, pembaruan rating secara *real-time*, serta antarmuka pembelajaran yang reaktif guna mendukung siklus belajar adaptif dan interaksi sejawat secara transparan.

VII.2 Saran

Berdasarkan pengalaman selama proses pengerjaan dan temuan pada tahap evaluasi, terdapat beberapa saran yang dapat dipertimbangkan oleh pengguna atau pengelola sistem:

1. **Bagi Instruktur/Pengajar:** Disarankan untuk tidak membiarkan siswa menggunakan sistem adaptif individual dalam durasi yang terlalu lama tanpa adanya sesi interaksi antar-rekan, guna mencegah terjadinya frustrasi akademik akibat materi yang terlalu tersegmentasi pada satu tingkat kesulitan saja.
2. **Bagi Siswa:** Umpan balik dari rekan sejawat sebaiknya ditinjau secara kritis sebagai bahan refleksi diri, karena proses memberikan dan menerima ulasan terbukti secara statistik membantu mempercepat penguasaan konsep yang sulit dibandingkan belajar secara mandiri.

VII.3 Saran Pengembangan Selanjutnya

Penelitian ini masih memiliki keterbatasan yang dapat diperbaiki pada pengembangan selanjutnya, antara lain:

1. **Rekalibrasi Parameter Stagnasi:** Ambang batas variansi ($\epsilon = 165$) yang digunakan saat ini terdeteksi terlalu sensitif (*hypersensitive*). Pengembangan selanjutnya perlu mencari nilai ambang batas yang lebih optimal atau menggunakan jendela aktivitas (*sliding window*) yang lebih lebar agar tidak setiap fluktuasi kecil memicu intervensi.
2. **Peningkatan Akurasi NLP untuk Bahasa Indonesia:** Komponen *Social Elo* dapat diperkuat dengan menggunakan model bahasa alami yang dilatih secara spesifik pada istilah teknis komputasi dalam bahasa Indonesia, guna meningkatkan akurasi penilaian kualitas umpan balik secara otomatis.
3. **Integrasi Model Generatif (LLM):** Penggunaan *Large Language Model* dapat dipertimbangkan untuk membantu memberikan *scaffolding* awal kepada siswa saat melakukan *peer review*, misalnya dengan memberikan saran poin-poin kesalahan yang perlu dikomentari pada kueri rekan.
4. **Pengujian Skala Besar:** Melakukan pengujian pada populasi siswa yang lebih besar dan durasi yang lebih lama (satu semester penuh) untuk melihat stabilitas konvergensi skor *Social Elo* serta dampak jangka panjang terhadap retensi pengetahuan siswa.

DAFTAR PUSTAKA

- Bahg, Giwon, Vladimir M. Sloutsky, dan Brandom M. Turner. 2025. "Supplemental Material for Algorithmic Personalization of Information Can Cause Inaccurate Generalization and Overconfidence". *Journal of Experimental Psychology: General* 154. ISSN: 0096-3445. <https://doi.org/10.1037/xge0001763.suppl>. <https://doi.org/10.1037/xge0001763.suppl>.
- Biasio, Alvise De, Merylin Monaro, Luca Oneto, Lamberto Ballan, dan Nicolò Navarin. 2023. "On the problem of recommendation for sensitive users and influential items: Simultaneously maintaining interest and diversity". *Knowledge-Based Systems* 275. ISSN: 09507051. <https://doi.org/10.1016/j.knosys.2023.110699>.
- Brusilovsky, Peter, Sibel Somyurek, Julio Guerra, Roya Hosseini, Vladimir Zadorozhny, dan Paula J. Durlach. 2016. "Open Social Student Modeling for Personalized Learning". *IEEE Transactions on Emerging Topics in Computing* 4 (3): 450–461. ISSN: 21686750. <https://doi.org/10.1109/TETC.2015.2501243>.
- Cohen, Jacob. 1988. *Statistical Power Analysis for the Behavioral Sciences Second Edition*. 2nd. Lawrence Erlbaum Associates. ISBN: 0-8058-0283-5.
- Coletta, Vincent P., dan Jeffrey J. Steinert. 2020. "Why normalized gain should continue to be used in analyzing preinstruction and postinstruction scores on concept inventories". *Physical Review Physics Education Research* 16 (1). ISSN: 24699896. <https://doi.org/10.1103/PhysRevPhysEducRes.16.010108>.
- Computing Education in Community Colleges, ACM Committee for. 2023. *Bloom's for Computing: Enhancing Bloom's Revised Taxonomy with Verbs for Computing Disciplines*. ACM. <https://doi.org/10.1145/3587276>.
- Daif-Allah, Ayman Sabry, dan Mohammad Imran Khan. 2016. "The Impact of Open Discussion Sessions on Enhancing the Oral Communicative Abilities of Saudi English Language Majors at Buraydah Community College". *English Language Teaching* 9 (6): 108. ISSN: 1916-4742. <https://doi.org/10.5539/elt.v9n6p108>.

- Demetroulis, Emmanouil A., Ilias Papadogiannis, Manolis Wallace, Vassilis Pouloupoulos, Anastasios Theodoropoulos, Nikos Vasilopoulos, Angeliki Antoniou, dan Fotini Dasakli. 2024. "Collaboration Skills and Puzzles: Development of a Performance-Based Assessment—Results from 12 Primary Schools in Greece". *Education Sciences* 14 (10): 1056. ISSN: 2227-7102. <https://doi.org/10.3390/educsci14101056>.
- Dokoupil, Patrik. 2022. "Long-term fairness for Group Recommender Systems with Large Groups", 724–726. Association for Computing Machinery, Inc. ISBN: 9781450392785. <https://doi.org/10.1145/3523227.3547424>.
- Elo, Arpad E. 1978. *THE RATING OF CHESSPLAYERS PAST & PRESENT*. 2nd. Arco Publishing Inc. ISBN: 0-668-04721-6.
- Fu, Xinjian, dan Qinbing Li. 2025. "Effectiveness of Role-play Method: A Meta-analysis". *International Journal of Instruction* 18 (1): 309–324. ISSN: 1694609X. <https://doi.org/10.29333/iji.2025.18117a>. http://www.e-iji.net/dosyalar/iji_2025_1_17.pdf.
- Gosselin, Kathryn, dan Nicole Okamoto. 2018. "Improving Instruction and Assessment via Bloom's Taxonomy and Descriptive Rubrics". Dalam *2018 ASEE Annual Conference & Exposition Proceedings*. ASEE Conferences. <https://doi.org/10.18260/1-2--30630>. <http://peer.asee.org/30630>.
- Hadi, Samsul, Muh AM Asriadi, dan Abdul Rahim. 2022. "Developing Classroom Assessment Tool using Learning Management System-based Computerized Adaptive Test in Vocational High Schools". *Journal of Educational Research and Evaluation* 6:143–155. <https://doi.org/10.23887/jere.v6i1>. <https://dx.doi.org/10.23887/jere.v6i1>.
- Halkiopoulos, Constantinos, dan Evgenia Gkintoni. 2024. *Leveraging AI in E-Learning: Personalized Learning and Adaptive Assessment through Cognitive Neuropsychology—A Systematic Analysis*. <https://doi.org/10.3390/electronics13183762>.
- Handayani, Dian, Muhammad Alief Ghifari, Vera Maya Santi, dan Rahfa Qur'aniyatin Dhuha. 2025. "ITEM RESPONSE MODEL FOR ANALYZING ITEM RESPONSES IN THE INSTRUMENT OF CHANGE MANAGEMENT AND ORGANIZATIONAL CULTURE". *Jurnal Statistika dan Aplikasinya* 9 (1): 37–49. <https://doi.org/10.21009/jsa.09104>.

- Ihichr, Adel, Omar Oustous, Younes El Bouzekri, El Idrissi, dan Ayoub Ait Lahcen. 2024. *A Systematic Review on Assessment in Adaptive Learning: Theories, Algorithms and Techniques*. www.ijacsa.thesai.org.
- Jiang, Tingting, Zhumo Sun, dan Shiting Fu. 2025. “Restraining the formation of filter bubbles with algorithmic affordances: Toward more balanced information consumption and decreased attitude extremity”. *Journal of the Association for Information Science and Technology* 76 (7): 989–1005. ISSN: 23301643. <https://doi.org/10.1002/asi.24988>.
- Kelompok Kerja Penyusun Strategi Nasional untuk Kecerdasan Artifisial. 2020. *AI TOWARDS INDONESIA VISION 2045*. Badan Pengkajian dan Penerapan Teknologi.
- Kerman, Nafiseh Taghizadeh, Omid Noroozi, Seyyed Kazem Banihashem, Morteza Karami, dan Harm J.A. Biemans. 2024. “Online peer feedback patterns of success and failure in argumentative essay writing”. *Interactive Learning Environments* 32 (2): 614–626. ISSN: 17445191. <https://doi.org/10.1080/10494820.2022.2093914>.
- Le, Huong-Giang, Sarin Sok, dan Kimkong Heng. 2024. *Journal of Learning Development in Higher Education The benefits of peer mentoring in higher education: findings from a systematic review*.
- Lu, Jingyan, dan Zhidong Zhang. 2012. “Understanding the Effectiveness of Online Peer Assessment: A Path Model”. *Journal of Educational Computing Research* 46 (3): 313–333. ISSN: 0735-6331. <https://doi.org/10.2190/EC.46.3.f>. <https://journals.sagepub.com/doi/10.2190/EC.46.3.f>.
- Minn, Sein. 2022. “AI-assisted knowledge assessment techniques for adaptive learning environments”. *Computers and Education: Artificial Intelligence* 3. ISSN: 2666920X. <https://doi.org/10.1016/j.caeai.2022.100050>.
- Nalli, Giacomo, Daniela Amendola, dan Serengul Smith. 2022. “Artificial Intelligence to improve learning outcomes through online collaborative activities”. *European Conference on e-Learning* 21 (1): 475–479. ISSN: 2048-8645. <https://doi.org/10.34190/ecel.21.1.661>. <https://papers.academic-conferences.org/index.php/ecel/article/view/661>.

- Nissen, Jayson M., Robert M. Talbot, Amreen Nasim Thompson, dan Ben Van Dusen. 2018. "Comparison of normalized gain and Cohen's d for analyzing gains on concept inventories". *Physical Review Physics Education Research* 14 (1). ISSN: 24699896. <https://doi.org/10.1103/PhysRevPhysEducRes.14.010115>.
- Ren, Baofeng, Tianyuan Yang, Boxuan Ma, dan Shin'ichi Konomi. 2025. "Leveraging personalized diversity level for recommendations with knowledge graph". *Journal of Intelligent Information Systems*, ISSN: 15737675. <https://doi.org/10.1007/s10844-025-01013-8>.
- Ryoo, Jungwoo, dan Kurt Winkelmann. 2021. *Innovative Learning Environments in STEM Higher Education*. <http://www.springer.com/series/8921>.
- Silberschatz, Abraham., Henry F. Korth, dan S.. Sudarshan. March 2019. *Database system concepts*. 7th. 1344. McGraw-Hill. ISBN: 9780078022159.
- Sukserm, Patsawut. 2024. "Determining the Appropriate Sample Size in EFL Pilot Studies". *Journal of Research Methodology* 37 (3): 245–264. ISSN: 0857-2933. <https://doi.org/10.14456/jrm.2024.13>.
- Tommasel, Antonela, Juan Manuel Rodriguez, dan Daniela Godoy. 2021. "I Want to break free! recommending friends from outside the echo chamber", 23–33. Association for Computing Machinery, Inc. ISBN: 9781450384582. <https://doi.org/10.1145/3460231.3474270>.
- Vesin, Boban, Katerina Mangaroska, Kamil Akhuseyinoglu, dan Michail Giannakos. 2022. "Adaptive Assessment and Content Recommendation in Online Programming Courses: On the Use of Elo rating". *ACM Transactions on Computing Education* 22 (3). ISSN: 19466226. <https://doi.org/10.1145/3511886>.
- Wang, Wenjie, Fuli Feng, Liqiang Nie, dan Tat Seng Chua. 2022. "User Controllable Recommendation Against Filter Bubbles", 1251–1261. Association for Computing Machinery, Inc. ISBN: 9781450387323. <https://doi.org/10.1145/3477495.3532075>.
- Zhang, Lu, dan Yan Ma. 2023. "A study of the impact of project-based learning on student learning effects: a meta-analysis study". *Frontiers in Psychology* 14. ISSN: 16641078. <https://doi.org/10.3389/fpsyg.2023.1202728>.